

中国海洋大学海德学院

统计建模与推断

THOMAS TUFTE STYLE BOOK TEMPLATE

版权所有 © 2026 中国海洋大学海德学院

由 Thomas Tufte Style Book Template 出版

首次印刷, *June 2026*

本笔记涵盖《统计建模与推断》第 1-14 周内容: 统计推断、置信区间、假设检验、双样本推断、比例推断, 简单与多元线性回归、多项式回归, 一元线性回归的参数估计、单因素与双因素方差分析、最大似然估计 (MLE) 以及 Fisher 信息.

Contents

1	单一总体均值的推断	9
2	两总体均值的推断 (Inference for Two Population Means)	23
3	总体比例的推断 (Inference for Population Proportions)	29
4	一元与多元线性回归 (Simple and Multiple Linear Regression)	33
5	多项式回归 (Polynomial Regression) 与非线性效应 (Non-Linear Effects)	43
6	一元线性回归的参数估计 (Parameter Estimation)	49
7	单因素方差分析 (One-Way ANOVA)	55
8	双因素方差分析 (Two-Way ANOVA)	61
9	最大似然估计 (Maximum Likelihood Estimation)	65
10	Fisher 信息 (Fisher Information)	71
11	关键公式汇总	75

List of Figures

- 4.1 由 R 脚本 `scripts/week5_tree_scatter.R` 生成的树高与树干周长散点图. 39

List of Tables

- 7.1 单因素 ANOVA 表. 57
- 8.1 双因素 ANOVA 表 (共 $n = bk$ 个观测). 62

1

单一总体均值的推断

§1.1 统计推断导论

统计推断 (Statistical Inference) 是指基于 **样本 (Sample)** 对 **总体 (Population)** 作出带有不确定性度量的推广性结论. 总体是研究者真正关心的全部对象或单位; 样本是实际观测到的总体子集.

量	总体	样本
描述	参数 (Parameter)	统计量 (Statistic)
是否由观测数据计算	否	是
在研究中是否固定	是	否, 随样本变化
均值	μ	$\bar{Y}$
方差	σ^2	S^2
标准差	σ	S

Definition 1.1: 点估计 (Point Estimate)

点估计是由样本数据计算得到的单个数值, 用作未知总体参数的最佳猜测. 例如 $\bar{Y}$ 估计 μ , S^2 估计 σ^2 , S 估计 σ .

Definition 1.2: 偏差 (Bias) 与均方误差 (MSE)

设 $\hat{\theta}$ 是参数 θ 的估计量. 其偏差为

$$B(\hat{\theta}) = E(\hat{\theta}) - \theta.$$

均方误差为

$$\text{MSE}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2].$$

若 $B(\hat{\theta}) = 0$, 即 $E(\hat{\theta}) = \theta$, 则称 $\hat{\theta}$ 为无偏估计量.

Proposition 1.3: 偏差-方差分解

任意估计量 $\hat{\theta}$ 满足

$$\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + [B(\hat{\theta})]^2.$$

Proof 写成

$$\hat{\theta} - \theta = \hat{\theta} - E(\hat{\theta}) + E(\hat{\theta}) - \theta = \hat{\theta} - E(\hat{\theta}) + B(\hat{\theta}).$$

两边平方并取期望:

$$\begin{aligned} \text{MSE}(\hat{\theta}) &= E[(\hat{\theta} - E(\hat{\theta}) + B(\hat{\theta}))^2] \\ &= E[(\hat{\theta} - E(\hat{\theta}))^2] + 2B(\hat{\theta})E[\hat{\theta} - E(\hat{\theta})] + [B(\hat{\theta})]^2 \\ &= \text{Var}(\hat{\theta}) + [B(\hat{\theta})]^2. \end{aligned}$$

□

Remark 常用期望与方差性质

对常数 a, b, c 与随机变量 X, Y :

$$E(c) = c, \quad E(aX + b) = aE(X) + b, \quad \text{Var}(aX + b) = a^2 \text{Var}(X),$$

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y).$$

若 X, Y 独立, 协方差项为零.

Example 1.4: 构造无偏估计量

设 $\hat{\theta}$ 估计 θ , 且 $E(\hat{\theta}) = a\theta + b$, 其中 $a \neq 0$. 求偏差并构造 θ 的无偏估计量.

Solution 偏差为

$$B(\hat{\theta}) = E(\hat{\theta}) - \theta = (a - 1)\theta + b.$$

由 $E(\hat{\theta}) = a\theta + b$ 解出 $\theta = (E(\hat{\theta}) - b)/a$. 因此定义

$$\hat{\theta}^* = \frac{\hat{\theta} - b}{a}.$$

则

$$E(\hat{\theta}^*) = \frac{E(\hat{\theta}) - b}{a} = \frac{a\theta + b - b}{a} = \theta,$$

故 $\hat{\theta}^*$ 为无偏估计量.

□

Example 1.5: 合并两个无偏估计量

设 $E(\hat{\theta}_1) = E(\hat{\theta}_2) = \theta$, $\text{Var}(\hat{\theta}_1) = \sigma_1^2$, $\text{Var}(\hat{\theta}_2) = \sigma_2^2$. 定义

$$\hat{\theta}_3 = a\hat{\theta}_1 + (1-a)\hat{\theta}_2.$$

(a) 证明 $\hat{\theta}_3$ 是 θ 的无偏估计量.

(b) 若 $\hat{\theta}_1$ 与 $\hat{\theta}_2$ 独立, 选择 a 使 $\text{Var}(\hat{\theta}_3)$ 最小.

(c) 若二者不独立且 $\text{Cov}(\hat{\theta}_1, \hat{\theta}_2) = c \neq 0$, 选择 a 使 $\text{Var}(\hat{\theta}_3)$ 最小.

Solution (a) 无偏性.

$$E(\hat{\theta}_3) = a\theta + (1-a)\theta = \theta,$$

因此任意 a 都给出无偏估计量.

(b) 独立估计量. 若两个估计量独立,

$$\text{Var}(\hat{\theta}_3) = a^2\sigma_1^2 + (1-a)^2\sigma_2^2.$$

对 a 求导:

$$\frac{d}{da} \text{Var}(\hat{\theta}_3) = 2a\sigma_1^2 - 2(1-a)\sigma_2^2.$$

令导数为零:

$$a\sigma_1^2 = (1-a)\sigma_2^2 \implies a = \frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2}.$$

方差较小的估计量获得较大的权重.

(c) 相关估计量. 若 $\text{Cov}(\hat{\theta}_1, \hat{\theta}_2) = c$,

$$\text{Var}(\hat{\theta}_3) = a^2\sigma_1^2 + (1-a)^2\sigma_2^2 + 2a(1-a)c.$$

展开并求导:

$$\frac{d}{da} \text{Var}(\hat{\theta}_3) = 2a\sigma_1^2 - 2(1-a)\sigma_2^2 + 2(1-2a)c.$$

令导数为零:

$$a\sigma_1^2 + a\sigma_2^2 - 2ac = \sigma_2^2 - c \implies a = \frac{\sigma_2^2 - c}{\sigma_1^2 + \sigma_2^2 - 2c}.$$

当 $c = 0$ 时, 该公式退化为独立情形. □

§1.2 基本术语

Definition 1.6: 参数 (Parameter) 与统计量 (Statistic)

参数是对总体 (Population) 的数值描述 (例如总体均值 (Population Mean) μ 、总体方差 (Population Variance) σ^2). **统计量**是由样本 (Sample) 数据计算得到的数值 (例如样本均值 (Sample Mean) $\bar{Y}$ 、样本方差 (Sample Variance) S^2).

Definition 1.7: 单尾检验与双尾检验

单尾检验 (One-Tailed Test) 的备择假设只指定一个方向:

$$H_a : \theta > \theta_0 \quad \text{或} \quad H_a : \theta < \theta_0.$$

双尾检验 (Two-Tailed Test) 的备择假设为参数不等于原假设值:

$$H_a : \theta \neq \theta_0.$$

双尾检验同时考察“大于”和“小于”两个方向, 因而显著性水平 α 分配到两个尾部.

Definition 1.8: 统计推断 (Statistical Inference)

利用样本统计量对未知总体参数作出推断. 主要包含两个分支:

- **估计 (Estimation)** – 用点估计 (Point Estimate, 单一数值) 或区间估计 (Interval Estimate, 取值范围) 预测参数.
- **假设检验 (Hypothesis Testing)** – 判断样本数据是否与指定的参数取值一致.

§1.3 有偏估计 (Biased Estimator) 与无偏估计 (Unbiased Estimator)**Theorem 1.9: 有偏与无偏样本方差**

设 $Y_1, Y_2, \dots, Y_n$ 为随机样本 (Random Sample), $E(Y_i) = \mu$, $\text{Var}(Y_i) = \sigma^2$. 定义:

$$S'^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2 \quad \text{与} \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2.$$

则:

- S'^2 是 **有偏估计**: $E(S'^2) = \frac{n-1}{n} \sigma^2 \neq \sigma^2$.
- S^2 是 **无偏估计**: $E(S^2) = \sigma^2$.

Remark

S^2 中分母 $n-1$ 校正了由 $\bar{Y}$ 估计 μ 时损失的一个自由度 (Degrees of Freedom). 在推断中, 总是优先采用 S^2 .

§1.4 μ 的置信区间 (Confidence Interval, CI) – 大样本

1.4.1 抽样分布 (Sampling Distribution)

由中心极限定理 (Central Limit Theorem, CLT), 当 n 充分大时:

$$\bar{Y} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right).$$

正态变量 (Normal Variable) 落在均值 ± 1.96 倍标准差 (Standard Deviation) 范围内的概率约为 0.95:

$$P\left(\mu - 1.96 \frac{\sigma}{\sqrt{n}} \leq \bar{Y} \leq \mu + 1.96 \frac{\sigma}{\sqrt{n}}\right) \approx 0.95.$$

1.4.2 一般公式

μ 的 $(1-\alpha) \times 100\%$ 置信区间为:

$$\bar{y} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

其中 $z_{\alpha/2}$ 是标准正态分布 (Standard Normal Distribution) 的上 $\alpha/2$ 临界值 (Critical Value).

Definition 1.10: 误差限 (Margin of Error)

$(1-\alpha) \times 100\%$ 置信水平 (Confidence Level) 下的 **误差限** 为 $z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$, 置信区间即 $\bar{y} \pm$ 误差限.

1.4.3 常用临界值

$1-\alpha$	$\alpha/2$	$1-\alpha/2$	$z_{\alpha/2}$
0.90	0.050	0.950	1.645
0.95	0.025	0.975	1.960
0.99	0.005	0.995	2.576

Example 1.11: 90% 置信区间 – 超市购物时间

某超市记录了 $n = 64$ 位随机选取顾客的购物时间. 该样本的平均购物时间为 $\bar{y} = 33$ 分钟. 假设购物时间的总体方差已知为 $\sigma^2 = 256$ 分钟² (即 $\sigma = 16$ 分钟). 求每位顾客真实平均购物时间的 90% 双侧置信区间 (Confidence Interval).

Solution

$$33 \pm 1.645 \frac{16}{\sqrt{64}} = 33 \pm 3.29 \implies (29.71, 36.29).$$

有 90% 把握认为真实平均购物时间在 29.71 至 36.29 分钟之间. $\square$

Example 1.12: 95% 置信区间 – 苹果重量

一位市场经理想估计某一特定品种苹果的平均重量. 他随机抽取 $n = 36$ 个苹果, 得到样本平均重量 $\bar{y} = 150$ g. 已知总体标准差为 $\sigma = 12$ g. 求真实平均苹果重量的 95% 置信区间 (Confidence Interval).

Solution

$$150 \pm 1.96 \frac{12}{\sqrt{36}} = 150 \pm 3.92 \implies (146.08, 153.92).$$

$\square$

§1.5 μ 的置信区间 – 小样本 ($n < 30$)

当 $n < 30$ 且总体 (近似) 正态、 σ 未知时, 用 S 替代 σ . 标准化统计量

$$t = \frac{\bar{Y} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

服从自由度 $\nu = n - 1$ 的 t 分布 (t -distribution).

$(1 - \alpha) \times 100\%$ 置信区间为:

$$\boxed{\bar{y} \pm t_{\alpha/2, \nu} \frac{S}{\sqrt{n}}} \quad \text{其中 } \nu = n - 1.$$

Example 1.13: 90% 与 98% 置信区间 – 体温

健康人类的正常体温是多少? 一位医生提供了 $n = 24$ 名健康人群的随机体温样本, 样本平均值为 $\bar{y} = 98.25^\circ\text{F}$, 样本标准差为 $s = 0.73^\circ\text{F}$.

(a) 估计健康人群平均体温的 90% 置信区间.

(b) 估计健康人群平均体温的 98% 置信区间.

Solution (a) 90% 区间: $t_{0.05, 23} = 1.714$

$$98.25 \pm 1.714 \times \frac{0.73}{\sqrt{24}} = 98.25 \pm 0.255 \implies (97.995, 98.505).$$

(b) 98% 区间: $t_{0.01, 23} = 2.500$

$$98.25 \pm 2.500 \times \frac{0.73}{\sqrt{24}} = 98.25 \pm 0.373 \implies (97.877, 98.623).$$

□

Remark

置信水平越高, 区间越宽: 98% 区间比 90% 区间更宽.

§1.6 μ 的假设检验

1.6.1 基本框架

Definition 1.14: 假设检验的要素 (Elements of a Hypothesis Test)

- (1) **原假设 (Null Hypothesis) H_0** : 被检验的命题, 含等号, 默认成立直至有证据反驳.
- (2) **备择假设 (Alternative Hypothesis) H_a** : 与 H_0 矛盾, 仅在数据提供强有力证据时方可接受. 可单边 (One-Sided) 或双边 (Two-Sided).
- (3) **检验统计量 (Test Statistic)**: 衡量观测统计量与 H_0 下假设值之间的差异.
- (4) **拒绝域 (Rejection Region)**: 导致拒绝 H_0 的检验统计量取值集合.
- (5) **P 值 (P-value)**: 在 H_0 为真的前提下, 沿 H_a 方向观测到至少与实际数据同样极端的数据的概率.

Definition 1.15: 第一类与第二类错误

- **第一类错误 (Type I Error)**: H_0 为真时拒绝 H_0 . $P(\text{第一类}) = \alpha$.
- **第二类错误 (Type II Error)**: H_a 为真时未能拒绝 H_0 . $P(\text{第二类}) = \beta$.

1.6.2 检验统计量(大样本)

检验 $H_0: \mu = \mu_0, \sigma$ 已知 (或大样本下估计):

$$Z_{\text{obs}} = \frac{\bar{y} - \mu_0}{\sigma / \sqrt{n}}$$

在 H_0 下, $Z_{\text{obs}} \sim N(0, 1)$ 近似.

分子 $\bar{y} - \mu_0$ 是样本均值与原假设值的观测差异; 分母 $\sigma / \sqrt{n}$ 是 $\bar{Y}$ 的标准误. 因此检验统计量表示观测均值距离原假设值有多少个标准误.

Remark

实践中 σ 未知, 大样本时用 s 替代; 当 $n \geq 30$ 时该近似可接受.

1.6.3 决策规则

取得检验统计量后, 可用拒绝域或 p 值作决策:

- 拒绝域方法: 将观测统计量与由 α 决定的临界值比较.
- p 值方法: 在 H_0 为真时, 计算沿 H_a 方向观测到至少同样极端统计量的概率. 若 $\text{p-value} \leq \alpha$, 拒绝 H_0 .

备择假设	拒绝 H_0 当	P 值
右尾: $H_a: \mu > \mu_0$	$Z_{\text{obs}} > z_\alpha$	$P(Z \geq Z_{\text{obs}})$
左尾: $H_a: \mu < \mu_0$	$Z_{\text{obs}} < -z_\alpha$	$P(Z \leq Z_{\text{obs}})$
双尾: $H_a: \mu \neq \mu_0$	$ Z_{\text{obs}} > z_{\alpha/2}$	$2P(Z \geq Z_{\text{obs}})$

Example 1.16: 双侧检验 – 居民体重

某城镇居民平均体重长期报告为 168 磅. 研究者认为真实均值可能不同. 她随机测量 65 人, 得到 $\bar{y} = 169.5$ 磅, 样本标准差 $s = 3.9$ 磅. 在 5% 显著性水平下检验总体均值是否不同于 168 磅.

Solution 第 1 步 – 假设:

$$H_0: \mu = 168, \quad H_a: \mu \neq 168.$$

第 2 步 – 检验统计量:

$$Z_{\text{obs}} = \frac{169.5 - 168}{3.9 / \sqrt{65}} = \frac{1.5}{0.484} \approx 3.10.$$

双侧 $\alpha = 0.05$ 的临界值为 ± 1.96 . 因 $|3.10| > 1.96$, 拒绝 H_0 .

P 值为

$$2P(Z \geq 3.10) = 2(1 - 0.9990) = 0.0019 < 0.05.$$

有充分证据认为真实平均体重与 168 磅不同. $\square$

Example 1.17: 左尾检验 – 汽车质保期

某汽车工厂对发动机和变速箱提供 5 年质保. 工程师认为故障时间均值小于 5 年. 他抽取 50 辆车, 得平均故障时间 $\bar{y} = 4.8$ 年, 标准差 $s = 0.5$ 年. 在 1% 显著性水平下检验是否应修订质保期.

Solution

$$H_0: \mu = 5, \quad H_a: \mu < 5.$$

$$Z_{\text{obs}} = \frac{4.8 - 5}{0.5/\sqrt{50}} = \frac{-0.2}{0.0707} \approx -2.83.$$

左尾 $\alpha = 0.01$ 的拒绝域为 $Z_{\text{obs}} < -z_{0.01} = -2.326$. 因 $-2.83 < -2.326$, 拒绝 H_0 . p 值约为 $P(Z \leq -2.83) = 0.0023 < 0.01$. 有充分证据认为平均故障时间小于 5 年, 应修订质保期. $\square$

§1.7 μ 的 t 检验 (小样本)

n 小且 σ 未知时, 用以下统计量替换 Z_{obs} :

$$t_{\text{obs}} = \frac{\bar{y} - \mu_0}{s/\sqrt{n}} \sim t(n-1).$$

1.7.1 t 检验的决策规则

备择假设	拒绝 H_0 当	P 值
右尾: $\mu > \mu_0$	$t_{\text{obs}} \geq t_{\alpha, \nu}$	$P(t_{(\nu)} \geq t_{\text{obs}})$
左尾: $\mu < \mu_0$	$t_{\text{obs}} \leq -t_{\alpha, \nu}$	$P(t_{(\nu)} \leq t_{\text{obs}})$
双尾: $\mu \neq \mu_0$	$ t_{\text{obs}} \geq t_{\alpha/2, \nu}$	$2P(t_{(\nu)} \geq t_{\text{obs}})$

Example 1.18: 双侧 t 检验 – 北京至巴黎飞行时间

北京至巴黎某航线的计划飞行时间为 580 分钟. 从该航线所有航班中随机选取 $n = 31$ 个航班, 得到样本平均飞行时间 $\bar{y} = 574.1$ 分钟, 样本标准差 $s = 19.7$ 分钟. 在 $\alpha = 0.05$ 下检验总体平均飞行时间是否不同于计划时间.

使用 $H_0: \mu = 580$ 与 $H_a: \mu \neq 580$. 对自由度 $n - 1 = 30$ 的双侧检验, $t_{0.025, 30} = 2.042$.

Solution

$$t_{\text{obs}} = \frac{574.1 - 580}{19.7/\sqrt{31}} = \frac{-5.9}{3.54} \approx -1.67.$$

双侧 $\alpha = 0.05$ 的临界值 $t_{0.025,30} = 2.042$. 因 $|-1.67| < 2.042$, 不拒绝 H_0 .

P 值 $= 2P(t_{(30)} \geq 1.67) \approx 0.10 > 0.05$. 无显著证据认为真实平均飞行时间与 580 分钟有差异. $\square$

Example 1.19: 单尾 t 检验 – 颜色词阅读时间

实验检验当颜色词用不同颜色书写时, 阅读颜色列表的总体平均时间是否增加. 对第 i 个被试, 定义

$$y_i = \text{Different colour 条件时间} - \text{Black 条件时间}.$$

样本结果为 $n = 70, \bar{y} = 2.39, s = 7.81$. 在 $\alpha = 0.05$ 下检验均值差是否为正.

Solution

$$H_0 : \mu \leq 0, \quad H_a : \mu > 0.$$

$$Z_{\text{obs}} = \frac{2.39 - 0}{7.81/\sqrt{70}} = \frac{2.39}{0.93} = 2.57.$$

右尾 $\alpha = 0.05$ 的临界值为 $z_{0.05} = 1.645$. 因 $2.57 > 1.645$, 拒绝 H_0 . p 值为

$$P(Z \geq 2.57) = 1 - 0.9949 = 0.0051.$$

数据表明不同颜色书写会增加阅读时间. $\square$

Example 1.20: 双侧检验 – 颜色词阅读时间

仍使用同一颜色词数据, 检验不同颜色书写是否会使平均阅读时间发生任意方向的变化.

Solution

$$H_0 : \mu = 0, \quad H_a : \mu \neq 0.$$

检验统计量仍为 $Z_{\text{obs}} = 2.57$. 双侧 $\alpha = 0.05$ 的临界值为 $z_{0.025} = 1.96$. 因 $|2.57| > 1.96$, 拒绝 H_0 . p 值为

$$2P(Z \geq 2.57) = 2(1 - 0.9949) = 0.0102.$$

数据支持存在非零阅读时间效应; 因 $\bar{y} > 0$, 观测效应方向为增加. $\square$

§1.8 Assignment 1 练习题

Example 1.21: Assignment 1 Q1 – 单总体均值

对单总体均值问题, 完整解答应包括: 参数与估计量、置信区间、原假设与备择假设、检验统计量与 p 值, 以及结合题意的结论.

Solution 通用流程为

$$\text{参数 } \mu, \quad \text{估计量 } \bar{Y}, \quad SE(\bar{Y}) = \begin{cases} \sigma/\sqrt{n}, & \sigma \text{ 已知}, \\ s/\sqrt{n}, & \sigma \text{ 未知}. \end{cases}$$

大样本或 σ 已知时用正态临界值; 小样本、总体近似正态且 σ 未知时用 t_{n-1} 临界值. 检验统计量为

$$Z_{\text{obs}} = \frac{\bar{y} - \mu_0}{\sigma/\sqrt{n}} \quad \text{或} \quad t_{\text{obs}} = \frac{\bar{y} - \mu_0}{s/\sqrt{n}}.$$

□

Example 1.22: Assignment 1 Q2 – 学生每周工作时间

研究者关心学生边上课边工作的影响. 对 200 名学生的调查给出每周工作小时数均值 $\bar{y} = 7.10$, 标准差约 $s = 3$ 小时.

- (i) 求总体均值的 95% 置信区间.
- (ii) 在 5% 显著性水平下检验学生平均每周工作是否超过 7 小时, 并给出检验统计量、拒绝域与结论.

Solution 样本量 $n = 200$ 较大:

$$SE = \frac{3}{\sqrt{200}} = 0.2121.$$

95% 置信区间:

$$7.10 \pm 1.96(0.2121) = 7.10 \pm 0.416 = (6.684, 7.516).$$

检验

$$H_0: \mu = 7, \quad H_a: \mu > 7.$$

$$Z_{\text{obs}} = \frac{7.10 - 7}{3/\sqrt{200}} = 0.47.$$

右尾 $\alpha = 0.05$ 的拒绝域为 $Z_{\text{obs}} > 1.645$. 因 $0.47 < 1.645$, 不拒绝 H_0 . p 值约 0.319, 无充分证据认为学生平均每周工作超过 7 小时. □

Example 1.23: Assignment 1 Q3 – 两总体均值

两总体均值问题需要先判断是独立样本还是配对样本, 再选择正确标准误、写出假设、计算统计量并结合原问题解释结论.

Solution 独立大样本比较 $\mu_1 - \mu_2$:

$$Z_{\text{obs}} = \frac{(\bar{y}_1 - \bar{y}_2) - \Delta_0}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}.$$

小样本且等方差时:

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}, \quad t_{\text{obs}} = \frac{(\bar{y}_1 - \bar{y}_2) - \Delta_0}{\sqrt{S_p^2(1/n_1 + 1/n_2)}}.$$

配对样本先计算差值 d_i , 再用

$$t_{\text{obs}} = \frac{\bar{d} - \Delta_0}{s_d/\sqrt{n}}.$$

□

§1.9 检验功效 (Power of a Test)**Definition 1.24: 功效 (Power)**

检验的 **功效** 是 H_0 为假时正确拒绝 H_0 的概率:

$$\text{Power} = P(\text{拒绝 } H_0 \mid H_0 \text{ 为假}) = 1 - \beta.$$

当 H_0 为真时, 功效 = $P(\text{第一类错误}) = \alpha$.

Proposition 1.25: 影响功效的因素

其他条件不变时:

- (i) 样本量 n 越大, 功效 **越高**.
- (ii) 总体方差 σ^2 越小, 功效 **越高**.
- (iii) 真实均值离 μ_0 越远, 功效 **越高**.

Example 1.26: 功效计算

沿用干扰效应 (interference effect) 的均值差背景. 检验总体平均干扰效应是否为正:

$$H_0 : \mu = 0, \quad H_a : \mu > 0.$$

假设 $\sigma^2 = 64$, $n = 16$, 因而标准误 (Standard Error) $\sigma/\sqrt{n} = 8/4 = 2$. 在 $\alpha = 0.05$ 下, 单侧检验的决策规则为 $Z_{\text{obs}} \geq 1.645$ 时拒绝 H_0 . 当真实均值为 $\mu = 3.0$ 时, 计算检验功效 (Power).

Solution **决策规则** ($\alpha = 0.05$ 下拒绝 H_0):

$$Z_{\text{obs}} = \frac{\bar{y} - 0}{2} \geq 1.645 \implies \bar{y} \geq 3.29.$$

设真实均值 $\mu = 3.0$:

$$\text{Power} = P(\bar{Y} \geq 3.29 \mid \mu = 3.0) = P\left(Z \geq \frac{3.29 - 3.0}{2.0}\right) = P(Z \geq 0.145) = 1 - 0.5576 = 0.4424.$$

$\beta = 1 - 0.4424 = 0.5576$. 在该样本量下检测出 $\mu = 3$ 的概率仅 44.2%. □

两总体均值的推断 (Inference for Two Population Means)

§2.1 抽样设计

Definition 2.1: 独立样本 (Independent Samples) 与配对样本 (Paired Samples)

- **独立 (平行 Parallel) 样本:** 两组单元完全不同, n_1 与 n_2 不必相等.
- **配对 (交叉 Crossover) 样本:** 每个个体接受两种处理, 或形成自然配对, 分析差值 $d_i = Y_{1i} - Y_{2i}$.

§2.2 $\mu_1 - \mu_2$ 的大样本推断

2.2.1 参数与估计量

参数	$\mu_1 - \mu_2$
估计量	$\bar{Y}_1 - \bar{Y}_2$
估计标准误	$\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}$
抽样分布	当 $n_1, n_2 > 20$ 时近似 $N(0, 1)$

2.2.2 大样本检验统计量

检验 $H_0: \mu_1 - \mu_2 = \Delta_0$ (通常 $\Delta_0 = 0$):

$$Z_{\text{obs}} = \frac{(\bar{y}_1 - \bar{y}_2) - \Delta_0}{\sqrt{S_1^2/n_1 + S_2^2/n_2}}$$

2.2.3 大样本决策规则

备择假设	拒绝 H_0 当	P 值
$\mu_1 - \mu_2 > \Delta_0$	$Z_{\text{obs}} \geq z_\alpha$	$P(Z \geq Z_{\text{obs}})$
$\mu_1 - \mu_2 < \Delta_0$	$Z_{\text{obs}} \leq -z_\alpha$	$P(Z \leq Z_{\text{obs}})$
$\mu_1 - \mu_2 \neq \Delta_0$	$ Z_{\text{obs}} \geq z_{\alpha/2}$	$2P(Z \geq Z_{\text{obs}})$

2.2.4 大样本 $(1 - \alpha) \times 100\%$ 置信区间

$$(\bar{y}_1 - \bar{y}_2) \pm z_{\alpha/2} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}$$

Example 2.2: 维生素 C 与感冒

研究结果变量为每名学生在研究期间的感冒次数. 组 1 接受安慰剂, 组 2 接受抗坏血酸 (维生素 C):

$$\bar{y}_1 = 2.2, \quad s_1 = 0.12, \quad n_1 = 155, \quad \bar{y}_2 = 1.9, \quad s_2 = 0.10, \quad n_2 = 208.$$

进行双侧组间均值比较, 并构造 $\mu_1 - \mu_2$ 的 95% 置信区间.

Solution 检验 $H_0: \mu_1 - \mu_2 = 0$ vs. $H_a: \mu_1 - \mu_2 \neq 0, \alpha = 0.05$:

$$SE = \sqrt{\frac{0.12^2}{155} + \frac{0.10^2}{208}} = 0.0119 \implies Z_{\text{obs}} = \frac{(2.2 - 1.9) - 0}{0.0119} = 25.3.$$

因 $25.3 > z_{0.025} = 1.96$, 拒绝 H_0 . 维生素 C 显著降低感冒次数.

95% 置信区间:

$$0.3 \pm 1.96(0.0119) = 0.30 \pm 0.023 \implies (0.277, 0.323).$$

□

Remark 双侧组间比较

双侧比较两个独立组均值时, 通常检验

$$H_0: \mu_1 - \mu_2 = 0, \quad H_a: \mu_1 - \mu_2 \neq 0.$$

$\bar{y}_1 - \bar{y}_2$ 的符号给出观测方向, 但拒绝规则使用 $|Z_{\text{obs}}|$ 或 $|t_{\text{obs}}|$, 因为两个方向都构成反对均值相等的证据.

§2.3 $\mu_1 - \mu_2$ 的小样本检验 (等方差 *Equal Variances*)

当 $n_1, n_2 < 30$, 总体正态, 且假设 $\sigma_1^2 = \sigma_2^2 = \sigma^2$:

2.3.1 合并方差 (Pooled Variance)

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

2.3.2 合并 t 检验统计量

$$t_{\text{obs}} = \frac{(\bar{y}_1 - \bar{y}_2) - \Delta_0}{\sqrt{S_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \sim t(n_1 + n_2 - 2)$$

2.3.3 小样本 $(1 - \alpha) \times 100\%$ 置信区间

$$(\bar{y}_1 - \bar{y}_2) \pm t_{\alpha/2, \nu} \sqrt{S_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}, \quad \nu = n_1 + n_2 - 2.$$

Example 2.3: 头皮伤口闭合 – 缝合 vs. 钉合

	钉合	缝合
n	15	16
$\bar{y}$	96.92	96.31
s	7.51	8.06

$$H_0: \mu_1 - \mu_2 = 0, H_a: \mu_1 - \mu_2 \neq 0, \alpha = 0.05.$$

Solution 合并方差:

$$S_p^2 = \frac{14(7.51)^2 + 15(8.06)^2}{15 + 16 - 2} = \frac{14(56.40) + 15(64.96)}{29} = 60.83.$$

检验统计量:

$$t_{\text{obs}} = \frac{96.92 - 96.31}{\sqrt{60.83(1/15 + 1/16)}} = \frac{0.61}{2.80} = 0.22.$$

结论: $|0.22| < t_{0.025, 29} = 2.045$. 不能拒绝 H_0 .

95% 置信区间:

$$0.61 \pm 2.045(2.80) = 0.61 \pm 5.73 \implies (-5.12, 6.34).$$

区间包含零, 与无显著差异的结论一致.

□

§2.4 配对样本 (交叉设计 Crossover Design)

2.4.1 背景与记号

每种处理施加于同一个体 (最好随机顺序). 定义:

$$d_i = Y_{1i} - Y_{2i} \quad (\text{第 } i \text{ 个个体的差值}).$$

Definition 2.4: 差值的汇总统计量

$$\bar{d} = \frac{1}{n} \sum_{i=1}^n d_i, \quad s_d^2 = \frac{\sum_{i=1}^n (d_i - \bar{d})^2}{n-1}, \quad s_d = \sqrt{s_d^2}.$$

2.4.2 配对 t 检验统计量

检验 $H_0: \mu_d = \Delta_0$:

$$t_{\text{obs}} = \frac{\bar{d} - \Delta_0}{s_d / \sqrt{n}} \sim t(n-1).$$

常见备择假设为

$$H_a: \mu_d > \Delta_0, \quad H_a: \mu_d < \Delta_0, \quad H_a: \mu_d \neq \Delta_0.$$

相应 p 值分别为 t_{n-1} 分布的右尾、左尾与双尾概率.

2.4.3 μ_d 的置信区间

$$\bar{d} \pm t_{\alpha/2, n-1} \frac{s_d}{\sqrt{n}}.$$

Example 2.5: 数学成绩评估

学生第二学期修读数学并接受两次评估. 对学生 i , 令 d_i 为两次评估分数差. 汇总统计量为 $n = 13, \bar{d} = 1.77, s_d = 1.48$. 在 $\alpha = 0.05$ 下进行双侧检验并构造 μ_d 的 95% 置信区间.

Solution

$$H_0: \mu_d = 0, \quad H_a: \mu_d \neq 0.$$

$$t_{\text{obs}} = \frac{1.77}{1.48/\sqrt{13}} = \frac{1.77}{0.41} = 4.31.$$

$|4.31| > t_{0.025, 12} = 2.179$. 拒绝 H_0 : 两次评估的分数有显著差异.

95% 置信区间:

$$1.77 \pm 2.179(0.41) = 1.77 \pm 0.89 \implies (0.88, 2.66).$$

□

Remark

当同一个体的两次测量正相关时, 配对设计比独立样本设计功效更高, 因为个体间差异在 d_i 中被抵消.

3

总体比例的推断 (Inference for Population Proportions)

§3.1 回顾: 比例 (Proportion) 的统计量与参数

量	统计量 (样本)	参数 (总体)
均值	$\bar{X}$	μ
标准差	s	σ
比例	$\hat{p}$ (或 p_0)	p

§3.2 标准误

Proposition 3.1: 标准误公式

定量变量 (Quantitative Variable): $SE(\bar{Y}) = \frac{S}{\sqrt{n}}$

定性变量 (Qualitative Variable): $SE(\hat{p}) = \sqrt{\frac{p(1-p)}{n}}$

§3.3 p 的单样本置信区间

Definition 3.2: 样本比例 (Sample Proportion)

$$\hat{p} = \frac{X}{n} = \frac{\text{成功次数}}{\text{样本量}}.$$

由中心极限定理, n 大时 $\hat{p} \sim N\left(p, \sqrt{p(1-p)/n}\right)$ 近似.

p 的 $(1 - \alpha) \times 100\%$ 置信区间为:

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

Example 3.3: 过敏调查

一项针对 $n = 140$ 户家庭的调查显示, 35% 的家庭存在屋尘过敏 (house-dust allergy). 构造具有屋尘过敏家庭总体比例的 95% 置信区间.

Solution

$$SE = \sqrt{\frac{0.35(0.65)}{140}} = 0.04.$$

95% 置信区间:

$$0.35 \pm 1.96(0.04) = (0.27, 0.43), \quad \text{即 } 27\% \leq p \leq 43\%.$$

□

§3.4 p 的单样本假设检验

检验 $H_0: p = p_0$, 检验统计量始终为 Z 检验:

$$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)/n}}$$

Remark

分母使用 p_0 (原假设值) 而非 $\hat{p}$, 因为评估的是 H_0 下的抽样分布. 临界值为 1.96 ($\alpha = 0.05$) 与 2.576 ($\alpha = 0.01$).

Example 3.4: 糖尿病足比例

调查: $n = 400$ 名糖尿病患者中 $X = 100$ 人患糖尿病足; 在 $\alpha = 0.05$ 下检验 $p = 0.20$.

$\hat{p} = 100/400 = 0.25$. $H_0: p = 0.20$, $H_a: p \neq 0.20$ (双侧).

Solution

$$Z = \frac{0.25 - 0.20}{\sqrt{0.20(0.80)/400}} = \frac{0.05}{0.02} = 2.5.$$

$|2.5| > 1.96$. 拒绝 H_0 . 有充分证据认为该比例不等于 20%.

□

§3.5 $p_1 - p_2$ 的双样本置信区间

由两个独立样本 $\hat{p}_1 = x_1/n_1$, $\hat{p}_2 = x_2/n_2$, $p_1 - p_2$ 的 $(1 - \alpha) \times 100\%$ 置信区间为:

$$(\hat{p}_1 - \hat{p}_2) \pm z_{\alpha/2} \sqrt{\frac{\hat{p}_1(1 - \hat{p}_1)}{n_1} + \frac{\hat{p}_2(1 - \hat{p}_2)}{n_2}}$$

Example 3.5: 教学方法 A 与 B: 在线学习与传统课堂

某大学想比较两种教学方法 A 与 B 的有效性. 方法 A 为在线学习 (online learning), 方法 B 为传统课堂学习 (traditional classroom learning). 根据样本数据, 构造两种教学方法有效性差异的 95% 置信区间.

方法 A: $n_1 = 100$, $x_1 = 85$, $\hat{p}_1 = 0.85$.

方法 B: $n_2 = 125$, $x_2 = 75$, $\hat{p}_2 = 0.60$.

Solution

$$SE = \sqrt{\frac{0.85(0.15)}{100} + \frac{0.60(0.40)}{125}} = \sqrt{0.001275 + 0.001920} = \sqrt{0.003195} \approx 0.0565.$$

95% 置信区间:

$$(0.85 - 0.60) \pm 1.96(0.0565) = 0.25 \pm 0.111 \implies (0.139, 0.361).$$

区间不含零, 说明方法 A 的通过率显著高于方法 B. □

§3.6 $p_1 - p_2$ 的双样本假设检验

3.6.1 假设

类型	假设
双侧	$H_0 : p_1 = p_2; H_a : p_1 \neq p_2$
右尾	$H_0 : p_1 \leq p_2; H_a : p_1 > p_2$
左尾	$H_0 : p_1 \geq p_2; H_a : p_1 < p_2$

3.6.2 合并比例与检验统计量

$H_0 : p_1 = p_2$ 下, 合并两样本估计共同比例:

$$\hat{p} = \frac{x_1 + x_2}{n_1 + n_2}.$$

检验统计量为:

$$Z_{\text{obs}} = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$$

决策规则与标准 Z 检验相同; p 值 $< \alpha$ 时拒绝 H_0 .

Example 3.6: 吸烟者与非吸烟者 – 烟草税意见

对 800 名中国成年人就提高烟草税以支持医疗保健进行的电话调查:

	非吸烟者	吸烟者
n	605	195
x (赞成)	351	41
$\hat{p}$	0.58	0.21

$H_0: p_1 = p_2, H_a: p_1 \neq p_2, \alpha = 0.05$.

Solution 合并比例:

$$\hat{p} = \frac{351 + 41}{605 + 195} = \frac{392}{800} = 0.49.$$

检验统计量:

$$Z_{\text{obs}} = \frac{0.58 - 0.21}{\sqrt{0.49(0.51)(1/605 + 1/195)}} = \frac{0.37}{\sqrt{0.49(0.51)(0.00677)}} = \frac{0.37}{0.0418} \approx 8.85.$$

因 $8.85 \gg 1.96$, 拒绝 H_0 . 非吸烟者与吸烟者在烟草税意见上存在显著差异. $\square$

4

一元与多元线性回归 (Simple and Multiple Linear Regression)

§4.1 回归分析 (Regression Analysis) 简介

Definition 4.1: 回归分析

一类统计方法, 用于:

- 解释 **自变量 (Independent Variable)** 的变化对 **因变量 (Dependent Variable)** 的影响;
- 由至少一个自变量的取值预测因变量的取值.

因变量: 需要研究的变量.

自变量: 用以研究因变量的变量.

Definition 4.2: 一元线性回归模型 (Simple Linear Regression Model)

仅含一个自变量 X . X 与 Y 之间的关系由线性函数描述, 并假定 Y 的变化由 X 的变化引起:

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

其中 β_0 为截距 (Intercept), β_1 为斜率 (Slope), ε 为误差项 (Error Term).

Definition 4.3: 总体线性回归 (Population Linear Regression)

总体回归模型为

$$Y = \beta_0 + \beta_1 X + \varepsilon.$$

其中 $\beta_0 + \beta_1 X$ 是线性部分, ε 是给定 X 处的随机误差. 条件均值

为

$$E(Y | X = x) = \beta_0 + \beta_1 x.$$

Definition 4.4: 估计回归模型 (Estimated Regression Model)

样本回归线用于估计总体回归线:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i.$$

$\hat{Y}_i$ 是 X_i 处的预测值, 残差为

$$e_i = Y_i - \hat{Y}_i.$$

§4.2 数学关系与统计关系

数学关系中所有点精确落在一条直线上, 如 $y = a + bx$. 统计关系允许直线周围存在随机误差:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

因此散点图很重要: 它帮助判断直线模型是否合理, 以及残差散布是否大致恒定.

§4.3 线性回归的假设

对误差项 ε 作如下假设:

- I. 误差之间在统计上相互独立.
- II. 给定 X 时, 误差服从正态分布.
- III. 误差的概率分布为正态.
- IV. 误差的方差为常数 (同方差性 Homoscedasticity).
- V. X 与 Y 之间的真实关系为线性.

§4.4 最小二乘估计 (Least Squares Estimation, OLS)

Definition 4.5: 最小二乘准则 (Least Squares Criterion)

估计 $\hat{\beta}_0$ 与 $\hat{\beta}_1$ 通过最小化残差 (Residual) 平方和得到:

$$\min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2.$$

Proposition 4.6: 最小二乘估计公式

斜率 $\hat{\beta}_1$ 与截距 $\hat{\beta}_0$ 的公式为

$$\hat{\beta}_1 = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2} = \frac{\sum x_i y_i - \frac{(\sum x_i)(\sum y_i)}{n}}{\sum x_i^2 - \frac{(\sum x_i)^2}{n}},$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

Example 4.7: 收入与教育年限

教育经济学家希望研究个人收入与教育年限的关系. 随机抽取 10 人, 记录收入 (单位: 千美元) 与受教育年限:

收入 y	25	33	22	41	18	28	32	24	53	26
教育 x	11	12	11	15	8	10	11	12	17	11

求最小二乘回归线并解释系数.

Solution 收入是因变量, 教育年限是自变量. 已知

$$\sum x_i = 118, \quad \sum y_i = 302, \quad \sum x_i^2 = 1450, \quad \sum y_i^2 = 10072, \quad \sum x_i y_i = 3779.$$

$$S_{xy} = 3779 - \frac{118(302)}{10} = 215.4, \quad S_{xx} = 1450 - \frac{118^2}{10} = 57.6.$$

$$\hat{\beta}_1 = \frac{215.4}{57.6} = 3.74, \quad \hat{\beta}_0 = \frac{302}{10} - 3.74 \frac{118}{10} = -13.93.$$

故

$$\hat{y} = -13.93 + 3.74x.$$

斜率表示教育年限每增加 1 年, 平均收入增加约 3.74 千美元. 截距表示 0 年教育时的预测收入, 在此处主要是数学锚点, 不具有实际解释意义. $\square$

4.4.1 误差方差与估计标准误

一元线性回归中

$$SSE = \sum(Y_i - \hat{Y}_i)^2 = S_{yy} - \frac{S_{xy}^2}{S_{xx}}, \quad s_e^2 = \frac{SSE}{n-2}.$$

对收入--教育例,

$$S_{yy} = 10072 - \frac{302^2}{10} = 951.6,$$

$$SSE = 951.6 - \frac{(215.4)^2}{57.6} = 146.09, \quad s_e^2 = \frac{146.09}{8} = 18.26, \quad s_e = 4.27.$$

因此观测收入通常离拟合直线约 4.27 千美元.

Proposition 4.8: 最小二乘回归的性质

- 最小二乘回归直线的残差之和为零: $\sum_{i=1}^n (Y_i - \hat{Y}_i) = 0$.
- 残差平方和取得最小.
- 简单线性回归直线必过点 $(\bar{x}, \bar{y})$.
- 最小二乘系数是 β_0 与 β_1 的无偏估计.

§4.5 残差分析 (Residual Analysis)**Definition 4.9: 残差分析的目的**

- 检验线性假设.
- 检验在所有 X 水平上方差是否恒定 (同方差性).
- 评估误差的正态分布假设.

4.5.1 残差的图形分析

- 绘制残差对 X 的散点图, 检查线性与方差恒定性.
- 绘制残差直方图, 检查正态性.

§4.6 斜率检验

检验 X 与 Y 是否线性相关, 可检验

$$H_0 : \beta_1 = 0.$$

双侧备择为 $H_a : \beta_1 \neq 0$; 若关心正相关, 则 $H_a : \beta_1 > 0$; 若关心负相关, 则 $H_a : \beta_1 < 0$. 检验统计量为

$$t_{\text{obs}} = \frac{\hat{\beta}_1}{s_{\hat{\beta}_1}}, \quad s_{\hat{\beta}_1} = \frac{s_\varepsilon}{\sqrt{S_{xx}}},$$

自由度为 $n - 2$.

§4.7 回归中的预测区间与置信区间

对新的自变量取值 x_g , 点预测为

$$\hat{y}_g = \hat{\beta}_0 + \hat{\beta}_1 x_g.$$

均值响应 $E(Y | X = x_g)$ 的置信区间为

$$\hat{y}_g \pm t_{\alpha/2, n-2} s_\varepsilon \sqrt{\frac{1}{n} + \frac{(x_g - \bar{x})^2}{S_{xx}}}.$$

单个未来观测的预测区间更宽:

$$\hat{y}_g \pm t_{\alpha/2, n-2} s_{\varepsilon} \sqrt{1 + \frac{1}{n} + \frac{(x_g - \bar{x})^2}{S_{xx}}}.$$

Example 4.10: 汽车价格与里程表读数

汽车经销商使用 red book 根据车辆特征确定售价. 其中一个特征是里程表读数. 回归输出为

$$\widehat{\text{Price}} = 6533.38 - 0.031158 \text{ Odometer}.$$

解释斜率, 并预测里程表读数为 40,000 英里时的售价.

Solution 斜率 -0.031158 表示里程每增加 1 英里, 预测售价平均下降约 \$0.031158, 即 3.1158 美分. 当里程为 40,000:

$$\widehat{\text{Price}} = 6533.38 - 0.031158(40000) = 5287.06.$$

预测售价约为 \$5,287. □

§4.8 散点图与相关性

Definition 4.11: 散点图 (Scatter Plot)

用于展示两个变量之间的关系.

Definition 4.12: 相关分析 (Correlation Analysis)

用于度量两个变量之间 (线性) 关联的强弱, 仅关注强度, 不蕴含因果关系.

Definition 4.13: 相关系数 (Correlation Coefficient)

总体相关系数 (Population Correlation Coefficient) ρ 度量变量间关联的强弱; 样本相关系数 (Sample Correlation Coefficient) r 为 ρ 的估计.

Proposition 4.14: ρ 与 r 的特征

- 无量纲.
- 取值在 -1 到 1 之间.
- 越接近 -1 , 负线性关系越强.

- 越接近 +1, 正线性关系越强.
- 越接近 0, 线性关系越弱.

Proposition 4.15: 相关系数的计算

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{[\sum (x_i - \bar{x})^2] [\sum (y_i - \bar{y})^2]}} = \frac{n \sum x_i y_i - (\sum x_i)(\sum y_i)}{\sqrt{[n \sum x_i^2 - (\sum x_i)^2] [n \sum y_i^2 - (\sum y_i)^2]}}.$$

等价地,

$$r = \hat{\rho} = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{S_X} \right) \left(\frac{Y_i - \bar{Y}}{S_Y} \right) = \frac{S_{XY}}{S_X S_Y}.$$

Example 4.16: 树高与树干周长

树木样本的高度与树干周长如下:

树	1	2	3	4	5	6	7	8
高度 y	10.0	13.0	15.0	18.0	20.0	22.0	25.0	28.0
树干周长 x	8.0	9.5	12.0	15.0	16.5	18.0	21.5	24.0

求拟合线与相关系数, 并查看散点图.

Solution $\bar{x} = 15.5625, \bar{y} = 18.875$, 且

$$S_{xx} = 214.21875, \quad S_{xy} = 234.4375, \quad S_{yy} = 266.875.$$

$$\hat{\beta}_1 = \frac{234.4375}{214.21875} = 1.0944, \quad \hat{\beta}_0 = 18.875 - 1.0944(15.5625) = 1.8449.$$

拟合线为

$$\hat{y} = 1.8449 + 1.0944x.$$

相关系数为

$$r = \frac{234.4375}{\sqrt{214.21875(266.875)}} = 0.9805,$$

说明存在很强的正线性关联.

□




Figure 4.1: 由 R 脚本
scripts/week5_tree_scatter.R
生成的树高与树干周长散点图.

§4.9 决定系数 (Coefficient of Determination) R^2

Definition 4.17: 决定系数

决定系数 R^2 是因变量总变异中由自变量解释的比例:

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST},$$

其中 SSR 为回归平方和 (Regression Sum of Squares), SST 为总平方和 (Total Sum of Squares), SSE 为残差平方和 (Residual Sum of Squares). 显然 $0 \leq R^2 \leq 1$.

Proposition 4.18: 与相关系数的关系

在单一自变量情形下, 决定系数为简单相关系数的平方:

$$R^2 = r^2.$$

§4.10 多元线性回归模型

Definition 4.19: 多元线性回归模型 (Multiple Linear Regression Model)

含多个自变量 $X_1, X_2, \dots, X_k$. X_i 与 Y 之间由线性函数描述, 假定 Y 的变化由 X_i 的变化引起:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k + \varepsilon.$$

§4.11 最小二乘估计的矩阵形式

对含 k 个自变量的模型, 记

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

其中

$$\mathbf{Y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}_{n \times 1}, \quad \mathbf{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1k} \\ 1 & x_{21} & x_{22} & \cdots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nk} \end{bmatrix}_{n \times (k+1)}, \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix}_{(k+1) \times 1}, \quad \boldsymbol{\varepsilon} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}_{n \times 1}.$$

Proposition 4.20: 最小二乘估计 (矩阵形式)

参数向量 $\boldsymbol{\beta}$ 的最小二乘估计为

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

拟合值为

$$\hat{\mathbf{Y}} = \mathbf{X} \hat{\boldsymbol{\beta}}.$$

Example 4.21: 房价、房龄与面积

随机抽取的 5 套住房的价格 (y , 单位 \$1000 澳元)、房龄 (x_1 , 单位 10 年) 与面积 (x_2 , 单位 1000 m²) 如下表, 拟合多元线性回归模型.

y	100	80	104	94	130
x_1	1	5	5	10	20
x_2	1	1	2	2	3

Solution 用矩阵方法拟合 $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$. 构造设计矩阵 (Design Matrix) 与响应向量

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 5 & 1 \\ 1 & 5 & 2 \\ 1 & 10 & 2 \\ 1 & 20 & 3 \end{pmatrix}, \quad \mathbf{Y} = \begin{pmatrix} 100 \\ 80 \\ 104 \\ 94 \\ 130 \end{pmatrix}.$$

则

$$\mathbf{X}^\top \mathbf{X} = \begin{pmatrix} 5 & 41 & 9 \\ 41 & 551 & 96 \\ 9 & 96 & 19 \end{pmatrix}, \quad \mathbf{X}^\top \mathbf{Y} = \begin{pmatrix} 508 \\ 4560 \\ 966 \end{pmatrix}.$$

求解 $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$ 得

$$\hat{\beta}_0 = 66.1252, \quad \hat{\beta}_1 = -0.3794, \quad \hat{\beta}_2 = 21.4365.$$

估计的回归模型为

$$\hat{y} = 66.1252 - 0.3794 x_1 + 21.4365 x_2.$$

□

§4.12 回归的方差分析表 (Analysis of Variance, ANOVA)

Definition 4.22: 方差分析汇总表 (ANOVA Summary Table)

用于检验回归模型整体显著性. 以房价例为例, 在 5% 显著性水平下检验 $H_0 : \beta_1 = \beta_2 = 0$:

来源	自由度	SS	MSS	F	P 值
x_1	1	724.17	724.17	3.7845	0.1911
x_2	1	232.33	232.33	1.2141	0.3854
误差	2	382.70	191.35		
合计	4				

结论: 两个 P 值均大于 0.05, 故不能拒绝原假设 $H_0 : \beta_1 = \beta_2 = 0$.

5

多项式回归 (Polynomial Regression) 与非线性效应 (Non-Linear Effects)

§5.1 多项式回归简介

Definition 5.1: 多项式回归模型 (Polynomial Regression Model)

一种回归分析形式, 把自变量 X 与因变量 Y 的关系建模为 n 次多项式. 模型对参数仍是线性的:

$$Y = A + BX + CX^2 + DX^3 + \cdots + QX^{N-1}.$$

最高次数 $(N - 1)$ 称为多项式的 **阶数 (Order)**.

Definition 5.2: 多项式回归的阶数与形状

- **线性** ($Y = A + BX$): 零个弯折.
- **二次** ($Y = A + BX + CX^2$): 一个弯折.
- **三次** ($Y = A + BX + CX^2 + DX^3$): 两个弯折.

弯折数比多项式的最高阶数少一. 最高阶系数的符号决定曲线的弯折方向.

Definition 5.3: 多项式系数的解释

- b_0 的解释不变: 所有预测变量取 0 时的预测值, 其数值会随模型复杂度变化.
- b_1 是 $X = 0$ 处 X 对 Y 的线性 (简单) 效应, 是一种条件效应.
- 高阶项反映线性效应如何随 X 的取值变化.

§5.2 多项式模型的拟合与比较

Example 5.4: 选修课兴趣预测

所选选修课数量 (X) 如何预测对后续选修课的兴趣 (Y)? 先拟合线性模型:

$$\text{Interest} = 8.7 + 1.4 \times \text{Electives}.$$

线性假设被违背, 拟合较差. 改拟合二次模型:

$$\text{Interest} = 1.0 + 3.3 \times \text{Electives} - 0.1 \times \text{Electives}^2.$$

Solution 线性模型的 R 代码:

```
scatterplot(dE$Electives, dE$Interest, cex=1.5, lwd=2,
            xlab="Electives", ylab="Interest", col="black")
mLinear <- lm(Interest ~ Electives, data=dE)
summary(mLinear)
modelAssumptions(mLinear, Type="linear", one.page=FALSE)
```

诊断图显示线性假设存在问题, 关系呈弯曲趋势.

二次模型的 R 代码:

```
dE$Electives2 <- dE$Electives * dE$Electives
mQuad <- lm(Interest ~ Electives + Electives2, data=dE)

# 等价写法:
mQuad <- lm(Interest ~ Electives + I(Electives^2), data=dE)
summary(mQuad)
anova(mLinear, mQuad)
```

模型比较:

- **线性模型:** $R^2 = 0.5608$, $SSE = 980.2$, 误差自由度 = 98.
- **二次模型:** $R^2 = 0.6726$, $SSE = 730.8$, 误差自由度 = 97.

二次模型的 R^2 更高, SSE 更低. 二次项系数 (-0.1266) 显著 ($p < 0.001$), 表明需要保留高阶项.

$$F = \frac{(980.2 - 730.8) / (98 - 97)}{730.8 / 97} = 33.10.$$

较大的 F 统计量说明加入二次项显著改善模型. □

Remark

判断是否需要多项式 (如二次 vs. 线性), 比较增广模型 (含高阶项) 与精简模型 (不含). 等价于检验高阶项系数是否为零, 可使用 F 检验或对该系数的 t 检验.

§5.3 条件效应与简单斜率

Definition 5.5: 简单效应 (Simple Effect) (斜率) 公式

简单斜率 (Simple Slope), 即在特定 X 处 Y 关于 X 的瞬时变化率, 由偏导给出. 对二次模型 $Y = \beta_0 + \beta_1 X + \beta_2 X^2$:

$$\frac{\partial Y}{\partial X} = \beta_1 + 2\beta_2 X.$$

该式描述 X 对 Y 的效应如何随 X 取值变化.

Example 5.6: 选修课模型的简单斜率

二次模型 $\text{Interest} = 1.0 + 3.27 \times \text{Electives} - 0.13 \times \text{Electives}^2$.

Solution 简单斜率公式:

$$\frac{\Delta \text{Interest}}{\Delta \text{Electives}} = 3.27 - 0.26 \times \text{Electives}.$$

不同点处取值:

- $\text{Electives} = 0$: 斜率 $= 3.27 - 0.26(0) = 3.3$;
- $\text{Electives} = \bar{X} = 8.17$: 斜率 $= 3.27 - 0.26(8.17) = 1.2$.

对已选课较少者, 多修一门课的效应最强; 随着选课数增加, 效应减弱. $\square$

5.3.1 交互作用中的简单斜率

对交互模型

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 XZ + \varepsilon,$$

X 的简单效应为

$$\frac{\partial Y}{\partial X} = \beta_1 + \beta_3 Z.$$

因此 X 的斜率依赖于 Z 的取值. 若 Z 已中心化, β_1 表示 Z 处于均值时 X 的效应. 若模型同时含二次项和交互项,

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 Z + \beta_4 XZ + \varepsilon,$$

则

$$\frac{\partial Y}{\partial X} = \beta_1 + 2\beta_2 X + \beta_4 Z.$$

§5.4 含多个预测变量的非线性效应

Definition 5.7: 含多个预测变量与非线性的模型

在含其他变量的模型中也可考察单个变量的非线性效应. 例如, 在越野滑雪选手中, 考察年龄与每周训练里程对 5K 比赛成绩的影响, 其中里程预计具有二次效应 (边际递减).

Example 5.8: 5K 成绩、年龄与训练里程

精简模型仅含中心化年龄 (cAge). 增广模型再加入中心化里程 (cMiles) 及其平方 (cMiles²):

$$\begin{aligned}\text{精简: } \text{Time} &= 23.55 + 0.217 \text{ cAge}, \\ R^2 &= 0.2245, \quad \text{SSE} = 1714.7,\end{aligned}$$

$$\begin{aligned}\text{增广: } \text{Time} &= 22.04 + 0.168 \text{ cAge} - 0.256 \text{ cMiles} \\ &\quad + 0.00803 \text{ cMiles}^2, \\ R^2 &= 0.7271, \quad \text{SSE} = 603.4.\end{aligned}$$

Solution 精简模型与增广模型的 R 代码:

```
mC <- lm(Time ~ cAge, data=dMiles)
summary(mC)
```

```
mA <- lm(Time ~ cAge + cMiles + I(cMiles^2), data=dMiles)
summary(mA)
anova(mC, mA)
```

里程的整体效应: 模型比较显示里程对 5K 时间存在显著整体效应, $F(2, 76) = 69.98$, $p < .001$; 控制年龄后里程解释了未解释方差的 64.8% ($\Delta R^2 = 0.648$).

各效应报告:

- 年龄效应 (控制里程): $b = 0.168$, $\Delta R^2 = 0.132$, $t(76) = 6.05$, $p < .001$.
- 里程线性效应 (在平均里程处): $b = -0.256$, $\Delta R^2 = 0.437$, $t(76) = -11.04$, $p < .001$.
- 里程二次效应: $b = 0.00803$, $\Delta R^2 = 0.062$, $t(76) = 4.165$, $p < .001$.

里程的简单斜率. 中心化模型给出平均里程处的线性效应:

$$\frac{\partial \text{Time}}{\partial \text{cMiles}} = -0.256 + 2(0.00803)\text{cMiles}.$$

课件中的非中心化展示为

$$\widehat{\text{Time}} = 36.9 + 0.17 \text{ cAge} - 0.74 \text{ Miles} + 0.01 \text{ Miles}^2,$$

所以

$$\frac{\partial \text{Time}}{\partial \text{Miles}} = -0.74 + 0.02 \text{ Miles}.$$

负的一次项表示增加每周里程最初会降低 5K 用时; 正的二次项表示该改善随高里程而递减. $\square$

Example 5.9: 里程简单斜率检验

使用相同 5K 数据, 分别检验平均、低、高每周里程跑者的里程斜率.

Solution 课件通过重新中心化来改变线性系数的评估点:

```
dMiles$hMiles <- dMiles$cMiles - sd(dMiles$cMiles)
mHigh <- lm(Time ~ cAge + hMiles + I(hMiles^2), data=dMiles)
summary(mHigh)

dMiles$lMiles <- dMiles$cMiles + sd(dMiles$cMiles)
mLow <- lm(Time ~ cAge + lMiles + I(lMiles^2), data=dMiles)
summary(mLow)
```

报告结论为:

- 平均每周里程处, 每增加 1 英里与 5K 用时减少 0.26 分钟相关 ($p < .001$).
- 低每周里程处, 每增加 1 英里与用时减少 0.48 分钟相关 ($p < .001$).
- 高每周里程处, 每增加 1 英里与非显著的 0.03 分钟减少相关 ($p = 0.556$).

因此额外训练里程的收益在低里程跑者中最强, 在高里程处逐渐消失. $\square$

Remark

多项式回归中 X 与 X^2 等回归量通常高度相关, 除非对 X 进行中心化 (Centring). 中心化后线性系数 b_1 的含义变为 X 取均值处 (即中心化后 $X = 0$) 的简单效应. 若不中心化, b_1 表示 $X = 0$ 处的简单效应, 这通常是不现实的极端取值.

§5.5 多项式回归结果撰写示例

Example 5.10: 结果段落示例

“我们以 Interest 为因变量, 用线性与二次效应建模选修课数量 (Number of Electives). 选修课数量的总体效应显著, $F(2, 97) = 99.62$, $p < .0001$, 解释了 Interest 总方差的 67.3%. 线性效应显著, $B = 1.2$, $\eta_p^2 = .651$, $t(97) = 13.45$, $p < .0001$, 表明对已选修过平均水平选修课的学生, 多修一门会带来 1.2 分的兴趣提升. 然而, 二次效应也显著, $B = -0.1$, $t(97) = 5.75$, $p < .0001$, 说明每多选一门选修课, 选修课效应的大小递减约 0.02.”

6

一元线性回归的参数估计 (Parameter Estimation)

§6.1 模型与记号

考虑一元线性回归模型:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, 2, \dots, n,$$

其中 $Y_1, Y_2, \dots, Y_n$ 相互独立, 且

$$E(Y_i) = \beta_0 + \beta_1 X_i, \quad \text{Var}(Y_i) = \sigma^2.$$

最小二乘估计 (OLS Estimate) 为:

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X},$$

其中

$$S_{xx} = \sum_{i=1}^n (X_i - \bar{X})^2, \quad S_{xy} = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}), \quad S_{yy} = \sum_{i=1}^n (Y_i - \bar{Y})^2.$$

§6.2 估计量的无偏性与方差

Theorem 6.1: 估计量的无偏性 (Unbiasedness) 与方差 (Variance)

设 $Y_1, \dots, Y_n$ 相互独立, 且 $E(Y_i) = \beta_0 + \beta_1 X_i$, $\text{Var}(Y_i) = \sigma^2$. 则:

(i) 无偏性:

$$E(\hat{\beta}_0) = \beta_0, \quad E(\hat{\beta}_1) = \beta_1.$$

(ii) $\hat{\beta}_0$ 的方差:

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{S_{xx}} \right).$$

(iii) $\hat{\beta}_1$ 的方差:

$$\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}.$$

(iv) 协方差 (Covariance):

$$\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\frac{\sigma^2 \bar{X}}{S_{xx}}.$$

Proof 记

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \sum_{i=1}^n a_i Y_i, \quad a_i = \frac{X_i - \bar{X}}{S_{xx}}.$$

这些权重满足

$$\sum a_i = 0, \quad \sum a_i X_i = \frac{\sum (X_i - \bar{X}) X_i}{S_{xx}} = 1.$$

因此

$$E(\hat{\beta}_1) = \sum a_i (\beta_0 + \beta_1 X_i) = \beta_1.$$

由 Y_i 独立且方差均为 σ^2 ,

$$\text{Var}(\hat{\beta}_1) = \sum a_i^2 \sigma^2 = \frac{\sigma^2}{S_{xx}}.$$

又因为 $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$,

$$E(\bar{Y}) = \beta_0 + \beta_1 \bar{X},$$

故

$$E(\hat{\beta}_0) = E(\bar{Y}) - \bar{X} E(\hat{\beta}_1) = \beta_0.$$

并且

$$\text{Cov}(\bar{Y}, \hat{\beta}_1) = \frac{\sigma^2}{n} \sum a_i = 0.$$

所以

$$\text{Var}(\hat{\beta}_0) = \text{Var}(\bar{Y}) + \bar{X}^2 \text{Var}(\hat{\beta}_1) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{S_{xx}} \right),$$

$$\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\bar{X} \text{Var}(\hat{\beta}_1) = -\frac{\sigma^2 \bar{X}}{S_{xx}}.$$

□

Remark

负协方差意味着: 当 $\hat{\beta}_1$ 高估斜率时, $\hat{\beta}_0$ 倾向于低估截距. 这从几何上看是合理的, 因为拟合直线必经过 $(\bar{X}, \bar{Y})$.

§6.3 拟合值 (Fitted Value) 的性质

Theorem 6.2: 拟合值的性质

在相同假设下, 对任意给定的 X_0 :

(i) 预测的无偏性:

$$E(\hat{\beta}_0 + \hat{\beta}_1 X_0) = \beta_0 + \beta_1 X_0.$$

(ii) 拟合值的方差:

$$\text{Var}(\hat{\beta}_0 + \hat{\beta}_1 X_0) = \sigma^2 \left(\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{S_{xx}} \right).$$

Proof 对固定 X_0 , 记 $\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 X_0$. 由无偏性,

$$E(\hat{Y}_0) = \beta_0 + \beta_1 X_0.$$

其方差为

$$\begin{aligned} \text{Var}(\hat{Y}_0) &= \text{Var}(\hat{\beta}_0) + X_0^2 \text{Var}(\hat{\beta}_1) + 2X_0 \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) \\ &= \sigma^2 \left(\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{S_{xx}} \right). \end{aligned}$$

□

Remark

当 $X_0 = \bar{X}$ 时方差最小, 离数据中心越远方差越大. 这就是预测区间在观测 X 范围两端变宽的原因.

§6.4 残差的性质

定义残差 $\hat{e}_i = Y_i - \hat{Y}_i$, 其中 $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$.

Proposition 6.3: OLS 残差的性质

(i) 和为零:

$$\sum_{i=1}^n \hat{e}_i = 0.$$

(ii) 与自变量正交 (Orthogonal):

$$\sum_{i=1}^n \hat{e}_i X_i = 0.$$

(iii) 均值为零:

$$E(\hat{e}_i) = 0.$$

(iv) 残差的方差:

$$\text{Var}(\hat{e}_i) = \sigma^2 \left(1 - \frac{1}{n} - \frac{(X_i - \bar{X})^2}{S_{xx}} \right).$$

Proof

$$\sum \hat{e}_i = \sum (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = n\bar{Y} - n\hat{\beta}_0 - n\hat{\beta}_1 \bar{X} = 0.$$

同理,

$$\sum X_i \hat{e}_i = 0$$

是最小化残差平方和时关于斜率的正规方程. 因 $E(\hat{Y}_i) = E(Y_i)$,

$$E(\hat{e}_i) = E(Y_i - \hat{Y}_i) = 0.$$

一元线性回归中第 i 个观测的杠杆值为

$$h_{ii} = \frac{1}{n} + \frac{(X_i - \bar{X})^2}{S_{xx}}.$$

因此

$$\text{Var}(\hat{e}_i) = \sigma^2(1 - h_{ii}) = \sigma^2 \left(1 - \frac{1}{n} - \frac{(X_i - \bar{X})^2}{S_{xx}} \right).$$

□

Remark

性质 (i) 和 (ii) 直接由 OLS 的正规方程 (Normal Equations) 得到. 注意 $\text{Var}(\hat{e}_i) < \sigma^2$, 因为拟合 $\hat{\beta}_0$ 与 $\hat{\beta}_1$ 消耗了两个自由度.

§6.5 σ^2 的估计

为估计误差方差 σ^2 , 使用 **残差 (误差) 均方 (Mean Squared Error, MSE)**:

$$S_e^2 = \frac{1}{n-2} (S_{yy} - \hat{\beta}_1 S_{xy}).$$

分子即残差平方和:

$$SSE = \sum (Y_i - \hat{Y}_i)^2 = S_{yy} - \hat{\beta}_1 S_{xy} = S_{yy} - \frac{S_{xy}^2}{S_{xx}}.$$

因为估计了 β_0, β_1 两个参数, 自由度为 $n-2$. 在线性模型假设下,

$$\frac{SSE}{\sigma^2} \sim \chi_{n-2}^2,$$

故 $E(SSE) = (n-2)\sigma^2$, 从而 $E(S_e^2) = \sigma^2$.

Remark

S_e^2 是 σ^2 的无偏估计, 即 $E(S_e^2) = \sigma^2$. 分母 $n - 2$ 反映估计 $\hat{\beta}_0$ 与 $\hat{\beta}_1$ 时损失的两个自由度.

7

单因素方差分析 (One-Way ANOVA)

§7.1 研究动机

单因素 ANOVA 检验由单一分类因子 (Categorical Factor) 所定义的若干 **组的均值 (Group Means)** 是否相等. 典型问题:

- 不同市场细分在产品消费量上是否有差异?
- 商店的熟悉度 (高/中/低) 是否影响偏好?

§7.2 假设

$$H_0: \mu_1 = \mu_2 = \cdots = \mu_k,$$
$$H_1: \text{至少有一个总体均值不同.}$$

Remark

H_1 并不要求所有均值都不相同, 只需有一对不同即可.

§7.3 总变差的分解

设有 k 个组, 每组大小为 n (平衡设计 Balanced Design), 总观测数 $N = nk$:

Definition 7.1: 平方和 (Sum of Squares)

$$\text{SST (总平方和)} = \sum_{i=1}^k \sum_{j=1}^n (y_{ij} - \bar{y})^2,$$

$$\text{SSB (组间 Between-Groups / 回归平方和)} = n \sum_{i=1}^k (\bar{y}_{i\bullet} - \bar{y})^2,$$

$$\text{SSW (组内 Within-Groups / 误差平方和)} = \sum_{i=1}^k \sum_{j=1}^n (y_{ij} - \bar{y}_{i\bullet})^2.$$

基本恒等式:

$$SST = SSB + SSW,$$

其中

- $\bar{y}_{i\bullet} = \frac{1}{n} \sum_{j=1}^n y_{ij}$ 是第 i 组的均值.
- $\bar{y} = \frac{1}{N} \sum_{i=1}^k \sum_{j=1}^n y_{ij}$ 是总均值 (Grand Mean).

7.3.1 如何手工计算 ANOVA

对含 k 个处理、每组 n 个观测的平衡单因素设计, 记观测为 y_{ij} . 手工计算步骤为:

- 计算各组均值 $\bar{y}_{i\bullet} = \frac{1}{n} \sum_j y_{ij}$;
- 计算总均值 $\bar{y} = \frac{1}{nk} \sum_i \sum_j y_{ij}$;
- 比较每个观测与其组均值, 计算 SSW/SSE ;
- 比较各组均值与总均值, 计算 SSB/SSR ;
- 用 $SST = SSB + SSW$ 得总平方和, 再填写 ANOVA 表.

Definition 7.2: 组内平方和 SSW/SSE

$$SSW = SSE = \sum_{i=1}^k \sum_{j=1}^n (y_{ij} - \bar{y}_{i\bullet})^2.$$

它度量允许每组具有自身均值后仍未被解释的变异. 对每组,

$$\sum_{j=1}^n (y_{ij} - \bar{y}_{i\bullet})^2 = (n-1)s_i^2,$$

故平衡设计中

$$SSW = \sum_{i=1}^k (n-1)s_i^2.$$

Definition 7.3: 组间平方和 SSB/SSR

$$SSB = SSR = n \sum_{i=1}^k (\bar{y}_{i\bullet} - \bar{y})^2.$$

它度量各组均值相对于总均值的变异, 即处理或因于解释的总变异部分.

Definition 7.4: 总平方和 SST/TSS

$$SST = TSS = \sum_{i=1}^k \sum_{j=1}^n (y_{ij} - \bar{y})^2.$$

它是所有观测合并后样本方差的分子, 且满足

$$SST = SSB + SSW.$$

§7.4 F 分布 (F-distribution)

两个独立卡方变量 (各除以其自由度) 的比服从 F 分布:

$$\frac{\sigma_{\text{组间}}^2}{\sigma_{\text{组内}}^2} \sim F_{k,n}.$$

F 检验的假设为:

$$H_0: \sigma_{\text{组间}}^2 = \sigma_{\text{组内}}^2 \quad \text{vs.} \quad H_a: \sigma_{\text{组间}}^2 \neq \sigma_{\text{组内}}^2.$$

若样本方差相等, 则 $F \approx 1$.

§7.5 ANOVA 表 (ANOVA Table)

来源	自由度	SS	MS	F
组间 (处理 Treatment)	$k - 1$	SSB	$MSB = \frac{SSB}{k - 1}$	$\frac{MSB}{MSW}$
组内 (误差 Error)	$nk - k$	SSW	$s^2 = \frac{SSW}{nk - k}$	
总计	$nk - 1$	SST		

Table 7.1: 单因素 ANOVA 表.

在显著性水平 α 下, 将 F_{calc} 与临界值 $F_{k-1, nk-k}$ 比较. 各列计算为

$$MSB = \frac{SSB}{k-1}, \quad MSW = MSE = \frac{SSW}{nk-k}, \quad F_{\text{calc}} = \frac{MSB}{MSW}.$$

分子自由度 $k-1$ 表示可独立比较的组均值对比数; 分母自由度 $nk-k = k(n-1)$ 来自组内残差变异.

Remark 结果的解读

- 若 不拒绝 H_0 , 则因子 X 对 Y 无显著影响.
- 若 拒绝 H_0 , 则因子影响显著; 此时比较各类别均值可揭示影响的具体形式.

§7.6 决定系数

$$R^2 = \frac{SSB}{SST} = \frac{SSB}{SSB + SSE}.$$

R^2 表示因子 (处理) 所解释的 Y 总变差的比例.

§7.7 示例

Example 7.5

四种处理对身高 (英寸) 的影响, 每组 $n = 10$:

处理 1	处理 2	处理 3	处理 4
60	50	48	47
67	52	49	67
42	43	50	54
67	67	55	67
56	67	56	68
62	59	61	65
64	67	61	65
59	64	60	56
72	63	59	60
71	65	64	65
$\bar{y}_{1\bullet} = 62.0$	$\bar{y}_{2\bullet} = 59.7$	$\bar{y}_{3\bullet} = 56.3$	$\bar{y}_{4\bullet} = 61.4$

总均值: $\bar{y} = 59.85$.

Solution 第 1 步 – SSB:

$$\begin{aligned} SSB &= 10 \left[(62 - 59.85)^2 + (59.7 - 59.85)^2 + (56.3 - 59.85)^2 + (61.4 - 59.85)^2 \right] \\ &= 10 \times 19.65 = 196.5. \end{aligned}$$

第 2 步 – SSW (组内平方和):

$$\begin{aligned} SSW_1 &= (60 - 62)^2 + (67 - 62)^2 + (42 - 62)^2 + (67 - 62)^2 + (56 - 62)^2 \\ &\quad + (62 - 62)^2 + (64 - 62)^2 + (59 - 62)^2 + (72 - 62)^2 + (71 - 62)^2 = 624, \end{aligned}$$

$$SSW_2 = (50 - 59.7)^2 + (52 - 59.7)^2 + \cdots + (65 - 59.7)^2 = 678.1,$$

$$SSW_3 = (48 - 56.3)^2 + (49 - 56.3)^2 + \cdots + (64 - 56.3)^2 = 332.1,$$

$$SSW_4 = (47 - 61.4)^2 + (67 - 61.4)^2 + \cdots + (65 - 61.4)^2 = 426.4,$$

$$SSW = \sum_{i=1}^4 \sum_{j=1}^{10} (y_{ij} - \bar{y}_{i\bullet})^2 = 624 + 678.1 + 332.1 + 426.4 = 2060.6.$$

第 3 步 – ANOVA 表:

来源	自由度	SS	MS	F	p 值
组间	3	196.5	65.5	1.14	0.344
组内	36	2060.6	57.2		
总计	39	2257.1			

结论: $F = 1.14 < F_{3,36,0.05}$. 不能拒绝 H_0 . 处理组对身高的差异不显著.

$R^2 = 196.5/2257.1 \approx 9\%$: 仅有 9% 的身高变差由处理所解释. $\square$

Example 7.6: 校餐钙摄入量

英国三所中学学生校餐中钙摄入量 (每校 $n = 25$):

	学校 1 ^a	学校 2 ^b	学校 3 ^c
钙均值 (mg)	117.8	158.7	206.5
标准差	62.4	70.5	86.2

^a 贫困程度最高; 40% 学生享受补贴午餐. ^b 中等贫困; 不足 10% 享受补贴. ^c 贫困程度最低; 私立学校, 无补贴.

总均值: $\bar{y} = 161$.

Solution SSB:

$$SSB = 25 \left[(117.8 - 161)^2 + (158.7 - 161)^2 + (206.5 - 161)^2 \right] = 98,113.$$

SSW:

$$SSW = 24 \left[62.4^2 + 70.5^2 + 86.2^2 \right] = 391,066.$$

ANOVA 表:

来源	自由度	SS	MS	F	p 值
组间	2	98,113	49,056	9	< 0.05
组内	72	391,066	5,431		
总计	74	489,179			

$R^2 = 98,113/489,179 \approx 20\%$. 学校解释了钙摄入量 20% 的变差.

结论: $F = 9 > F_{2,72,0.05}$. 拒绝 H_0 . 不同学校之间的钙摄入量存在显著差异. $\square$

§7.8 单因素 ANOVA 的假定

误差项 ε_{ij} 须满足:

I. 服从均值为零的正态分布.

- II. 方差恒定 (同方差性).
- III. 与 X 的类别不相关.
- IV. 误差项之间相互不相关.

§7.9 超越单因素 ANOVA

ANOVA 可自然拓展到多个因子, 只要各因子相互独立. 总变差仍可干净地分解:

$$SST = SSB_1 + SSB_2 + SSW,$$

这是下一章双因素 ANOVA 的出发点.

8

双因素方差分析 (Two-Way ANOVA)

§8.1 研究动机

当存在两个因子 (例如处理因子与区组变量 Blocking Variable) 时, **双因素 ANOVA** 控制第二个因子, 从而减小 SSE 并提升检验功效.

§8.2 假设

设有 k 个处理组和 b 个区组 (Block).

关于处理:

$$H_0 : \tau_1 = \tau_2 = \cdots = \tau_k \quad H_a : \tau_i \text{ 不全相等.}$$

关于区组:

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_b \quad H_a : \beta_i \text{ 不全相等.}$$

§8.3 总变差的分解

$$SST = SSB_1 + SSB_2 + SSE,$$

其中

$$SSB_1 = b \sum_{j=1}^k \left(\bar{Y}_{\bullet j} - \bar{\bar{Y}} \right)^2 \quad (\text{处理间变差}),$$

$$SSB_2 = k \sum_{i=1}^b \left(\bar{Y}_{i\bullet} - \bar{\bar{Y}} \right)^2 \quad (\text{区组间变差}),$$

$$SST = \sum_{i=1}^b \sum_{j=1}^k (Y_{ij} - \bar{\bar{Y}})^2 \quad (\text{总变差}),$$

$$SSE = SST - SSB_1 - SSB_2 \quad (\text{残差 / 误差}).$$

来源	自由度	SS	MS	F
处理	$k - 1$	SSB_1	$MSB_1 = \frac{SSB_1}{k - 1}$	$\frac{MSB_1}{MSE}$
区组	$b - 1$	SSB_2	$MSB_2 = \frac{SSB_2}{b - 1}$	$\frac{MSB_2}{MSE}$
误差	$n - k - b + 1$	SSE	$MSE = \frac{SSE}{n - k - b + 1}$	
总计	$n - 1$	SST		

Table 8.1: 双因素 ANOVA 表
(共 $n = bk$ 个观测).

§8.4 双因素 ANOVA 表

§8.5 F 检验

处理差异的检验:

$$F = \frac{MSB_1}{MSE} = \frac{SSB_1 / (k - 1)}{SSE / (n - k - b + 1)} \sim F_{k-1, n-k-b+1}.$$

区组差异的检验:

$$F = \frac{MSB_2}{MSE} = \frac{SSB_2 / (b - 1)}{SSE / (n - k - b + 1)} \sim F_{b-1, n-k-b+1}.$$

在显著性水平 α 下, 若 $F_{\text{calc}} > F_{\text{critical}}$ 则拒绝相应 H_0 .

§8.6 均方误差作为合并方差

MSE 类似于配对样本推断中的合并方差 s_p^2 :

$$MSE = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2 + \cdots + (n_k - 1)s_k^2}{n - k}.$$

Theorem 8.1

MSE 是 σ^2 的无偏估计, 即 $E(MSE) = \sigma^2$.

§8.7 示例

Example 8.2

$k = 3$ 个商科专业 (会计、市场营销、金融) 跨 $b = 6$ 个 GPA 区组的薪资数据, 共 $n = 18$.

	会计	市场营销	金融	区组均值
区组 1	41	45	51	45.67
区组 2	36	38	45	39.67
区组 3	27	33	31	30.83
区组 4	32	29	35	32.00
区组 5	26	31	32	29.67
区组 6	23	25	27	25.00
处理均值	30.83	33.50	36.83	

总均值: $\bar{Y} = 33.72$.

Solution **SSB₁ (处理):**

$$SSB_1 = 6 \left[(30.83 - 33.72)^2 + (33.5 - 33.72)^2 + (36.83 - 33.72)^2 \right] = 108.4.$$

SSB₂ (区组):

$$SSB_2 = 3 \left[(45.67 - 33.72)^2 + (39.67 - 33.72)^2 + \cdots + (25 - 33.72)^2 \right] = 854.9.$$

SST:

$$SST = \sum_{i,j} (Y_{ij} - \bar{Y})^2 = 1015.61.$$

SSE:

$$SSE = 1015.61 - 108.4 - 854.9 = 52.2, \quad \text{自由度} = 18 - 3 - 6 + 1 = 10.$$

处理的 F 检验:

$$F = \frac{108.4/2}{52.2/10} = \frac{54.2}{5.2} = 10.4 > F_{0.05, 2, 10} = 4.10.$$

拒绝 H_0 : 不同专业之间的薪资差异显著.

区组的 F 检验:

$$F = \frac{854.9/5}{52.2/10} = \frac{170.98}{5.2} = 32.76 > F_{0.05, 5, 10} = 3.33.$$

拒绝 H_0 : 不同 GPA 区组之间的薪资差异显著.

□

9

最大似然估计 (Maximum Likelihood Estimation)

§9.1 似然与最大似然

Definition 9.1: 似然 (Likelihood)

设实验或样本产生观测事件或数据向量 E , 概率模型依赖参数 θ . 对离散数据, 似然函数为

$$\mathcal{L}(E; \theta) = P(E; \theta);$$

对连续数据, 似然为联合密度在观测数据处的取值. 分号表示 θ 是模型规则的一部分, 不是被条件化的事件.

Definition 9.2: 最大似然估计量 (MLE)

最大似然估计量是使似然最大的参数值:

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \mathcal{L}(E; \theta).$$

因为 $\log(x)$ 单调递增, 最大化 $\mathcal{L}$ 等价于最大化对数似然

$$\ell(\theta) = \log \mathcal{L}(E; \theta).$$

§9.2 抛硬币例子

Example 9.3: 抛硬币

独立抛硬币 10 次, 观测序列为

$H T T T H H T H H H.$

估计硬币正面朝上的概率 θ .

Solution 序列中有 6 次正面、4 次反面, 故

$$\mathcal{L}(\theta) = \theta^6(1-\theta)^4, \quad 0 \leq \theta \leq 1.$$

对数似然为

$$\ell(\theta) = 6 \log \theta + 4 \log(1-\theta).$$

$$\ell'(\theta) = \frac{6}{\theta} - \frac{4}{1-\theta}.$$

令 $\ell'(\theta) = 0$:

$$\frac{6}{\hat{\theta}} = \frac{4}{1-\hat{\theta}} \implies 6(1-\hat{\theta}) = 4\hat{\theta} \implies \hat{\theta} = \frac{3}{5}.$$

二阶导数

$$\ell''(\theta) = -\frac{6}{\theta^2} - \frac{4}{(1-\theta)^2} < 0,$$

所以该点为最大值. □

§9.3 一般 MLE 步骤

对独立观测 $x_1, \dots, x_n$:

- I. 写出似然函数. 离散情形 $\mathcal{L}(\theta) = \prod_i P(X = x_i; \theta)$; 连续情形 $\mathcal{L}(\theta) = \prod_i f_X(x_i; \theta)$.
- II. 取对数得到 $\ell(\theta)$.
- III. 求导, 令 score 等于零并求解.
- IV. 检查端点或用二阶导数/Hessian 确认最大值.

§9.4 正态均值: 方差已知

Example 9.4: 正态均值 MLE

设 $x_1, \dots, x_n$ 独立来自 $N(\mu, \sigma^2)$, 其中 μ 未知, σ^2 已知. 求 μ 的最大似然估计 (MLE).

Solution

$$\mathcal{L}(\mu) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x_i - \mu)^2}{2\sigma^2}\right].$$

$$\ell(\mu) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

$$\ell'(\mu) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu).$$

令其为零:

$$\sum_{i=1}^n (x_i - \hat{\mu}) = 0 \implies \hat{\mu} = \bar{x}.$$

因

$$\ell''(\mu) = -\frac{n}{\sigma^2} < 0,$$

样本均值为最大值点. □

§9.5 正态均值与方差均未知

Theorem 9.5: 正态分布的 MLE

若 $x_1, \dots, x_n$ 独立来自 $N(\mu, \sigma^2)$, 且 μ, σ^2 均未知, 则

$$\hat{\mu}_{\text{MLE}} = \bar{x}, \quad \hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Proof 似然为

$$\mathcal{L}(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x_i - \mu)^2}{2\sigma^2}\right].$$

对数似然:

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

对 μ 求偏导:

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu).$$

令其为零得 $\hat{\mu} = \bar{x}$. 令 $v = \sigma^2$, 对 v 求偏导:

$$\frac{\partial \ell}{\partial v} = -\frac{n}{2v} + \frac{1}{2v^2} \sum_{i=1}^n (x_i - \mu)^2.$$

令其为零并乘以 $2v^2$:

$$-nv + \sum_{i=1}^n (x_i - \mu)^2 = 0 \implies \hat{v} = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2.$$

代入 $\hat{\mu} = \bar{x}$ 得

$$\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

注意 MLE 使用分母 n , 而不是无偏样本方差中的 $n-1$. □

§9.6 常见分布的 MLE

Example 9.6: Poisson 分布

设 $y_1, \dots, y_n$ 独立同分布于 $\text{Poisson}(\lambda)$:

$$f(y_i; \lambda) = \frac{\lambda^{y_i} e^{-\lambda}}{y_i!}.$$

求 λ 的 MLE.

Solution

$$\ell(\lambda) = (\sum y_i) \log \lambda - n\lambda - \sum \log(y_i!).$$

$$\ell'(\lambda) = \frac{\sum y_i}{\lambda} - n.$$

令其为零:

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n y_i = \bar{y}.$$

□

Example 9.7: Binomial 分布

设 $y_1, \dots, y_m$ 独立同分布于 $\text{Binomial}(n, p)$, n 已知:

$$f(y_i; p) = \binom{n}{y_i} p^{y_i} (1-p)^{n-y_i}.$$

求 p 的 MLE.

Solution

$$\ell'(p) = \frac{\sum y_i}{p} - \frac{mn - \sum y_i}{1-p}.$$

令其为零:

$$(1 - \hat{p}) \sum y_i = \hat{p}(mn - \sum y_i) \implies \hat{p} = \frac{\sum_{i=1}^m y_i}{mn}.$$

□

Example 9.8: Exponential 分布

设 $y_1, \dots, y_n$ 独立同分布于 rate 参数为 θ 的指数分布:

$$f(y_i; \theta) = \theta e^{-\theta y_i}, \quad \theta > 0.$$

求 θ 的 MLE.

Solution

$$\ell(\theta) = n \log \theta - \theta \sum y_i.$$

$$\ell'(\theta) = \frac{n}{\theta} - \sum y_i.$$

令其为零:

$$\hat{\theta} = \frac{n}{\sum y_i} = \frac{1}{\bar{y}}.$$

□

Example 9.9: 正态方差: 均值已知

设 $y_1, \dots, y_n$ 独立来自 $N(\mu, \sigma^2)$, 其中 μ 已知, σ^2 未知. 求 σ^2 的 MLE.

Solution 令 $v = \sigma^2$:

$$\ell(v) = -\frac{n}{2} \log v - \frac{1}{2v} \sum_{i=1}^n (y_i - \mu)^2 + \text{常数}.$$

$$\ell'(v) = -\frac{n}{2v} + \frac{1}{2v^2} \sum_{i=1}^n (y_i - \mu)^2.$$

令其为零:

$$\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \mu)^2.$$

□

Fisher 信息 (Fisher Information)

§10.1 定义

Definition 10.1: Fisher 信息

对独立观测的对数似然 $\ell(\theta)$, 标量参数 θ 的 Fisher 信息为

$$I(\theta) = -E \left[\frac{d^2}{d\theta^2} \ell(\theta) \right].$$

样本的观测信息 (Observed Information) 为

$$J(\theta) = -\frac{d^2}{d\theta^2} \ell(\theta).$$

若有 n 个独立观测, 信息通常相加: $I_n(\theta) = nI_1(\theta)$.

§10.2 常见模型的 Fisher 信息

Example 10.2: Poisson Fisher 信息

若 $Y_1, \dots, Y_n \stackrel{iid}{\sim} \text{Poisson}(\lambda)$, 求 $I(\lambda)$.

Solution

$$\ell(\lambda) = (\sum y_i) \log \lambda - n\lambda - \sum \log(y_i!).$$

$$\ell''(\lambda) = -\frac{\sum y_i}{\lambda^2}.$$

因此

$$I(\lambda) = -E[\ell''(\lambda)] = E \left[\frac{\sum Y_i}{\lambda^2} \right] = \frac{n\lambda}{\lambda^2} = \frac{n}{\lambda}.$$

□

Example 10.3: Exponential Fisher 信息

若 $Y_1, \dots, Y_n \stackrel{iid}{\sim} \text{Exponential}(\theta)$, rate 为 θ , 求 $I(\theta)$.

Solution

$$\ell(\theta) = n \log \theta - \theta \sum y_i, \quad \ell''(\theta) = -\frac{n}{\theta^2}.$$

故

$$I(\theta) = \frac{n}{\theta^2}.$$

□

Example 10.4: 正态均值 Fisher 信息

若 $Y_1, \dots, Y_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$, 且 σ^2 已知, 求 μ 的 Fisher 信息.

Solution

$$\ell(\mu) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum (y_i - \mu)^2.$$

$$\frac{\partial^2 \ell}{\partial \mu^2} = -\frac{n}{\sigma^2}, \quad I(\mu) = \frac{n}{\sigma^2}.$$

□

Example 10.5: 正态方差 Fisher 信息

若 $Y_1, \dots, Y_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$, 且 μ 已知, 令 $v = \sigma^2$, 求 v 的 Fisher 信息.

Solution

$$\ell(v) = -\frac{n}{2} \log v - \frac{1}{2v} \sum (y_i - \mu)^2 + \text{常数}.$$

$$\frac{\partial^2 \ell}{\partial v^2} = \frac{n}{2v^2} - \frac{1}{v^3} \sum (y_i - \mu)^2.$$

由于 $E[\sum (Y_i - \mu)^2] = nv$,

$$I(v) = -E\left[\frac{\partial^2 \ell}{\partial v^2}\right] = \frac{n}{2v^2}.$$

即

$$I(\sigma^2) = \frac{n}{2\sigma^4}.$$

□

Example 10.6: 正态 Fisher 信息矩阵

若 $Y_1, \dots, Y_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$, 且 μ, σ^2 均未知, 求 (μ, v) 的 Fisher 信息矩阵, 其中 $v = \sigma^2$.

Solution 令 $v = \sigma^2$, 对数似然为

$$\ell(\mu, v) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log v - \frac{1}{2v} \sum_{i=1}^n (y_i - \mu)^2.$$

两个 score 分量为

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{v} \sum_{i=1}^n (y_i - \mu), \quad \frac{\partial \ell}{\partial v} = -\frac{n}{2v} + \frac{1}{2v^2} \sum_{i=1}^n (y_i - \mu)^2.$$

二阶导数为

$$\frac{\partial^2 \ell}{\partial \mu^2} = -\frac{n}{v}, \quad \frac{\partial^2 \ell}{\partial \mu \partial v} = -\frac{1}{v^2} \sum_{i=1}^n (y_i - \mu),$$

以及

$$\frac{\partial^2 \ell}{\partial v^2} = \frac{n}{2v^2} - \frac{1}{v^3} \sum_{i=1}^n (y_i - \mu)^2.$$

Fisher 信息 (Fisher information) 是负的期望 Hessian. 因为

$$E \left[\sum_{i=1}^n (Y_i - \mu) \right] = 0, \quad E \left[\sum_{i=1}^n (Y_i - \mu)^2 \right] = nv,$$

所以各元素为

$$I_{\mu\mu} = -E \left(\frac{\partial^2 \ell}{\partial \mu^2} \right) = \frac{n}{v},$$

$$I_{\mu v} = I_{v\mu} = -E \left(\frac{\partial^2 \ell}{\partial \mu \partial v} \right) = \frac{1}{v^2} E \left[\sum_{i=1}^n (Y_i - \mu) \right] = 0,$$

以及

$$I_{vv} = -E \left(\frac{\partial^2 \ell}{\partial v^2} \right) = - \left(\frac{n}{2v^2} - \frac{nv}{v^3} \right) = \frac{n}{2v^2}.$$

因此

$$I(\mu, v) = \begin{pmatrix} n/v & 0 \\ 0 & n/(2v^2) \end{pmatrix}.$$

等价地,

$$I(\mu, \sigma^2) = \begin{pmatrix} n/\sigma^2 & 0 \\ 0 & n/(2\sigma^4) \end{pmatrix}.$$

□

11

关键公式汇总

§11.1 单一总体均值 μ 的推断 (第 1-2 周, 第 1 讲)

大样本置信区间: $\bar{y} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$

小样本置信区间: $\bar{y} \pm t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}$

大样本 Z 检验: $Z_{\text{obs}} = \frac{\bar{y} - \mu_0}{\sigma / \sqrt{n}}$

小样本 t 检验: $t_{\text{obs}} = \frac{\bar{y} - \mu_0}{s / \sqrt{n}}, \quad \nu = n - 1$

功效 (右尾): $P(\bar{Y} \geq c \mid \mu = \mu_a), \quad c = \mu_0 + z_{\alpha} \frac{\sigma}{\sqrt{n}}$

§11.2 $\mu_1 - \mu_2$ 的双样本推断 (第 2 周, 第 2 讲)

大样本置信区间: $(\bar{y}_1 - \bar{y}_2) \pm z_{\alpha/2} \sqrt{S_1^2/n_1 + S_2^2/n_2}$

合并方差: $S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$

合并 t 统计量: $t_{\text{obs}} = \frac{(\bar{y}_1 - \bar{y}_2) - \Delta_0}{\sqrt{S_p^2(1/n_1 + 1/n_2)}}, \quad \nu = n_1 + n_2 - 2$

配对 t 统计量: $t_{\text{obs}} = \frac{\bar{d} - \Delta_0}{s_d / \sqrt{n}}, \quad \nu = n - 1$

§11.3 比例 p 的单样本推断 (第 3 周)

$$\hat{p} = \frac{X}{n}, \quad \text{CI: } \hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \quad Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$$

§11.4 $p_1 - p_2$ 的双样本推断 (第 3 周)

$$\text{CI: } (\hat{p}_1 - \hat{p}_2) \pm z_{\alpha/2} \sqrt{\frac{\hat{p}_1(1 - \hat{p}_1)}{n_1} + \frac{\hat{p}_2(1 - \hat{p}_2)}{n_2}}$$

$$\hat{p} = \frac{x_1 + x_2}{n_1 + n_2}, \quad Z_{\text{obs}} = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1 - \hat{p})(1/n_1 + 1/n_2)}}$$

§11.5 一元与多元线性回归 (第 5 周)

一元线性模型: $Y = \beta_0 + \beta_1 X + \varepsilon$

最小二乘斜率: $\hat{\beta}_1 = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}$

最小二乘截距: $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$

多元线性模型: $Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k + \varepsilon$

矩阵估计: $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$

样本相关系数: $r = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum(x_i - \bar{x})^2 \sum(y_i - \bar{y})^2}}$

决定系数: $R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}, \quad R^2 = r^2 \text{ (一元情形)}$

§11.6 多项式回归 (第 6 周)

多项式模型: $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \cdots + \beta_{N-1} X^{N-1}$

简单斜率公式: $\frac{\partial Y}{\partial X} = \beta_1 + 2\beta_2 X + 3\beta_3 X^2 + \cdots$

高阶项检验: 比较增广与精简模型, 使用 F 或 t 检验.

§11.7 一元线性回归 (第 9 周)

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}, \quad S_e^2 = \frac{S_{yy} - \hat{\beta}_1 S_{xy}}{n - 2}.$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{S_{xx}} \right), \quad \text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}, \quad \text{Var}(\hat{\varepsilon}_i) = \sigma^2 \left(1 - \frac{1}{n} - \frac{(X_i - \bar{X})^2}{S_{xx}} \right).$$

§11.8 单因素 ANOVA (第 10 周)

$$SST = SSB + SSW, \quad F = \frac{SSB/(k-1)}{SSW/(nk-k)}, \quad R^2 = \frac{SSB}{SST}.$$

§11.9 双因素 ANOVA (第 11 周)

$$SST = SSB_1 + SSB_2 + SSE.$$

$$F_{\text{处理}} = \frac{SSB_1/(k-1)}{SSE/(n-k-b+1)}, \quad F_{\text{区组}} = \frac{SSB_2/(b-1)}{SSE/(n-k-b+1)}.$$

