

Statistical Modelling and Inference

2026 期末复习讲义

依据黑板考试范围、课程讲义、课件、样卷与教师录音确认整理

June 2026

考试范围说明

本讲义纳入：

1. 无偏估计 (unbiased estimation) 与均方误差 (MSE);
2. 估计与假设检验：单总体均值、两总体均值、总体方差未知时的均值推断、总体比例；
3. 回归建模：简单线性回归、多元线性回归、最小二乘估计、残差及其性质；
4. MLE 的推断：正态、二项、泊松、指数分布，包括 Fisher 信息与大样本近似推断。

明确排除：ANOVA、R 编程、P-value、Power、Polynomial regression、nested-model comparison。

教师录音确认：期末共 5 道大题，每题可拆成若干小问；没有固定“几道证明、几道计算”的比例，但整体更偏 derivation/proof。Simple linear regression 仍需准备手算与基础推导；multiple linear regression 重点是理论推导与证明，不考给出大数据集后的繁重手算；polynomial regression 不纳入期末。

第三张黑板图说明：图中在 “Unknown Variance” 附近补写了两个统计量，但板书细节尚未由教师确认。本讲义当前按照课程材料中明确出现的内容，将 “Unknown Variance” 解释为“总体方差未知时，使用 t 分布进行单总体或两总体均值推断”。不把尚未确认的板书解释当作考试结论。

目录

1	全课程主线与做题决策	5
1.1	从样本到结论	5
1.2	推断方法选择总表	5
2	无偏估计、偏差与均方误差	6
2.1	定义与基本性质	6
2.2	偏差-方差分解	6
2.3	构造无偏估计量	7
2.4	合并两个无偏估计量	7

2.5	样本均值与样本方差	8
3	Estimation 与 Testing 的统一框架	9
3.1	点估计、区间估计与假设检验	9
3.2	假设检验的结构	9
3.3	CI 与双侧检验的关系	10
4	单总体均值：已知与未知方差	10
4.1	抽样分布	10
4.2	总体标准差已知： Z 推断	11
4.3	总体方差未知： t 推断	11
5	两总体均值的估计与检验	12
5.1	先判断：独立还是配对	12
5.2	两个独立大样本	12
5.3	小样本、正态、等方差：Pooled t	13
5.4	扩展：小样本、不假设等方差的 Welch t	13
5.5	配对样本	13
6	总体比例的估计与检验	14
6.1	单总体比例	14
6.2	两个独立总体比例	15
7	回归建模总览	15
7.1	回归的目标	15
7.2	误差假设	16
8	简单线性回归与最小二乘估计	16
8.1	模型与系数解释	16
8.2	最小二乘准则与正规方程	16
8.3	最小二乘直线的几何性质	17
8.4	平方和与误差方差	17
8.5	平方和分解、相关系数与决定系数	17
8.6	Week 9: OLS 估计量性质的标量证明	18
8.7	拟合均值与单个未来观测	19
8.8	斜率的区间与检验	20

9 残差及其性质	20
9.1 误差与残差的区别	20
9.2 简单线性回归残差性质	20
9.3 残差诊断的模式识别	21
10 多元线性回归与矩阵最小二乘	22
10.1 模型与设计矩阵	22
10.2 矩阵最小二乘推导	22
10.3 Hat matrix 与残差矩阵	23
10.4 估计量与残差的分布性质	23
11 录音确认的回归范围调整	24
12 MLE: 从最大似然到推断	24
12.1 Likelihood、log-likelihood 与 score	24
12.2 Fisher 信息与大样本推断	25
12.3 MLE 的不变性	25
13 四类分布的 MLE 与推断	26
13.1 正态分布	26
13.1.1 方差已知, 均值未知	26
13.1.2 均值已知, 方差未知	26
13.1.3 均值与方差都未知	26
13.2 二项分布	27
13.3 Poisson 分布	28
13.4 指数分布	28
13.5 四类分布速查表	29
14 高频证明与答题模板	30
14.1 证明题的通用路线	30
14.2 完整书面结论的语言	30
15 考前公式总表	30
15.1 无偏估计与 MSE	30
15.2 均值推断	31
15.3 比例推断	31

15.4 回归	31
15.5 MLE	32
16 最后检查清单	32

1 全课程主线与做题决策

1.1 从样本到结论

统计推断的主线是

总体参数未知 $\xleftarrow{\text{利用抽样分布}}$ 样本统计量已观测.

研究对象	总体参数（固定但未知）	样本统计量（随样本变化）
均值	μ	$\bar{X}$
方差	σ^2	S^2
总体比例	p	$\hat{p} = X/n$
回归系数	β_j	$\hat{\beta}_j$
一般模型参数	θ	$\hat{\theta}_{\text{MLE}}$

Estimator 与 Estimate

估计量（estimator）是样本的函数，如

$$\hat{\theta} = g(X_1, \dots, X_n),$$

因此在抽样之前是随机变量。估计值（estimate）是观察数据后代入得到的具体数值。证明无偏性、计算方差和 MSE 时讨论的是估计量；报告数据结果时给出的是估计值。

1.2 推断方法选择总表

目标参数	情形	核心标准误	参考分布
μ	σ 已知，或明确要求大样本正态近似	$\sigma/\sqrt{n}$ （大样本可按题意用 $s/\sqrt{n}$ ）	标准正态 Z
μ	σ 未知且总体正态	$s/\sqrt{n}$	t_{n-1}
$\mu_1 - \mu_2$	独立、大样本	$\sqrt{s_1^2/n_1 + s_2^2/n_2}$	标准正态 Z
$\mu_1 - \mu_2$	独立、小样本、正态、等方差	$s_p \sqrt{1/n_1 + 1/n_2}$	$t_{n_1+n_2-2}$
$\mu_1 - \mu_2$	独立、小样本、正态、不假设等方差	$\sqrt{s_1^2/n_1 + s_2^2/n_2}$	Welch t_ν
μ_d	配对样本	$s_d/\sqrt{n}$	t_{n-1}
p	单总体比例、大样本	CI 用 $\sqrt{\hat{p}(1-\hat{p})/n}$; 检 验 用 $\sqrt{p_0(1-p_0)/n}$	标准正态 Z
$p_1 - p_2$	两独立比例、大样本	CI 不合并；检验 $H_0: p_1 = p_2$ 时合并	标准正态 Z

任何 CI / 检验题的第一分钟

1. 写清楚参数：究竟是 μ 、 $\mu_1 - \mu_2$ 、 μ_d 、 p 还是 $p_1 - p_2$ 。
2. 判断设计：单样本、两个独立样本，还是配对样本。
3. 判断标准误与参考分布： Z 还是 t ；方差是否未知；两样本是否等方差。
4. 检查假设条件：随机性、独立性、正态性 or 大样本近似。
5. 再代公式，最后用题目语境解释。

2 无偏估计、偏差与均方误差

2.1 定义与基本性质

必须记忆：Bias 与 MSE

设 $\hat{\theta}$ 估计参数 θ ：

$$\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta.$$

若 $E(\hat{\theta}) = \theta$ ，则称 $\hat{\theta}$ 是 θ 的无偏估计量。

$$\text{MSE}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2].$$

常用运算规则：

$$E(aX + b) = aE(X) + b,$$

$$\text{Var}(aX + b) = a^2 \text{Var}(X),$$

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y).$$

独立蕴含协方差为零，但协方差为零一般不蕴含独立。

2.2 偏差-方差分解

必须记忆：MSE 分解

$$\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + [\text{Bias}(\hat{\theta})]^2.$$

若 $\hat{\theta}$ 无偏，则 $\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta})$ 。

完整证明

把估计误差拆成随机波动与系统偏差：

$$\hat{\theta} - \theta = [\hat{\theta} - E(\hat{\theta})] + [E(\hat{\theta}) - \theta].$$

令 $B = \text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta$ ，平方并取期望：

$$E[(\hat{\theta} - \theta)^2] = E[(\hat{\theta} - E\hat{\theta})^2 + 2B(\hat{\theta} - E\hat{\theta}) + B^2]$$

$$\begin{aligned}
 &= \text{Var}(\hat{\theta}) + 2B \underbrace{\text{E}[\hat{\theta} - \text{E}(\hat{\theta})]}_0 + B^2 \\
 &= \text{Var}(\hat{\theta}) + B^2.
 \end{aligned}$$

为什么 MSE 比 “是否无偏” 更全面

无偏只说明长期平均位置正确，不保证每次估计都靠近真值。MSE 同时惩罚方差和偏差，因此一个轻微有偏但方差显著更小的估计量，可能比无偏估计量具有更小的 MSE。

2.3 构造无偏估计量

若

$$\text{E}(\hat{\theta}) = a\theta + b, \quad a \neq 0,$$

则

$$\hat{\theta}^* = \frac{\hat{\theta} - b}{a}$$

是无偏估计量，因为

$$\text{E}(\hat{\theta}^*) = \frac{a\theta + b - b}{a} = \theta.$$

样卷型：缩放后的样本均值

设 $X_1, \dots, X_n$ 的均值为 μ 、方差为 σ^2 ，并定义

$$T = \frac{n-1}{n} \bar{X}.$$

则

$$\begin{aligned}
 \text{E}(T) &= \frac{n-1}{n} \mu, & \text{Bias}(T) &= -\frac{\mu}{n}, \\
 \text{Var}(T) &= \left(\frac{n-1}{n}\right)^2 \frac{\sigma^2}{n} = \frac{(n-1)^2 \sigma^2}{n^3}, \\
 \text{MSE}(T) &= \frac{(n-1)^2 \sigma^2}{n^3} + \frac{\mu^2}{n^2}.
 \end{aligned}$$

若令 $T^* = aT$ 并要求无偏，则

$$a \frac{n-1}{n} \mu = \mu \implies a = \frac{n}{n-1},$$

所以 $T^* = \bar{X}$ 。

2.4 合并两个无偏估计量

设 $\hat{\theta}_1, \hat{\theta}_2$ 都无偏，定义

$$\hat{\theta}_a = a\hat{\theta}_1 + (1-a)\hat{\theta}_2.$$

由于权重和为 1，

$$\text{E}(\hat{\theta}_a) = a\theta + (1-a)\theta = \theta.$$

所以任意固定 a 都保持无偏。

若

$$\text{Var}(\hat{\theta}_1) = v_1, \quad \text{Var}(\hat{\theta}_2) = v_2, \quad \text{Cov}(\hat{\theta}_1, \hat{\theta}_2) = c,$$

则

$$\text{Var}(\hat{\theta}_a) = a^2 v_1 + (1-a)^2 v_2 + 2a(1-a)c.$$

因为无偏，最小化 MSE 等价于最小化方差。求导可得

$$a^* = \frac{v_2 - c}{v_1 + v_2 - 2c}.$$

独立时 $c = 0$:

$$a^* = \frac{v_2}{v_1 + v_2}, \quad 1 - a^* = \frac{v_1}{v_1 + v_2}.$$

方差较小的估计量得到更大的权重。

2.5 样本均值与样本方差

若 $X_1, \dots, X_n$ 独立同分布, $E(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2$, 则

$$E(\bar{X}) = \mu, \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

定义

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

利用恒等式

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2,$$

取期望:

$$E \left[\sum_{i=1}^n (X_i - \bar{X})^2 \right] = n\sigma^2 - n \frac{\sigma^2}{n} = (n-1)\sigma^2.$$

因此

$$E(S_n^2) = \frac{n-1}{n} \sigma^2, \quad E(S^2) = \sigma^2.$$

常见陷阱

- 无偏样本方差用分母 $n-1$; 正态方差的 MLE 通常用分母 n 。
- S^2 对 σ^2 无偏, 并不意味着 S 对 σ 无偏。
- 比较估计量不能只比较偏差; 题目问“更好”时优先比较 MSE。

3 Estimation 与 Testing 的统一框架

3.1 点估计、区间估计与假设检验

点估计给一个最合理的数值；置信区间 (CI) 给出与数据相容的一段参数范围；假设检验考察某个指定参数值是否与数据相容。

大多数双侧 CI 都具有结构

$$\text{point estimate} \pm \text{critical value} \times \text{standard error}.$$

置信水平的正确解释

一个具体算出的 95% CI 要么覆盖真参数，要么不覆盖；在频率学派中参数不是随机的。95% 的含义是：若无限次重复抽样并用同一方法构造区间，约 95% 的区间会覆盖真参数。

3.2 假设检验的结构

原假设必须包含参数空间中的边界值，可以是简单原假设

$$H_0 : \theta = \theta_0.$$

也可以是单侧复合原假设，例如

$$H_0 : \theta \leq \theta_0 \quad \text{vs.} \quad H_a : \theta > \theta_0.$$

在后一种情形中，临界值法通常在原假设边界 $\theta = \theta_0$ 处计算检验统计量的参考分布。不能只因为观测估计值落在备择方向，就直接拒绝原假设。

备择假设决定尾部方向：

$$H_a : \theta > \theta_0, \quad H_a : \theta < \theta_0, \quad H_a : \theta \neq \theta_0.$$

标准化统计量的基本结构是

$$\text{test statistic} = \frac{\text{estimate} - \text{null value}}{\text{standard error under } H_0}.$$

它衡量观测估计值距离原假设值有多少个标准误。

第一类错误与第二类错误

- 第一类错误 (Type I error): H_0 真实却拒绝 H_0 。检验设计使其概率不超过显著性水平 α ；在边界处通常等于 α 。
- 第二类错误 (Type II error): H_0 错误却不能拒绝 H_0 。其概率通常记为 β ，会随真实参数值、样本量和拒绝域变化。

“不能拒绝 H_0 ”不等于证明 H_0 为真；它只表示现有样本没有提供足够强的反对证据。

临界值法：本讲义唯一采用的检验决策方法

若检验统计量在 H_0 下服从标准正态：

$$H_a : \theta > \theta_0 \Rightarrow Z_{\text{obs}} > z_\alpha \text{ 时拒绝 } H_0,$$

$$H_a : \theta < \theta_0 \Rightarrow Z_{\text{obs}} < -z_\alpha \text{ 时拒绝 } H_0,$$

$$H_a : \theta \neq \theta_0 \Rightarrow |Z_{\text{obs}}| > z_{\alpha/2} \text{ 时拒绝 } H_0.$$

t 检验将 z 临界值替换为相应自由度的 t 临界值。

置信水平	α	双侧临界值 $z_{\alpha/2}$	单侧临界值 z_α
90%	0.10	1.645	1.282
95%	0.05	1.960	1.645
99%	0.01	2.576	2.326

假设检验标准答题模板

1. 定义参数，并写出 H_0 与 H_a ；
2. 写出显著性水平 α ；
3. 说明适用条件与所用参考分布；
4. 写公式并计算观测检验统计量；
5. 写出临界值和拒绝域；
6. 比较并作出“拒绝 H_0 ”或“不能拒绝 H_0 ”的决定；
7. 用题目语境写结论，不写“接受 H_0 ”。

3.3 CI 与双侧检验的关系

在使用同一标准误与同一参考分布时，显著性水平为 α 的双侧检验

$$H_0 : \theta = \theta_0 \quad \text{vs.} \quad H_a : \theta \neq \theta_0$$

与 $(1 - \alpha)100\%$ CI 具有如下对应关系：

$$\theta_0 \notin \text{CI} \iff \text{拒绝 } H_0.$$

4 单总体均值：已知与未知方差

4.1 抽样分布

若 $X_1, \dots, X_n$ 独立同分布，均值为 μ 、方差为 σ^2 ：

$$E(\bar{X}) = \mu, \quad SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

若总体正态，则 $\bar{X}$ 精确正态；若总体不正态但样本量足够大，则由中心极限定理近似正态。

4.2 总体标准差已知: Z 推断

单总体均值: σ 已知

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1).$$

$(1 - \alpha)100\%$ CI:

$$\bar{x} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}.$$

检验 $H_0: \mu = \mu_0$:

$$Z_{\text{obs}} = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}.$$

单均值 Z 区间与检验

已知 $n = 64, \bar{x} = 33, \sigma = 16$ 。95% CI 为

$$33 \pm 1.96 \frac{16}{8} = 33 \pm 3.92 = (29.08, 36.92).$$

检验 $H_0: \mu = 30$ 对 $H_a: \mu > 30$, $\alpha = 0.05$:

$$Z_{\text{obs}} = \frac{33 - 30}{16/\sqrt{64}} = 1.50.$$

右尾临界值为 $z_{0.05} = 1.645$ 。因为 $1.50 < 1.645$, 不能拒绝 H_0 ; 数据不足以支持总体平均购物时间超过 30 分钟。

4.3 总体方差未知: t 推断

当 σ 未知, 用样本标准差 S 替代。若总体正态, 则

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

t 分布比标准正态尾部更厚, 反映了用 S 估计 σ 带来的额外不确定性; 自由度增加时, t 分布趋近标准正态。

单总体均值: σ 未知

$(1 - \alpha)100\%$ CI:

$$\bar{x} \pm t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}.$$

检验 $H_0: \mu = \mu_0$:

$$t_{\text{obs}} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}, \quad \nu = n - 1.$$

单均值 t 区间

某总体近似正态, $n = 24, \bar{x} = 98.25, s = 0.73$ 。若 $t_{0.05, 23} = 1.714$, 则 90% CI 为

$$98.25 \pm 1.714 \frac{0.73}{\sqrt{24}} = 98.25 \pm 0.255 = (97.995, 98.505).$$

Unknown Variance 的关键含义

- “方差未知”并不意味着不能推断; 它意味着用 S 替代 σ , 并使用 t 参考分布。
- 小样本 t 推断要求总体近似正态; 样本量很大时方法对轻度非正态更稳健。
- 自由度是 $n - 1$, 因为样本方差计算中先估计了一个均值。

5 两总体均值的估计与检验

5.1 先判断: 独立还是配对

独立样本 vs 配对样本

独立样本: 两组由不同个体组成, 例如治疗组与对照组。

配对样本: 同一个体前后测量, 或按特征一一匹配。配对设计的分析单位是差值

$$D_i = X_{1i} - X_{2i},$$

因此本质上是对差值做单样本推断。

5.2 两个独立大样本

若两组独立且样本量足够大,

$$SE(\bar{X}_1 - \bar{X}_2) = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}.$$

两个独立大样本均值

$(1 - \alpha)100\%$ CI:

$$(\bar{x}_1 - \bar{x}_2) \pm z_{\alpha/2} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}.$$

检验 $H_0: \mu_1 - \mu_2 = \Delta_0$:

$$Z_{\text{obs}} = \frac{(\bar{x}_1 - \bar{x}_2) - \Delta_0}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}.$$

两个独立大样本

组 A: $n_1 = 36, \bar{x}_1 = 18.4, s_1 = 4.8$; 组 B: $n_2 = 49, \bar{x}_2 = 15.9, s_2 = 5.6$ 。

$$\widehat{\mu_A - \mu_B} = 2.5,$$

$$SE = \sqrt{\frac{4.8^2}{36} + \frac{5.6^2}{49}} = \sqrt{0.64 + 0.64} = 1.131.$$

95% CI:

$$2.5 \pm 1.96(1.131) = (0.283, 4.717).$$

检验 $H_0: \mu_A - \mu_B = 0$ 对 $H_a: \mu_A - \mu_B > 0$:

$$Z_{\text{obs}} = \frac{2.5}{1.131} = 2.21 > 1.645.$$

拒绝 H_0 ; 数据支持组 A 的总体平均学习时间更长。

5.3 小样本、正态、等方差: Pooled t

若两个总体正态、相互独立, 并可假设

$$\sigma_1^2 = \sigma_2^2 = \sigma^2,$$

则把两个样本方差按自由度加权合并:

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}.$$

两个独立小样本: 等方差

$$t_{\text{obs}} = \frac{(\bar{x}_1 - \bar{x}_2) - \Delta_0}{s_p \sqrt{1/n_1 + 1/n_2}}, \quad \nu = n_1 + n_2 - 2.$$

$$(\bar{x}_1 - \bar{x}_2) \pm t_{\alpha/2, \nu} s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}.$$

5.4 扩展: 小样本、不假设等方差的 Welch t

Welch 推断是处理两个独立小样本且不假设等方差的常用方法, 但课程材料主要强调 pooled t 。若试题未要求 Welch, 先依据题目给出的假设与课堂约定选法。Welch 方法为:

$$SE = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}, \quad t_{\text{obs}} = \frac{(\bar{x}_1 - \bar{x}_2) - \Delta_0}{SE}.$$

近似自由度为

$$\nu \approx \frac{(s_1^2/n_1 + s_2^2/n_2)^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1}}.$$

若试题明确要求 pooled t 或明确给出等方差, 则使用上一节方法。

5.5 配对样本

定义差值

$$D_i = X_{1i} - X_{2i}, \quad i = 1, \dots, n.$$

计算差值样本均值 $\bar{d}$ 与标准差 s_d ，再做单总体 t 推断。

配对 t 推断

$$t_{\text{obs}} = \frac{\bar{d} - \Delta_0}{s_d/\sqrt{n}}, \quad \nu = n - 1.$$

$$\bar{d} \pm t_{\alpha/2, n-1} \frac{s_d}{\sqrt{n}}.$$

两总体均值高频错误

- 配对数据不能当成两个独立样本；必须先求每一对的差值。
- 独立大样本标准误不能写成 $s_1/\sqrt{n_1} + s_2/\sqrt{n_2}$ ；方差先相加，再开方。
- Pooled t 需要等方差假设；Welch t 不合并方差。
- 参数顺序必须与样本差的顺序一致。例如估计 $\mu_A - \mu_B$ 就应计算 $\bar{x}_A - \bar{x}_B$ 。

6 总体比例的估计与检验

6.1 单总体比例

若 X 是 n 次独立 Bernoulli 试验中的成功次数，则

$$X \sim \text{Binomial}(n, p), \quad \hat{p} = \frac{X}{n}.$$

$$E(\hat{p}) = p, \quad \text{Var}(\hat{p}) = \frac{p(1-p)}{n}.$$

单总体比例：CI 与检验分母不同

CI 使用样本比例估计标准误：

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}.$$

检验 $H_0: p = p_0$ 时，标准误在 H_0 下计算：

$$Z_{\text{obs}} = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}.$$

正态近似通常要求成功与失败的期望次数都足够大。常用检查为

$$n\hat{p} \geq 5, \quad n(1-\hat{p}) \geq 5$$

用于 CI；检验时用 np_0 与 $n(1-p_0)$ 检查。

单总体比例

在 $n = 400$ 人中有 $x = 100$ 人具有某特征，因此 $\hat{p} = 0.25$ 。检验 $H_0 : p = 0.20$ 对 $H_a : p \neq 0.20$ ， $\alpha = 0.05$ ：

$$Z_{\text{obs}} = \frac{0.25 - 0.20}{\sqrt{0.20(0.80)/400}} = \frac{0.05}{0.02} = 2.50.$$

因为 $|2.50| > 1.96$ ，拒绝 H_0 ；数据支持总体比例不同于 20%。

6.2 两个独立总体比例

设

$$\hat{p}_1 = \frac{x_1}{n_1}, \quad \hat{p}_2 = \frac{x_2}{n_2}.$$

两总体比例：CI 不合并

$$(\hat{p}_1 - \hat{p}_2) \pm z_{\alpha/2} \sqrt{\frac{\hat{p}_1(1 - \hat{p}_1)}{n_1} + \frac{\hat{p}_2(1 - \hat{p}_2)}{n_2}}.$$

检验

$$H_0 : p_1 = p_2$$

时，原假设认为两组共享同一个比例，因此先计算合并比例

$$\hat{p}_{\text{pool}} = \frac{x_1 + x_2}{n_1 + n_2},$$

再使用

$$Z_{\text{obs}} = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}_{\text{pool}}(1 - \hat{p}_{\text{pool}}) (1/n_1 + 1/n_2)}}.$$

比例推断最常见陷阱

- 单比例 CI 分母用 $\hat{p}$ ，单比例检验分母用 p_0 。
- 两比例 CI 不合并；检验 $H_0 : p_1 = p_2$ 时才合并。
- 两比例 CI 的第二项必须是 $\hat{p}_2(1 - \hat{p}_2)/n_2$ ；原课程 PDF 的该处存在下标笔误。
- 区间端点若超出 $[0, 1]$ ，说明简单正态近似可能不理想。

7 回归建模总览

7.1 回归的目标

回归分析用于描述和预测响应变量 Y 如何随预测变量变化。必须区分：

条件均值 $E(Y | X = x)$ 与 单个观测 Y 。

即使条件均值是一条确定的曲线，单个观测仍因误差项而随机波动。

7.2 误差假设

简单线性回归的总体模型为

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i.$$

经典假设可写为：

$$E(\varepsilon_i | x_i) = 0, \quad \text{Var}(\varepsilon_i | x_i) = \sigma^2, \quad \varepsilon_i \perp \varepsilon_j \ (i \neq j).$$

若还假定

$$\varepsilon_i \sim N(0, \sigma^2),$$

则可得到精确的小样本 t 推断。正态性主要服务于推断，不是最小二乘系数存在的必要条件。

模型假设与残差图

- 线性或函数形式合理：残差对拟合值图不应出现系统曲线。
- 同方差：残差散布宽度应大致恒定，不应呈漏斗形。
- 独立：依赖研究设计与时间顺序，不能只靠普通散点图保证。
- 正态性：误差应近似正态；残差只能作为误差的观测代理。

8 简单线性回归与最小二乘估计

8.1 模型与系数解释

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad E(Y_i | x_i) = \beta_0 + \beta_1 x_i.$$

- β_0 : $x = 0$ 时的总体平均响应；若 0 不在数据合理范围内，它可能只具有数学意义。
- β_1 : x 每增加一个单位，条件均值平均变化 β_1 个单位。

8.2 最小二乘准则与正规方程

拟合直线

$$\hat{y}_i = b_0 + b_1 x_i$$

使残差平方和最小：

$$SSE(b_0, b_1) = \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2.$$

对 b_0, b_1 求偏导并令其为零：

$$\begin{aligned} \frac{\partial SSE}{\partial b_0} &= -2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i) = 0, \\ \frac{\partial SSE}{\partial b_1} &= -2 \sum_{i=1}^n x_i (y_i - b_0 - b_1 x_i) = 0. \end{aligned}$$

这给出正规方程，也立刻给出残差的两个正交性质：

$$\sum e_i = 0, \quad \sum x_i e_i = 0.$$

定义

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2, \quad S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}), \quad S_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2.$$

简单线性回归 OLS

$$\hat{\beta}_1 = b_1 = \frac{S_{xy}}{S_{xx}}.$$

$$\hat{\beta}_0 = b_0 = \bar{y} - b_1 \bar{x}.$$

$$\hat{y} = b_0 + b_1 x.$$

8.3 最小二乘直线的几何性质

- 拟合直线必经过 $(\bar{x}, \bar{y})$:

$$b_0 + b_1 \bar{x} = \bar{y}.$$

- 若模型含截距, 残差均值为零:

$$\bar{e} = 0.$$

- 残差与预测变量正交:

$$\sum x_i e_i = 0.$$

- 残差与拟合值正交:

$$\sum \hat{y}_i e_i = 0.$$

8.4 平方和与误差方差

$$SST = S_{yy} = \sum (y_i - \bar{y})^2,$$

$$SSE = \sum (y_i - \hat{y}_i)^2 = S_{yy} - \frac{S_{xy}^2}{S_{xx}} = S_{yy} - \hat{\beta}_1 S_{xy}.$$

简单线性回归估计了两个系数, 故误差方差的无偏估计为

$$s_e^2 = \frac{SSE}{n-2}, \quad s_e = \sqrt{\frac{SSE}{n-2}}.$$

8.5 平方和分解、相关系数与决定系数

在含截距的简单线性回归中, 总变异可分解为模型解释的变异与未解释的残差变异:

$$SST = SSR + SSE,$$

其中

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2, \quad SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2, \quad SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

决定系数为

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}.$$

R^2 表示样本中 Y 的总变异有多大比例被拟合模型解释。它不证明因果关系，也不能单独保证模型形式正确。

样本相关系数为

$$r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}, \quad -1 \leq r \leq 1.$$

在含截距的简单线性回归中，

$$R^2 = r^2.$$

但在多元回归中，不再有某一个简单相关系数满足该等式。

8.6 Week 9: OLS 估计量性质的标量证明

令

$$a_i = \frac{x_i - \bar{x}}{S_{xx}}, \quad \hat{\beta}_1 = \sum_{i=1}^n a_i Y_i.$$

又因为

$$\hat{\beta}_0 = \bar{Y} - \bar{x}\hat{\beta}_1,$$

可写成

$$\hat{\beta}_0 = \sum_{i=1}^n b_i Y_i, \quad b_i = \frac{1}{n} - \bar{x}a_i.$$

权重满足

$$\sum a_i = 0, \quad \sum a_i x_i = 1, \quad \sum a_i^2 = \frac{1}{S_{xx}}.$$

同时

$$\begin{aligned} \sum b_i &= 1, & \sum b_i x_i &= 0, \\ \sum b_i^2 &= \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}, & \sum a_i b_i &= -\frac{\bar{x}}{S_{xx}}. \end{aligned}$$

老师手写证明的入口

手写备课笔记的核心技巧是把估计量写成 Y_i 的线性组合：

$$\hat{\beta}_1 = \sum a_i Y_i, \quad \hat{\beta}_0 = \sum b_i Y_i.$$

之后所有期望、方差和协方差证明，都只是在使用

$$E(Y_i) = \beta_0 + \beta_1 x_i, \quad \text{Var}(Y_i) = \sigma^2, \quad Y_i \text{ 相互独立}.$$

$\hat{\beta}_1$ 无偏性的完整证明

$$E(\hat{\beta}_1) = \sum_{i=1}^n a_i E(Y_i)$$

$$\begin{aligned}
&= \sum_{i=1}^n a_i(\beta_0 + \beta_1 x_i) \\
&= \beta_0 \sum_{i=1}^n a_i + \beta_1 \sum_{i=1}^n a_i x_i \\
&= 0 + \beta_1 = \beta_1.
\end{aligned}$$

$\hat{\beta}_0$ 无偏性的完整证明

$$\begin{aligned}
E(\hat{\beta}_0) &= \sum_{i=1}^n b_i E(Y_i) \\
&= \sum_{i=1}^n b_i(\beta_0 + \beta_1 x_i) \\
&= \beta_0 \sum_{i=1}^n b_i + \beta_1 \sum_{i=1}^n b_i x_i \\
&= \beta_0 + 0 = \beta_0.
\end{aligned}$$

由独立与同方差：

$$\begin{aligned}
\text{Var}(\hat{\beta}_1) &= \sum a_i^2 \sigma^2 = \boxed{\frac{\sigma^2}{S_{xx}}}. \\
\text{Var}(\hat{\beta}_0) &= \sum b_i^2 \sigma^2 = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right).
\end{aligned}$$

以及

$$\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = \text{Cov}\left(\sum b_i Y_i, \sum a_i Y_i\right) = \sigma^2 \sum a_i b_i = -\frac{\sigma^2 \bar{x}}{S_{xx}}.$$

因此

$$\boxed{\text{Var}(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)},$$

$$\boxed{\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\frac{\sigma^2 \bar{x}}{S_{xx}}}.$$

若 $\bar{x} > 0$ ，斜率与截距估计负相关；斜率更陡时，为保持直线经过 $(\bar{x}, \bar{y})$ ，截距倾向降低。

8.7 拟合均值与单个未来观测

在 x_0 处的拟合均值为

$$\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0.$$

它是 $E(Y | X = x_0) = \beta_0 + \beta_1 x_0$ 的无偏估计：

$$E(\hat{Y}_0) = \beta_0 + \beta_1 x_0.$$

方差为

$$\boxed{\text{Var}(\hat{Y}_0) = \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]}.$$

它在 $x_0 = \bar{x}$ 处最小，离样本中心越远越大。

均值响应的 CI:

$$\hat{y}_0 \pm t_{\alpha/2, n-2} s_e \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}.$$

单个未来观测还包含新误差项，因此预测区间更宽:

$$\hat{y}_0 \pm t_{\alpha/2, n-2} s_e \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}.$$

8.8 斜率的区间与检验

用 s_e^2 替代 σ^2 :

$$SE(\hat{\beta}_1) = \frac{s_e}{\sqrt{S_{xx}}}.$$

斜率 CI:

$$\hat{\beta}_1 \pm t_{\alpha/2, n-2} \frac{s_e}{\sqrt{S_{xx}}}.$$

检验 $H_0: \beta_1 = \beta_{1,0}$:

$$t_{\text{obs}} = \frac{\hat{\beta}_1 - \beta_{1,0}}{s_e / \sqrt{S_{xx}}}, \quad \nu = n - 2.$$

9 残差及其性质

9.1 误差与残差的区别

$$\varepsilon_i = Y_i - E(Y_i | x_i)$$

是不可直接观测的真实误差；而

$$e_i = y_i - \hat{y}_i$$

是拟合模型后可计算的残差。残差用于诊断误差假设，但残差不是误差本身。

9.2 简单线性回归残差性质

必须掌握：含截距 OLS 残差

$$\sum_{i=1}^n e_i = 0,$$

$$\sum_{i=1}^n x_i e_i = 0,$$

$$\sum_{i=1}^n \hat{y}_i e_i = 0.$$

在模型正确时:

$$E(e_i) = 0.$$

简单线性回归中，第 i 个观测的杠杆值为

$$h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}.$$

残差方差为

$$\text{Var}(e_i) = \sigma^2(1 - h_{ii}) = \sigma^2 \left[1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{S_{xx}} \right].$$

Week 9: 残差期望与方差的标量证明

在简单线性回归中

$$e_i = Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i = Y_i - \bar{Y} - (x_i - \bar{x})\hat{\beta}_1.$$

因此

$$\begin{aligned} E(e_i) &= E(Y_i) - E(\bar{Y}) - (x_i - \bar{x})E(\hat{\beta}_1) \\ &= (\beta_0 + \beta_1 x_i) - (\beta_0 + \beta_1 \bar{x}) - (x_i - \bar{x})\beta_1 = 0. \end{aligned}$$

令 $d_i = x_i - \bar{x}$ 。由于

$$\text{Var}(Y_i - \bar{Y}) = \sigma^2 \left(1 - \frac{1}{n} \right), \quad \text{Cov}(Y_i - \bar{Y}, \hat{\beta}_1) = \frac{d_i \sigma^2}{S_{xx}},$$

并且

$$\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}},$$

所以

$$\begin{aligned} \text{Var}(e_i) &= \text{Var}(Y_i - \bar{Y} - d_i \hat{\beta}_1) \\ &= \sigma^2 \left(1 - \frac{1}{n} \right) + d_i^2 \frac{\sigma^2}{S_{xx}} - 2d_i \frac{d_i \sigma^2}{S_{xx}} \\ &= \sigma^2 \left[1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{S_{xx}} \right]. \end{aligned}$$

为什么残差方差小于误差方差

拟合值使用了同一个观测的信息，因此残差不是未经处理的原始误差。高杠杆观测对自己的拟合值影响更大，故其原始残差方差反而更小。这也是诊断时常使用标准化或学生化残差的原因。

9.3 残差诊断的模式识别

残差图现象	可能问题
围绕 0 随机散布、宽度大致恒定	线性与同方差假设较合理
明显弯曲或波浪形	函数形式错误，可能需要重新指定模型或作变量变换
漏斗形，散布随拟合值增大	异方差
孤立的大残差	可能的异常响应值
远离数据中心且杠杆高	可能的高杠杆点；不一定有大残差
时间顺序上连续同号或周期模式	独立性可能失效

10 多元线性回归与矩阵最小二乘

10.1 模型与设计矩阵

含 k 个预测变量的模型为

$$Y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + \varepsilon_i.$$

矩阵形式:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

其中 $\mathbf{X}$ 的第一列通常为全 1 截距列, 维数为

$$\mathbf{X} : n \times p, \quad p = k + 1.$$

多元回归系数的解释

β_j 表示: 保持其他预测变量不变时, x_j 增加一个单位, 条件平均响应变化 β_j 个单位。它不是忽略其他变量后 x_j 与 Y 的简单关联。

10.2 矩阵最小二乘推导

最小化

$$SSE(\boldsymbol{\beta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}).$$

对 $\boldsymbol{\beta}$ 求梯度并令其为零:

$$-2\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = 0.$$

得到正规方程

$$\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}.$$

若 $\mathbf{X}$ 列满秩, 使 $\mathbf{X}^\top \mathbf{X}$ 可逆, 则

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

多元回归理论证明题

教师录音确认: multiple regression 不考给出大数据集后的繁重 numerical calculation。应重点准备以下证明路线:

1. 从最小化 $SSE(\boldsymbol{\beta})$ 推出正规方程 $\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}$;
2. 在列满秩条件下写出 $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$;
3. 由 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ 推出 $E(\hat{\boldsymbol{\beta}}) = \boldsymbol{\beta}$;
4. 用协方差矩阵运算推出 $\text{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$;
5. 用 $\mathbf{e} = (\mathbf{I} - \mathbf{H})\mathbf{y}$ 与 $\mathbf{X}^\top \mathbf{e} = \mathbf{0}$ 证明残差性质。

10.3 Hat matrix 与残差矩阵

定义帽子矩阵

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top.$$

则

$$\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}, \quad \mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = (\mathbf{I} - \mathbf{H})\mathbf{y}.$$

$\mathbf{H}$ 对称且幂等:

$$\mathbf{H}^\top = \mathbf{H}, \quad \mathbf{H}^2 = \mathbf{H}.$$

残差与设计矩阵的每一列正交:

$$\mathbf{X}^\top \mathbf{e} = \mathbf{0}.$$

若模型含截距列 $\mathbf{1}$, 则 $\mathbf{1}^\top \mathbf{e} = 0$, 即残差和为零。

10.4 估计量与残差的分布性质

若

$$E(\boldsymbol{\varepsilon}) = \mathbf{0}, \quad \text{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I},$$

则

$$E(\hat{\boldsymbol{\beta}}) = \boldsymbol{\beta},$$

$$\text{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}.$$

证明:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}) = \boldsymbol{\beta} + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\varepsilon}.$$

取期望即得无偏性; 利用协方差矩阵运算即得方差。

残差协方差矩阵:

$$\text{Var}(\mathbf{e}) = \sigma^2 (\mathbf{I} - \mathbf{H}).$$

因此

$$\text{Var}(e_i) = \sigma^2 (1 - h_{ii}), \quad \text{Cov}(e_i, e_j) = -\sigma^2 h_{ij} \quad (i \neq j).$$

残差一般并不相互独立。

误差方差的无偏估计:

$$s^2 = \frac{SSE}{n - p},$$

其中 p 是估计参数个数, 包括截距。

11 录音确认的回归范围调整

Polynomial regression 不纳入期末

教师录音中明确说明: polynomial regression 属于 computer-based / R-based / graph-based work, 手算负担过重, 因此不进入期末考试。此前根据黑板照片临时标注为重点的判断, 以本次录音确认结果为准。

回归复习时间应转移到:

- simple linear regression 的手算、最小二乘与基础推导;
- multiple linear regression 的矩阵最小二乘、估计量期望/方差/协方差与残差性质证明;
- Week 9 中 regression inference 的证明路线。

12 MLE: 从最大似然到推断

12.1 Likelihood、log-likelihood 与 score

设 $Y_1, \dots, Y_n$ 独立同分布, 密度或概率质量函数为 $f(y; \theta)$ 。观测值为 $y_1, \dots, y_n$ 。

$$L(\theta) = \prod_{i=1}^n f(y_i; \theta).$$

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(y_i; \theta).$$

score 函数为

$$U(\theta) = \frac{\partial \ell(\theta)}{\partial \theta}.$$

MLE 定义为

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta \in \Theta} L(\theta) = \arg \max_{\theta \in \Theta} \ell(\theta).$$

MLE 推导标准流程

1. 写出单个观测的 pmf/pdf, 并标明参数空间;
2. 利用独立性写乘积似然;
3. 取对数, 将乘积转为求和;
4. 求 score, 令 $U(\theta) = 0$;
5. 解出候选 MLE;
6. 用二阶导数、凹性、端点或参数空间检查最大值;
7. 计算 Fisher 信息, 写出大样本标准误与近似推断。

12.2 Fisher 信息与大样本推断

对标量参数,

$$I_n(\theta) = -\mathbb{E}_\theta \left[\frac{\partial^2 \ell(\theta)}{\partial \theta^2} \right].$$

在常见正则条件下, 也有

$$I_n(\theta) = \text{Var}_\theta[U(\theta)].$$

独立观测的信息相加:

$$I_n(\theta) = nI_1(\theta).$$

MLE 的渐近正态性

在常见正则条件下, 当 n 大时,

$$\hat{\theta}_{\text{MLE}} \approx N(\theta, I_n(\theta)^{-1}).$$

用 MLE 代入未知参数后,

$$\widehat{\text{SE}}(\hat{\theta}_{\text{MLE}}) = \frac{1}{\sqrt{I_n(\hat{\theta}_{\text{MLE}})}}.$$

近似 $(1 - \alpha)100\%$ Wald CI:

$$\hat{\theta}_{\text{MLE}} \pm z_{\alpha/2} \widehat{\text{SE}}(\hat{\theta}_{\text{MLE}}).$$

Wald 近似的适用边界

Wald CI 与 Wald 检验依赖大样本渐近正态近似。样本很小、似然明显偏斜, 或参数接近边界时, 近似可能较差; 区间甚至可能超出合法参数空间, 例如比例区间超出 $[0, 1]$ 、正参数区间出现负端点。遇到此类结果, 应明确说明这是简单 Wald 近似的局限。

检验 $H_0: \theta = \theta_0$ 可使用近似 Wald 统计量

$$Z_{\text{obs}} = \frac{\hat{\theta}_{\text{MLE}} - \theta_0}{1/\sqrt{I_n(\hat{\theta}_{\text{MLE}})}}.$$

再按单尾或双尾临界值法作决策。

Fisher 信息的直觉

信息越大, 对数似然在真参数附近越尖, 参数越容易被精确定位; 因此估计方差约为信息的倒数。样本量增加时信息通常线性增加, 标准误通常按 $1/\sqrt{n}$ 缩小。

12.3 MLE 的不变性

若 $\hat{\theta}$ 是 θ 的 MLE, 且 $\phi = g(\theta)$, 则在适当条件下

$$\hat{\phi}_{\text{MLE}} = g(\hat{\theta}_{\text{MLE}}).$$

例如指数分布 rate 参数为 λ , mean 参数为 $\beta = 1/\lambda$; 若 $\hat{\lambda} = 1/\bar{Y}$, 则

$$\hat{\beta} = \frac{1}{\hat{\lambda}} = \bar{Y}.$$

13 四类分布的 MLE 与推断

13.1 正态分布

13.1.1 方差已知, 均值未知

若

$$Y_1, \dots, Y_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

且 σ^2 已知, 则

$$\ell(\mu) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2.$$

$$U(\mu) = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \mu).$$

令 $U(\mu) = 0$:

$$\hat{\mu}_{\text{MLE}} = \bar{y}.$$

二阶导数为 $-n/\sigma^2 < 0$, 所以确为最大值。

$$I_n(\mu) = \frac{n}{\sigma^2}, \quad \text{SE}(\hat{\mu}) = \frac{\sigma}{\sqrt{n}}.$$

此处正态均值 MLE 的正态分布是精确结果, 而不仅是渐近结果。

13.1.2 均值已知, 方差未知

令 $v = \sigma^2$, 且 μ 已知:

$$\ell(v) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log v - \frac{1}{2v} \sum_{i=1}^n (y_i - \mu)^2.$$

求导并令其为零:

$$\hat{v}_{\text{MLE}} = \frac{1}{n} \sum_{i=1}^n (y_i - \mu)^2.$$

Fisher 信息:

$$I_n(v) = \frac{n}{2v^2}, \quad \widehat{\text{SE}}(\hat{v}) = \sqrt{\frac{2\hat{v}^2}{n}} = \hat{v} \sqrt{\frac{2}{n}}.$$

13.1.3 均值与方差都未知

$$\hat{\mu}_{\text{MLE}} = \bar{y}, \quad \hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2.$$

注意

$$E(\hat{\sigma}_{\text{MLE}}^2) = \frac{n-1}{n}\sigma^2,$$

所以它有偏；无偏样本方差使用分母 $n-1$ 。

令 $v = \sigma^2$ ，Fisher 信息矩阵为

$$\mathbf{I}_n(\mu, v) = \begin{pmatrix} n/v & 0 \\ 0 & n/(2v^2) \end{pmatrix}.$$

交叉信息为零，因为相关交叉二阶导数的期望包含

$$E\left[\sum(Y_i - \mu)\right] = 0.$$

因此 $\hat{\mu}$ 与 $\hat{v}$ 在大样本下渐近不相关。

13.2 二项分布

先考虑一个二项计数

$$Y \sim \text{Binomial}(m, p),$$

观测到 y 次成功。似然与对数似然为

$$L(p) = \binom{m}{y} p^y (1-p)^{m-y},$$

$$\ell(p) = \log \binom{m}{y} + y \log p + (m-y) \log(1-p).$$

score:

$$U(p) = \frac{y}{p} - \frac{m-y}{1-p}.$$

当 $0 < y < m$ 时，令其为零：

$$\hat{p}_{\text{MLE}} = \frac{y}{m}.$$

若 $y = 0$ 或 $y = m$ ，score 方程在参数空间内部没有根，但检查边界仍得到同一公式：

$$y = 0 \Rightarrow \hat{p} = 0, \quad y = m \Rightarrow \hat{p} = 1.$$

Fisher 信息：

$$I(p) = \frac{m}{p(1-p)}.$$

所以

$$\widehat{\text{SE}}(\hat{p}) = \sqrt{\frac{\hat{p}(1-\hat{p})}{m}}.$$

若有 n 个独立的 $\text{Binomial}(m, p)$ 观测，则

$$\hat{p} = \frac{\sum_{i=1}^n y_i}{nm}, \quad I_n(p) = \frac{nm}{p(1-p)}.$$

Bernoulli 是 $m = 1$ 的特殊情况。

二项 MLE 与 Fisher 信息

若 $m = 50$ 次试验观察到 $y = 18$ 次成功, 则

$$\hat{p} = \frac{18}{50} = 0.36,$$

$$\widehat{\text{SE}}(\hat{p}) = \sqrt{\frac{0.36(0.64)}{50}} \approx 0.0679.$$

13.3 Poisson 分布

若

$$Y_1, \dots, Y_n \stackrel{\text{iid}}{\sim} \text{Poisson}(\lambda),$$

则

$$f(y_i; \lambda) = \frac{\lambda^{y_i} e^{-\lambda}}{y_i!}.$$

对数似然:

$$\ell(\lambda) = \sum_{i=1}^n y_i \log \lambda - n\lambda - \sum_{i=1}^n \log(y_i!).$$

score:

$$U(\lambda) = \frac{\sum y_i}{\lambda} - n.$$

因此

$$\hat{\lambda}_{\text{MLE}} = \bar{y}.$$

二阶导数:

$$\ell''(\lambda) = -\frac{\sum y_i}{\lambda^2}.$$

利用 $E(\sum Y_i) = n\lambda$:

$$I_n(\lambda) = \frac{n}{\lambda}.$$

因此

$$\widehat{\text{SE}}(\hat{\lambda}) = \sqrt{\frac{\hat{\lambda}}{n}}.$$

近似 CI:

$$\hat{\lambda} \pm z_{\alpha/2} \sqrt{\frac{\hat{\lambda}}{n}}.$$

13.4 指数分布

课程采用 rate 参数化:

$$Y_1, \dots, Y_n \stackrel{\text{iid}}{\sim} \text{Exponential}(\theta), \quad f(y; \theta) = \theta e^{-\theta y}, \quad y > 0, \theta > 0.$$

此时

$$E(Y) = \frac{1}{\theta}, \quad \text{Var}(Y) = \frac{1}{\theta^2}.$$

对数似然:

$$\ell(\theta) = n \log \theta - \theta \sum_{i=1}^n y_i.$$

score:

$$U(\theta) = \frac{n}{\theta} - \sum_{i=1}^n y_i.$$

因此

$$\hat{\theta}_{\text{MLE}} = \frac{n}{\sum y_i} = \frac{1}{\bar{y}}.$$

$$\ell''(\theta) = -\frac{n}{\theta^2}, \quad I_n(\theta) = \frac{n}{\theta^2}.$$

所以

$$\widehat{\text{SE}}(\hat{\theta}) = \frac{\hat{\theta}}{\sqrt{n}}.$$

近似 CI:

$$\hat{\theta} \pm z_{\alpha/2} \frac{\hat{\theta}}{\sqrt{n}}.$$

指数分布参数化

必须先确认参数是 rate 还是 mean/scale。

$$f(y; \theta) = \theta e^{-\theta y} \Rightarrow \theta \text{ 是 rate, MLE} = 1/\bar{y}.$$

$$f(y; \beta) = \frac{1}{\beta} e^{-y/\beta} \Rightarrow \beta \text{ 是 mean/scale, MLE} = \bar{y}.$$

13.5 四类分布速查表

模型	MLE	Fisher 信息	估计标准误
$N(\mu, \sigma^2)$, σ^2 已知	$\hat{\mu} = \bar{Y}$	$I_n(\mu) = n/\sigma^2$	$\sigma/\sqrt{n}$
$N(\mu, v)$, μ 已知	$\hat{v} = n^{-1} \sum (Y_i - \mu)^2$	$I_n(v) = n/(2v^2)$	$\hat{v}\sqrt{2/n}$
Binomial(m, p)	$\hat{p} = Y/m$	$I(p) = m/[p(1-p)]$	$\sqrt{\hat{p}(1-\hat{p})/m}$
Poisson(λ)	$\hat{\lambda} = \bar{Y}$	$I_n(\lambda) = n/\lambda$	$\sqrt{\hat{\lambda}/n}$
Exponential(θ), rate	$\hat{\theta} = 1/\bar{Y}$	$I_n(\theta) = n/\theta^2$	$\hat{\theta}/\sqrt{n}$

14 高频证明与答题模板

14.1 证明题的通用路线

证明估计量无偏

1. 把估计量写成随机变量的线性组合；
2. 利用期望线性性；
3. 代入每个随机变量的期望；
4. 化简为目标参数。

计算估计量方差

1. 提取常数的平方；
2. 展开线性组合方差；
3. 使用独立性删除协方差项，或保留给定协方差；
4. 化简并检查单位。

证明 OLS 残差性质

直接从正规方程出发：

$$\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{0} \implies \mathbf{X}^\top \mathbf{e} = \mathbf{0}.$$

若 $\mathbf{X}$ 第一列是全 1，则第一条方程给出 $\sum e_i = 0$ ；其他列分别给出残差与各预测变量正交。

14.2 完整书面结论的语言

- 拒绝 H_0 ：“在 $\alpha = 0.05$ 显著性水平下，数据提供充分证据支持……”
- 不能拒绝 H_0 ：“在 $\alpha = 0.05$ 显著性水平下，数据不足以支持……”
- 不写“证明了 H_0 为真”，也不写“接受 H_0 ”。
- CI 解释必须包含参数、置信水平、方向与单位。
- 回归斜率解释必须包含“保持其他变量不变”（多元回归）与响应单位。

15 考前公式总表

15.1 无偏估计与 MSE

$$\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta, \quad \text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + \text{Bias}(\hat{\theta})^2.$$

$$a_{\text{combine}}^* = \frac{v_2 - c}{v_1 + v_2 - 2c}.$$

15.2 均值推断

$$\begin{aligned}\bar{x} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \quad Z &= \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}. \\ \bar{x} \pm t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}, \quad t &= \frac{\bar{x} - \mu_0}{s/\sqrt{n}}. \\ (\bar{x}_1 - \bar{x}_2) \pm z_{\alpha/2} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}. \\ s_p^2 &= \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}, \\ t &= \frac{(\bar{x}_1 - \bar{x}_2) - \Delta_0}{s_p \sqrt{1/n_1 + 1/n_2}}. \\ t_{\text{paired}} &= \frac{\bar{d} - \Delta_0}{s_d/\sqrt{n}}.\end{aligned}$$

15.3 比例推断

$$\begin{aligned}\hat{p} &= \frac{x}{n}, \quad \hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}, \\ Z &= \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)/n}}. \\ (\hat{p}_1 - \hat{p}_2) \pm z_{\alpha/2} \sqrt{\frac{\hat{p}_1(1 - \hat{p}_1)}{n_1} + \frac{\hat{p}_2(1 - \hat{p}_2)}{n_2}}. \\ \hat{p}_{\text{pool}} &= \frac{x_1 + x_2}{n_1 + n_2}, \quad Z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}_{\text{pool}}(1 - \hat{p}_{\text{pool}})(1/n_1 + 1/n_2)}}.\end{aligned}$$

15.4 回归

$$\begin{aligned}\hat{\beta}_1 &= \frac{S_{xy}}{S_{xx}}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}, \\ SSE &= S_{yy} - \frac{S_{xy}^2}{S_{xx}}, \quad s_e^2 = \frac{SSE}{n - 2}. \\ \text{Var}(\hat{\beta}_1) &= \frac{\sigma^2}{S_{xx}}, \quad \text{Var}(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right), \\ \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) &= -\frac{\sigma^2 \bar{x}}{S_{xx}}. \\ \hat{\beta} &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}, \quad \mathbf{X}^\top \mathbf{e} = \mathbf{0}, \\ \text{Var}(\hat{\beta}) &= \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}, \quad s^2 = \frac{SSE}{n - p}. \\ \frac{d}{dx} (\beta_0 + \beta_1 x + \cdots + \beta_q x^q) &= \beta_1 + 2\beta_2 x + \cdots + q\beta_q x^{q-1}. \\ \text{二次模型转折点:} \quad x^* &= -\frac{\beta_1}{2\beta_2}. \\ z = x - c: \quad \gamma_0 &= m(c), \quad \gamma_1 = m'(c), \quad \gamma_2 = \beta_2.\end{aligned}$$

15.5 MLE

$$L(\theta) = \prod_{i=1}^n f(y_i; \theta), \quad \ell(\theta) = \log L(\theta), \quad U(\theta) = \ell'(\theta),$$

$$I_n(\theta) = -E[\ell''(\theta)], \quad \widehat{SE}(\hat{\theta}) = \frac{1}{\sqrt{I_n(\hat{\theta})}}.$$

$$\hat{\theta} \pm z_{\alpha/2} \widehat{SE}(\hat{\theta}).$$

16 最后检查清单

交卷前逐项检查

1. 我是否先定义了参数，而不只是写样本统计量？
2. 单尾还是双尾是否由题意决定，临界值是否放在正确尾部？
3. 未知方差时是否正确使用 t 与自由度？
4. 两样本是独立还是配对？等方差是否有依据？
5. 比例 CI 与比例检验是否使用了正确的标准误？
6. 回归设计矩阵是否含截距列？参数个数 p 是否包括截距？
7. 多元回归系数解释是否写了“保持其他变量不变”？
8. 多元回归证明是否写清 $\mathbf{X}$ 列满秩、含截距、参数个数 p 与残差自由度 $n - p$ ？
9. MLE 是否写了参数空间、score、边界或最大值检查与 Fisher 信息？
10. 最终结论是否联系题目语境与单位，并使用“拒绝/不能拒绝 H_0 ”？

资料核对与暂留问题

本讲义已使用以下材料交叉核对：课程中文讲义、英文讲义、Week 1–14 相关课件、两套 2026 样卷及答案、往年试题中与当前范围相符的部分。

第三张黑板图中额外补写统计量的具体考试含义，等待教师后续确认。确认后应优先核对：

- 它是否只是单样本/双样本未知方差 t 统计量的提示；
- 是否要求额外的总体方差本身推断；
- 是否给定等方差条件，或要求使用其他双样本标准误。