

Statistical Modelling and Inference

课程知识笔记

Based on Spring 2026 lecture slides

2026 年 6 月 15 日

目录

1	统计推断基础	4
1.1	统计推断的目标	4
1.2	样本均值、样本方差与样本比例	4
1.3	估计量、偏差与均方误差	5
1.4	MSE 分解证明	5
1.5	核心无偏估计量与完整证明	6
1.6	线性组合估计量的方差最小化	7
2	单总体均值的置信区间	8
2.1	置信区间的含义	8
2.2	总体方差已知或大样本: z 区间	8
2.3	总体方差未知: t 区间	8
3	单总体均值的假设检验	9
3.1	假设检验的基本元素	9
3.2	z 检验与 t 检验统计量	9
4	两总体均值推断	10
4.1	研究设计: 独立样本 vs 配对样本	10
4.2	独立样本: 大样本正态近似	11
4.3	独立样本: 小样本且方差相等	11
4.4	配对样本	12

5	总体比例推断	12
5.1	单总体比例	12
5.2	两总体比例	13
6	简单线性回归与最小二乘	14
6.1	模型与目标	14
6.2	误差假设	14
6.3	最小二乘估计	15
6.4	残差平方和与误差方差估计	16
6.5	最小二乘线的性质	16
6.6	系数解释	17
6.7	斜率检验	17
6.8	均值响应置信区间与个体预测区间	17
6.9	残差诊断	18
7	多元线性回归与矩阵最小二乘	18
7.1	模型、矩阵形式与系数解释	18
7.2	矩阵最小二乘估计的完整推导	19
7.3	正规方程、投影与残差自由度	20
7.4	多元最小二乘估计量的无偏性与方差	20
8	回归估计量定理与残差性质	21
8.1	模型假设与记号	21
8.2	无偏性的完整证明	22
8.3	方差与协方差推导	22
8.4	平均响应估计量	23
8.5	残差性质与误差方差估计	23
9	相关系数与决定系数	24
9.1	散点图与相关	24
9.2	决定系数 R^2	25
10	最大似然估计	25

10.1 likelihood 的概念	25
10.2 i.i.d. 样本的似然	26
10.3 Bernoulli / coin flip 例子	26
10.4 正态均值的 MLE	27
10.5 正态均值与方差都未知	27
10.6 Poisson 分布的 MLE	28
10.7 Binomial 分布的 MLE	28
10.8 Exponential 分布的 MLE	29
10.9 正态方差的 MLE: 均值已知与未知	30
11 MLE 的 Fisher Information 与渐近推断	30
11.1 定义、可加性与解释	30
11.2 Poisson、Binomial 与 Exponential 的 Fisher information	31
11.3 正态分布的 Fisher information	31
11.4 MLE 的渐近置信区间与临界值检验	32
12 课件勘误与待核对点	33
课程覆盖完成状态	35

当前版本说明

本笔记当前覆盖 slides/ 文件夹中已提供课件的核心知识：

- 无偏估计、偏差与均方误差；
- estimation 与 critical-value hypothesis testing：单总体均值、两总体均值、未知方差与总体比例；
- regression modelling：简单/多元线性回归、最小二乘估计、残差及其性质；
- inference for MLE：Normal、Binomial、Poisson、Exponential 与 Fisher information。

截至 2026-06-15, 本笔记按最新考试范围整理。ANOVA/ANCOVA、R 编程、P-value 与 Power 不纳入笔记。橙色“必须记忆/基石公式”盒表示考试中通常需要直接掌握、不会默认给出的基础公式。

1 统计推断基础

1.1 统计推断的目标

定义 1.1 (统计推断). 统计推断 (statistical inference) 是指：从样本 (sample) 出发，对总体 (population) 的未知参数作出带有不确定性刻画判断。

课程中的基本逻辑可以概括为：

population parameter unknown $\xleftarrow{\text{inference}}$ sample statistic observed.

核心区分：parameter vs statistic

对象	总体量 Parameter	样本量 Statistic
来源	population	sample
是否可直接计算	通常不可	可以由数据计算
是否随机	在频率学派中视为固定未知常数	随样本变化，是随机变量
常见符号	μ, σ, σ^2, p	$\bar{X}, S, S^2, \hat{p}$

1.2 样本均值、样本方差与样本比例

设 $X_1, \dots, X_n$ 是来自总体的样本。常见统计量为

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad (1)$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad (2)$$

$$S = \sqrt{S^2}. \quad (3)$$

若 X 是二分类变量，令 X 表示成功次数，则样本比例

$$\hat{p} = \frac{X}{n}.$$

样本方差的分母

统计推断中最常用的样本方差是 $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ ，因为它是总体方差 σ^2 的无偏估计。若题目或软件输出使用不同定义，必须先确认分母。

1.3 估计量、偏差与均方误差

定义 1.2 (估计量与估计值). 估计量 (estimator) 是根据样本计算参数估计的规则，通常写作 $\hat{\theta} = g(X_1, \dots, X_n)$ ，因此它本身是随机变量。估计值 (estimate) 是把实际观测样本代入后得到的数值。

定义 1.3 (偏差). 设 $\hat{\theta}$ 是参数 θ 的估计量，其偏差定义为

$$B(\hat{\theta}) = E(\hat{\theta}) - \theta.$$

若 $E(\hat{\theta}) = \theta$ ，则称 $\hat{\theta}$ 是 θ 的无偏估计量 (unbiased estimator)；否则称为有偏估计量 (biased estimator)。

定义 1.4 (均方误差). 均方误差 (mean squared error, MSE) 定义为

$$\text{MSE}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2].$$

必须记忆：MSE 分解

$$\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + [B(\hat{\theta})]^2.$$

因此若 $\hat{\theta}$ 无偏，则

$$\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}).$$

1.4 MSE 分解证明

利用恒等式

$$\hat{\theta} - \theta = (\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta) = (\hat{\theta} - E(\hat{\theta})) + B(\hat{\theta}).$$

两边平方并取期望：

$$\text{MSE}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2 + 2(\hat{\theta} - E(\hat{\theta}))B(\hat{\theta}) + B(\hat{\theta})^2] \quad (4)$$

$$= E[(\hat{\theta} - E(\hat{\theta}))^2] + 2B(\hat{\theta}) E[\hat{\theta} - E(\hat{\theta})] + B(\hat{\theta})^2 \quad (5)$$

$$= \text{Var}(\hat{\theta}) + B(\hat{\theta})^2, \quad (6)$$

因为 $E[\hat{\theta} - E(\hat{\theta})] = 0$ 。

1.5 核心无偏估计量与完整证明

必须记忆：期望与方差运算

对常数 a, b 与随机变量 X, Y ,

$$\mathbb{E}(aX + b) = a \mathbb{E}(X) + b.$$

$$\text{Var}(aX + b) = a^2 \text{Var}(X).$$

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y).$$

若 X, Y 独立, 则 $\text{Cov}(X, Y) = 0$ 。

设 $X_1, \dots, X_n$ i.i.d., 且

$$\mathbb{E}(X_i) = \mu, \quad \text{Var}(X_i) = \sigma^2.$$

样本均值满足

$$\mathbb{E}(\bar{X}) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i) = \mu,$$

因此 $\bar{X}$ 是 μ 的无偏估计量。由独立性,

$$\text{Var}(\bar{X}) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{\sigma^2}{n}.$$

若 $X_i \sim \text{Bernoulli}(p)$, 则 $\hat{p} = \bar{X}$, 所以

$$\mathbb{E}(\hat{p}) = p, \quad \text{Var}(\hat{p}) = \frac{p(1-p)}{n}.$$

必须记忆：样本均值、样本比例与样本方差

$$\mathbb{E}(\bar{X}) = \mu, \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

$$\mathbb{E}(\hat{p}) = p, \quad \text{Var}(\hat{p}) = \frac{p(1-p)}{n}.$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad \mathbb{E}(S^2) = \sigma^2.$$

样本方差定义为

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

使用恒等式

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2,$$

取期望得到

$$\mathbb{E}\left[\sum_{i=1}^n (X_i - \bar{X})^2\right] = \sum_{i=1}^n \mathbb{E}[(X_i - \mu)^2] - n \mathbb{E}[(\bar{X} - \mu)^2] \quad (7)$$

$$= n\sigma^2 - n \operatorname{Var}(\bar{X}) \quad (8)$$

$$= n\sigma^2 - \sigma^2 = (n-1)\sigma^2. \quad (9)$$

因此这证明了 $E(S^2) = \sigma^2$ ，也解释了无偏样本方差为何使用分母 $n-1$ 。

必须记忆：由已知偏差构造无偏估计量

若

$$E(\hat{\theta}) = a\theta + b, \quad a \neq 0,$$

则

$$\hat{\theta}^* = \frac{\hat{\theta} - b}{a}$$

满足 $E(\hat{\theta}^*) = \theta$ ，因此是 θ 的无偏估计量。

1.6 线性组合估计量的方差最小化

课件 Exercise 5 涉及两个无偏估计量的加权组合。设

$$E(\hat{\theta}_1) = E(\hat{\theta}_2) = \theta, \quad \operatorname{Var}(\hat{\theta}_1) = \sigma_1^2, \quad \operatorname{Var}(\hat{\theta}_2) = \sigma_2^2,$$

并定义

$$\hat{\theta}_3 = a\hat{\theta}_1 + (1-a)\hat{\theta}_2.$$

则

$$E(\hat{\theta}_3) = a\theta + (1-a)\theta = \theta,$$

所以任意 a 下 $\hat{\theta}_3$ 仍是无偏估计量。

必须记忆：独立情形的最优权重

若 $\hat{\theta}_1, \hat{\theta}_2$ 独立，则

$$\operatorname{Var}(\hat{\theta}_3) = a^2\sigma_1^2 + (1-a)^2\sigma_2^2.$$

使方差最小的权重为

$$a^* = \frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2}.$$

这表示方差较小的估计量应获得更大的权重。

必须记忆：非独立情形的最优权重

若 $\operatorname{Cov}(\hat{\theta}_1, \hat{\theta}_2) = c$ ，则

$$\operatorname{Var}(\hat{\theta}_3) = a^2\sigma_1^2 + (1-a)^2\sigma_2^2 + 2a(1-a)c,$$

最优权重为

$$a^* = \frac{\sigma_2^2 - c}{\sigma_1^2 + \sigma_2^2 - 2c}.$$

2 单总体均值的置信区间

2.1 置信区间的含义

对总体均值 μ ，置信区间通常写作

$$\text{estimate} \pm \text{margin of error}.$$

其频率学派解释是：如果反复抽样并用同一规则构造区间，则约有 $(1 - \alpha)100\%$ 的区间会覆盖真实参数 μ 。

置信区间的常见误解

构造出一个具体区间后，真实参数 μ 在频率学派中不是随机变量。因此严格说法不是“ μ 有 95% 概率落在这个已给定区间内”，而是“该构造规则有 95% 的长期覆盖率”。

2.2 总体方差已知或大样本： z 区间

若总体标准差 σ 已知，且

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right),$$

则

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1).$$

必须记忆：单总体均值 z 置信区间

常用临界值：

$1 - \alpha$	0.90	0.95	0.99
$z_{\alpha/2}$	1.645	1.960	2.576

$$\bar{X} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}.$$

2.3 总体方差未知： t 区间

实际问题中 σ 往往未知，用样本标准差 s 估计。若样本来自正态总体，或样本量足够大，则可使用

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

必须记忆：单总体均值 t 置信区间

$$\bar{X} \pm t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}.$$

其中自由度为 $\nu = n - 1$ 。

选择 z 还是 t

- σ 已知，或题目明确要求大样本正态近似：用 z 。
- σ 未知且用样本标准差 s ：通常用 t 。
- 样本量很大时， t 分布接近标准正态，但写作 t 往往更严谨。

3 单总体均值的假设检验

3.1 假设检验的基本元素

定义 3.1 (统计假设). 统计假设是关于一个或多个总体参数的命题。

假设检验通常包含：

- 原假设 H_0 ：被检验的基准命题，通常含有等号；
- 备择假设 H_a ：与 H_0 对立的命题，可为单侧或双侧；
- 检验统计量：衡量样本结果与 H_0 差距的标准化量；
- 拒绝域：使我们拒绝 H_0 的统计量取值范围；
- 显著性水平 α ：在 H_0 为真时错误拒绝 H_0 的概率上限。

结论措辞

课件中有时写“accept H_0 ”。更严谨的统计表达是“fail to reject H_0 ”（不拒绝原假设）。不拒绝并不等于证明 H_0 为真，只表示当前数据证据不足。

3.2 z 检验与 t 检验统计量

检验

$$H_0 : \mu = \mu_0$$

时，若 σ 已知，使用

$$z_{\text{obs}} = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}.$$

若 σ 未知，使用

$$t_{\text{obs}} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}, \quad \nu = n - 1.$$

必须记忆：单总体均值检验统计量与拒绝域

备择假设	z 检验拒绝域	t 检验拒绝域
$H_a: \mu > \mu_0$	$z_{\text{obs}} \geq z_\alpha$	$t_{\text{obs}} \geq t_{\alpha, \nu}$
$H_a: \mu < \mu_0$	$z_{\text{obs}} \leq -z_\alpha$	$t_{\text{obs}} \leq -t_{\alpha, \nu}$
$H_a: \mu \neq \mu_0$	$ z_{\text{obs}} \geq z_{\alpha/2}$	$ t_{\text{obs}} \geq t_{\alpha/2, \nu}$

必须记忆：临界值法的一般拒绝规则

设标准化检验统计量为 T_{obs} ，其在 H_0 下服从对称分布，临界值记为 c_α 或 $c_{\alpha/2}$ ：

备择假设	拒绝 H_0 的条件
$H_a: \theta > \theta_0$	$T_{\text{obs}} \geq c_\alpha$
$H_a: \theta < \theta_0$	$T_{\text{obs}} \leq -c_\alpha$
$H_a: \theta \neq \theta_0$	$ T_{\text{obs}} \geq c_{\alpha/2}$

使用正态近似时 $c = z$ ；使用未知方差的小样本均值检验时 $c = t_\nu$ 。

假设检验书写模板

1. 写出 H_0, H_a ，确认单侧还是双侧；
2. 选择显著性水平 α ；
3. 写出检验统计量公式并代入数值；
4. 写出对应临界值和拒绝域，用临界值法作决策；
5. 用题目语境写结论，例如“在 5% 显著性水平下，有/没有足够证据表明……”

4 两总体均值推断

4.1 研究设计：独立样本 vs 配对样本

先判断数据结构

- 独立样本 (independent samples)：两组单位不同，例如 Treatment 组和 Control 组是不同的人；
- 配对样本 (paired samples / crossover design)：同一对象接受两个处理，或天然成对，例如 before/after、左右眼、匹配个体。

判断错数据结构会直接导致标准误、自由度和检验统计量错误。

4.2 独立样本：大样本正态近似

设两个总体均值为 μ_1, μ_2 ，参数为 $\mu_1 - \mu_2$ 。估计量为

$$\bar{Y}_1 - \bar{Y}_2.$$

大样本下，其标准误估计为

$$\widehat{\text{SE}}(\bar{Y}_1 - \bar{Y}_2) = \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}.$$

必须记忆：大样本两独立均值检验

检验

$$H_0 : \mu_1 - \mu_2 = \Delta_0$$

时，

$$z_{\text{obs}} = \frac{(\bar{y}_1 - \bar{y}_2) - \Delta_0}{\sqrt{S_1^2/n_1 + S_2^2/n_2}}.$$

必须记忆：大样本两独立均值置信区间

$$(\bar{y}_1 - \bar{y}_2) \pm z_{\alpha/2} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}.$$

4.3 独立样本：小样本且方差相等

若两个总体近似正态，且可假设共同方差

$$\sigma_1^2 = \sigma_2^2 = \sigma^2,$$

则使用合并方差估计量

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}.$$

自由度为

$$\nu = n_1 + n_2 - 2.$$

必须记忆：pooled two-sample t 检验

$$t_{\text{obs}} = \frac{(\bar{y}_1 - \bar{y}_2) - \Delta_0}{\sqrt{S_p^2(1/n_1 + 1/n_2)}}.$$

必须记忆：pooled two-sample t 区间

$$(\bar{y}_1 - \bar{y}_2) \pm t_{\alpha/2, n_1 + n_2 - 2} \sqrt{S_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}.$$

方差相等假设

当前 Week 2 Lecture 2 课件主要给出 common variance 的小样本公式。若题目没有方差相等假设，实际应用中常用 Welch two-sample t 方法，其自由度由 Welch-Satterthwaite 公式近似给出。写作业时应根据题目要求和课堂覆盖范围选择。

4.4 配对样本

配对样本把两组观测转化为差值：

$$d_i = \text{Trt1}_i - \text{Trt2}_i, \quad i = 1, \dots, n.$$

于是问题变成单总体均值推断：

$$H_0 : \mu_d = \Delta_0.$$

差值样本均值与方差为

$$\bar{d} = \frac{1}{n} \sum_{i=1}^n d_i, \quad s_d^2 = \frac{1}{n-1} \sum_{i=1}^n (d_i - \bar{d})^2.$$

必须记忆：配对样本 t 检验与区间

$$t_{\text{obs}} = \frac{\bar{d} - \Delta_0}{s_d / \sqrt{n}}, \quad \nu = n - 1.$$

$$\bar{d} \pm t_{\alpha/2, n-1} \frac{s_d}{\sqrt{n}}.$$

独立样本与配对样本的快速识别

如果题目中的每个个体都有两个结果，优先考虑配对样本；如果两组由不同个体组成，优先考虑独立样本。配对样本绝不能直接当作两独立样本处理，否则会丢失“个体内对照”信息。

5 总体比例推断

5.1 单总体比例

设 X 是样本中“成功”的个数， $X \sim \text{Binomial}(n, p)$ ，样本比例

$$\hat{p} = \frac{X}{n}.$$

大样本下

$$\hat{p} \approx N\left(p, \frac{p(1-p)}{n}\right).$$

必须记忆：单总体比例置信区间

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}.$$

必须记忆：单总体比例检验

检验

$$H_0 : p = p_0$$

时，标准误应在 H_0 下计算：

$$z_{\text{obs}} = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}.$$

比例推断中的两个标准误

置信区间通常使用 $\hat{p}$ 代入标准误；检验 $H_0 : p = p_0$ 时通常使用 p_0 代入标准误。这是很多题目中最容易混淆的地方。

5.2 两总体比例

设两组样本比例为

$$\hat{p}_1 = \frac{X_1}{n_1}, \quad \hat{p}_2 = \frac{X_2}{n_2}.$$

目标参数通常为

$$p_1 - p_2.$$

必须记忆：两总体比例差的置信区间

$$(\hat{p}_1 - \hat{p}_2) \pm z_{\alpha/2} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}.$$

检验最常见的原假设是

$$H_0 : p_1 - p_2 = 0.$$

此时在 H_0 下认为两组比例相同，因此使用 pooled proportion

$$\hat{p} = \frac{X_1 + X_2}{n_1 + n_2}.$$

必须记忆：两总体比例差检验

$$z_{\text{obs}} = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1-\hat{p})(1/n_1 + 1/n_2)}}.$$

比例题步骤

1. 找出成功次数 X 和样本量 n ，计算 $\hat{p} = X/n$ ；
2. 判断是单总体比例还是两总体比例；
3. 置信区间用样本比例标准误；
4. 检验用原假设下的标准误，尤其两比例相等检验要用 pooled proportion；
5. 结论用“比例/百分比”语境表达。

关于 Week 3 Lecture 2

Week 3 Lecture 2 的部分公式页在 PDF 文本抽取中显示不完整，但标题与上下文明确指向单总体/两总体比例的置信区间和假设检验。本节公式按标准大样本比例推断规则补全，后续若拿到更清晰课件或课堂板书，应再核对一次。

6 简单线性回归与最小二乘

6.1 模型与目标

简单线性回归研究一个解释变量 X 与一个响应变量 Y 的线性关系：

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, \dots, n.$$

其中：

- Y_i : dependent / response variable;
- X_i : independent / predictor variable;
- β_0 : 截距;
- β_1 : 斜率;
- ε_i : 随机误差。

简单线性回归的含义

“简单”指只有一个解释变量；“线性”主要指参数线性，即参数不互相相乘、不作为指数、不出现在分母中。

6.2 误差假设

课程课件列出的基本假设包括：

1. 误差 ε_i 相互独立；
2. 对任意给定 x ，误差近似正态；

3. $E(\varepsilon_i) = 0$;
4. $\text{Var}(\varepsilon_i) = \sigma^2$, 即常方差;
5. X 与 Y 的底层关系近似线性。

回归与因果

回归和相关可以描述关联, 但单凭回归模型本身不能证明因果关系。要谈因果, 需要实验设计、随机化、控制混杂因素等额外条件。

6.3 最小二乘估计

拟合直线写作

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i,$$

残差为

$$e_i = Y_i - \hat{Y}_i.$$

最小二乘法选择 $\hat{\beta}_0, \hat{\beta}_1$ 使残差平方和最小:

$$\text{SSE} = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2.$$

对候选系数 b_0, b_1 定义

$$Q(b_0, b_1) = \sum_{i=1}^n (Y_i - b_0 - b_1 X_i)^2.$$

对两参数求偏导并令其为零:

$$\frac{\partial Q}{\partial b_0} = -2 \sum_{i=1}^n (Y_i - b_0 - b_1 X_i) = 0,$$

$$\frac{\partial Q}{\partial b_1} = -2 \sum_{i=1}^n X_i (Y_i - b_0 - b_1 X_i) = 0.$$

第一条正规方程给出

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}.$$

将其代入第二条正规方程:

$$\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) = \hat{\beta}_1 \sum_{i=1}^n (X_i - \bar{X})^2,$$

所以

$$\hat{\beta}_1 = \frac{\sum_i (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_i (X_i - \bar{X})^2}.$$

定义

$$SS_x = \sum_{i=1}^n (X_i - \bar{X})^2 = \sum X_i^2 - \frac{(\sum X_i)^2}{n}, \quad (10)$$

$$SS_y = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum Y_i^2 - \frac{(\sum Y_i)^2}{n}, \quad (11)$$

$$SS_{xy} = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) = \sum X_i Y_i - \frac{(\sum X_i)(\sum Y_i)}{n}. \quad (12)$$

必须记忆：最小二乘直线

$$\hat{\beta}_1 = \frac{SS_{xy}}{SS_x}, \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}.$$

因此

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X.$$

6.4 残差平方和与误差方差估计

必须记忆：简单回归的 SSE 与误差方差

$$SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = SS_y - \frac{SS_{xy}^2}{SS_x}.$$

由于估计了两个参数 β_0, β_1 ，误差方差用 $n - 2$ 个自由度估计：

$$s_\varepsilon^2 = \frac{SSE}{n - 2} = \text{MSE}, \quad s_\varepsilon = \sqrt{s_\varepsilon^2}.$$

手算最小二乘题

1. 先列出 $\sum x, \sum y, \sum x^2, \sum y^2, \sum xy, n$;
2. 计算 SS_x, SS_y, SS_{xy} ;
3. 计算 $\hat{\beta}_1 = SS_{xy}/SS_x$ 与 $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$;
4. 写出回归线 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$;
5. 若要求误差估计，计算 $SSE = SS_y - SS_{xy}^2/SS_x$ 和 $s_\varepsilon = \sqrt{SSE/(n - 2)}$ 。

6.5 最小二乘线的性质

在含截距的简单线性回归中：

$$\sum_{i=1}^n e_i = 0, \quad (13)$$

$$\sum_{i=1}^n X_i e_i = 0. \quad (14)$$

因此最小二乘直线必经过点 $(\bar{X}, \bar{Y})$ 。在标准线性模型假设下， $\hat{\beta}_0, \hat{\beta}_1$ 是 β_0, β_1 的无偏估计量。

6.6 系数解释

- $\hat{\beta}_1$: X 每增加 1 个单位, Y 的预测均值平均改变 $\hat{\beta}_1$ 个单位。
- $\hat{\beta}_0$: $X = 0$ 时 Y 的预测均值; 若 $X = 0$ 不在数据范围内或无实际意义, 不应作实质解释。

例 6.1 (教育年限与收入). 课件例子中 $\hat{y} = -13.93 + 3.74x$, 其中 y 为收入 (千美元), x 为教育年限。斜率 3.74 表示教育年限每增加一年, 预测收入平均增加约 3.74 千美元。截距 -13.93 对“0 年教育”的收入解释在现实中没有太大意义。

6.7 斜率检验

判断 X 与 Y 是否存在线性关系, 通常检验

$$H_0: \beta_1 = 0.$$

斜率估计量的标准误为

$$s_{\hat{\beta}_1} = \frac{s_\varepsilon}{\sqrt{SS_x}}.$$

必须记忆: 斜率 t 检验

$$t_{\text{obs}} = \frac{\hat{\beta}_1 - \beta_{1,0}}{s_{\hat{\beta}_1}}, \quad \nu = n - 2.$$

常见双侧检验为 $H_0: \beta_1 = 0$ vs $H_a: \beta_1 \neq 0$ 。

必须记忆: 斜率置信区间

$$\hat{\beta}_1 \pm t_{\alpha/2, n-2} s_{\hat{\beta}_1}.$$

6.8 均值响应置信区间与个体预测区间

给定新点 x_g , 预测值为

$$\hat{y}_g = \hat{\beta}_0 + \hat{\beta}_1 x_g.$$

必须记忆: 均值响应的置信区间

用于估计所有 $X = x_g$ 个体的平均响应 $E(Y | X = x_g)$:

$$\hat{y}_g \pm t_{\alpha/2, n-2} s_\varepsilon \sqrt{\frac{1}{n} + \frac{(x_g - \bar{x})^2}{SS_x}}.$$

必须记忆：单个新观测的预测区间

用于预测一个具体新个体的 Y ：

$$\hat{y}_g \pm t_{\alpha/2, n-2} s_\varepsilon \sqrt{1 + \frac{1}{n} + \frac{(x_g - \bar{x})^2}{SS_x}}.$$

预测区间一定更宽

预测单个个体时多了一个新的随机误差，所以根号内比均值响应区间多一个 1。因此同一置信水平下，prediction interval 一定比 confidence interval for mean response 更宽。

6.9 残差诊断

残差分析用于检查模型假设：

- 残差 vs x 图：检查线性关系与常方差；
- 残差直方图或 QQ 图：检查误差正态性；
- 异常点与高杠杆点：可能显著影响拟合线。

看残差图的直觉

- 随机云状分布：线性与常方差假设较合理；
- 明显曲线模式：可能非线性；
- 漏斗形扩散：可能异方差；
- 少数点远离主体：可能存在异常值或高影响点。

7 多元线性回归与矩阵最小二乘

7.1 模型、矩阵形式与系数解释

当响应变量 Y 同时由 k 个解释变量描述时，多元线性回归模型为

$$Y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + \varepsilon_i, \quad i = 1, \dots, n.$$

令 $p = k + 1$ 表示包含截距在内的参数个数，则矩阵形式为

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

其中

$$\mathbf{y} \in \mathbb{R}^{n \times 1}, \quad \mathbf{X} \in \mathbb{R}^{n \times p}, \quad \boldsymbol{\beta} \in \mathbb{R}^{p \times 1}, \quad \boldsymbol{\varepsilon} \in \mathbb{R}^{n \times 1}.$$

含截距模型的设计矩阵第一列全为 1:

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1k} \\ 1 & x_{21} & \cdots & x_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{nk} \end{pmatrix}.$$

偏回归系数的解释

在模型其他解释变量保持不变时, x_j 每增加一个单位, 条件均值 $E(Y | x_1, \dots, x_k)$ 改变 β_j 个单位。这个 “holding other variables constant” 条件是多元回归系数解释与简单回归系数解释的核心差别。

通常假设

$$E(\boldsymbol{\varepsilon}) = \mathbf{0}, \quad \text{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}_n.$$

若还假设 $\boldsymbol{\varepsilon} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$, 则可进行精确的正态理论推断。

7.2 矩阵最小二乘估计的完整推导

最小二乘法选择 $\mathbf{b}$ 使

$$S(\mathbf{b}) = (\mathbf{y} - \mathbf{X}\mathbf{b})^\top (\mathbf{y} - \mathbf{X}\mathbf{b})$$

最小。展开:

$$S(\mathbf{b}) = \mathbf{y}^\top \mathbf{y} - 2\mathbf{b}^\top \mathbf{X}^\top \mathbf{y} + \mathbf{b}^\top \mathbf{X}^\top \mathbf{X} \mathbf{b}.$$

对 $\mathbf{b}$ 求梯度并令其为零:

$$\frac{\partial S}{\partial \mathbf{b}} = -2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X} \mathbf{b} = \mathbf{0}.$$

因此正规方程为

$$\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}.$$

若 $\mathbf{X}$ 满列秩, 使 $\mathbf{X}^\top \mathbf{X}$ 可逆, 则

必须记忆: 多元回归矩阵最小二乘

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

$$\hat{\mathbf{y}} = \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{H} \mathbf{y}, \quad \mathbf{H} = \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top.$$

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = (\mathbf{I}_n - \mathbf{H}) \mathbf{y}.$$

不能直接删去误差项

课件矩阵演示中从 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ 写到 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta}$ 容易造成误解。观测数据一般不会恰好满足 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta}$; 正规方程必须由最小化残差平方和得到, 而不是把随机误差直接设为零。

满列秩与完全多重共线性

若设计矩阵某一列能由其他列精确线性表示，则 $\mathbf{X}$ 不满列秩， $\mathbf{X}^\top \mathbf{X}$ 不可逆，系数不能用普通逆矩阵唯一确定。常见原因包括重复变量、冗余虚拟变量或同时放入一个变量及其精确线性组合。

7.3 正规方程、投影与残差自由度

由正规方程可得

$$\mathbf{X}^\top \mathbf{e} = \mathbf{0}.$$

因此残差向量与设计矩阵每一列正交。若模型含截距，设计矩阵含全 1 列，故

$$\sum_{i=1}^n e_i = 0.$$

hat matrix 满足

$$\mathbf{H}^\top = \mathbf{H}, \quad \mathbf{H}^2 = \mathbf{H},$$

所以 $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ 是 $\mathbf{y}$ 在 $\mathbf{X}$ 列空间上的正交投影。

必须记忆：多元回归误差方差估计

若 $\mathbf{X}$ 满列秩且参数个数为 $p = k + 1$ ，则

$$\text{SSE} = \mathbf{e}^\top \mathbf{e}, \quad s^2 = \frac{\text{SSE}}{n - p}.$$

残差自由度为 $n - p$ ；简单线性回归中 $p = 2$ ，故退化为 $n - 2$ 。

7.4 多元最小二乘估计量的无偏性与方差

由模型和最小二乘公式，

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}) = \boldsymbol{\beta} + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \boldsymbol{\varepsilon}.$$

对两边取期望，并使用 $E(\boldsymbol{\varepsilon}) = \mathbf{0}$ ：

$$E(\hat{\boldsymbol{\beta}}) = \boldsymbol{\beta} + (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top E(\boldsymbol{\varepsilon}) = \boldsymbol{\beta}.$$

因此多元最小二乘估计量是无偏的。进一步，

$$\text{Var}(\hat{\boldsymbol{\beta}}) = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \text{Var}(\boldsymbol{\varepsilon}) \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \quad (15)$$

$$= \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}. \quad (16)$$

必须记忆：多元最小二乘估计量性质

$$E(\hat{\beta}) = \beta.$$

$$\text{Var}(\hat{\beta}) = \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}.$$

Week 5 Lecture 2 范围说明

本节吸收 Week 5 Lecture 2 的 multiple linear regression 与 matrix least squares 内容。课件末尾的 ANOVA summary 和整体显著性检验不纳入本笔记。

8 回归估计量定理与残差性质

8.1 模型假设与记号

Week 9 的核心是最小二乘估计量的性质。这里把解释变量 x_i 视为固定数，响应变量 Y_i 随机，并假设

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad E(\varepsilon_i) = 0, \quad \text{Var}(\varepsilon_i) = \sigma^2,$$

且 $\varepsilon_1, \dots, \varepsilon_n$ 相互独立。等价地，

$$E(Y_i) = \beta_0 + \beta_1 x_i, \quad \text{Var}(Y_i) = \sigma^2.$$

仍记

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2, \quad S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y}).$$

因为 $\sum_{i=1}^n (x_i - \bar{x}) = 0$ ，也有

$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})Y_i.$$

必须记忆：简单线性回归估计量性质

$$E(\hat{\beta}_0) = \beta_0, \quad E(\hat{\beta}_1) = \beta_1.$$

$$\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}}.$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right).$$

$$\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\frac{\sigma^2 \bar{x}}{S_{xx}}.$$

8.2 无偏性的完整证明

令

$$a_i = \frac{x_i - \bar{x}}{S_{xx}}.$$

由于

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \sum_{i=1}^n \frac{x_i - \bar{x}}{S_{xx}} Y_i = \sum_{i=1}^n a_i Y_i,$$

我们先计算两个关键和：

$$\sum_{i=1}^n a_i = \frac{1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) = 0,$$

$$\sum_{i=1}^n a_i x_i = \frac{1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) x_i = \frac{1}{S_{xx}} \sum_{i=1}^n (x_i - \bar{x}) ((x_i - \bar{x}) + \bar{x}) = \frac{S_{xx}}{S_{xx}} = 1.$$

因此

$$E(\hat{\beta}_1) = \sum_{i=1}^n a_i E(Y_i) \quad (17)$$

$$= \sum_{i=1}^n a_i (\beta_0 + \beta_1 x_i) \quad (18)$$

$$= \beta_0 \sum_{i=1}^n a_i + \beta_1 \sum_{i=1}^n a_i x_i \quad (19)$$

$$= 0 + \beta_1 = \beta_1. \quad (20)$$

这证明了 $\hat{\beta}_1$ 是 β_1 的无偏估计量。

又因为

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x},$$

且

$$E(\bar{Y}) = \frac{1}{n} \sum_{i=1}^n E(Y_i) = \frac{1}{n} \sum_{i=1}^n (\beta_0 + \beta_1 x_i) = \beta_0 + \beta_1 \bar{x},$$

所以

$$E(\hat{\beta}_0) = E(\bar{Y}) - \bar{x} E(\hat{\beta}_1) \quad (21)$$

$$= (\beta_0 + \beta_1 \bar{x}) - \bar{x} \beta_1 \quad (22)$$

$$= \beta_0. \quad (23)$$

这证明了 $\hat{\beta}_0$ 是 β_0 的无偏估计量。

8.3 方差与协方差推导

由独立性和 $\hat{\beta}_1 = \sum a_i Y_i$,

$$\text{Var}(\hat{\beta}_1) = \sum_{i=1}^n a_i^2 \text{Var}(Y_i) = \sigma^2 \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{S_{xx}^2} = \frac{\sigma^2}{S_{xx}}.$$

同时

$$\text{Var}(\bar{Y}) = \text{Var}\left(\frac{1}{n} \sum Y_i\right) = \frac{\sigma^2}{n}.$$

并且

$$\text{Cov}(\bar{Y}, \hat{\beta}_1) = \text{Cov}\left(\frac{1}{n} \sum_i Y_i, \sum_j a_j Y_j\right) = \frac{1}{n} \sum_i a_i \text{Var}(Y_i) = \frac{\sigma^2}{n} \sum_i a_i = 0.$$

于是

$$\text{Var}(\hat{\beta}_0) = \text{Var}(\bar{Y} - \bar{x}\hat{\beta}_1) \quad (24)$$

$$= \text{Var}(\bar{Y}) + \bar{x}^2 \text{Var}(\hat{\beta}_1) - 2\bar{x} \text{Cov}(\bar{Y}, \hat{\beta}_1) \quad (25)$$

$$= \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right). \quad (26)$$

最后,

$$\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = \text{Cov}(\bar{Y} - \bar{x}\hat{\beta}_1, \hat{\beta}_1) = 0 - \bar{x} \text{Var}(\hat{\beta}_1) = -\frac{\sigma^2 \bar{x}}{S_{xx}}.$$

8.4 平均响应估计量

给定 x_0 , 平均响应 $E(Y | X = x_0) = \beta_0 + \beta_1 x_0$ 的估计量为

$$\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0.$$

必须记忆：平均响应估计量性质

$$E(\hat{\beta}_0 + \hat{\beta}_1 x_0) = \beta_0 + \beta_1 x_0.$$

$$\text{Var}(\hat{\beta}_0 + \hat{\beta}_1 x_0) = \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right].$$

证明直接代入上一节的方差、协方差：

$$\text{Var}(\hat{\beta}_0 + \hat{\beta}_1 x_0) = \text{Var}(\hat{\beta}_0) + x_0^2 \text{Var}(\hat{\beta}_1) + 2x_0 \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) \quad (27)$$

$$= \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right) + x_0^2 \frac{\sigma^2}{S_{xx}} - 2x_0 \frac{\sigma^2 \bar{x}}{S_{xx}} \quad (28)$$

$$= \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]. \quad (29)$$

8.5 残差性质与误差方差估计

残差记为

$$e_i = Y_i - \hat{Y}_i = Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i.$$

必须记忆：残差性质

$$\sum_{i=1}^n e_i = 0, \quad \sum_{i=1}^n x_i e_i = 0.$$

$$E(e_i) = 0.$$

$$\text{Var}(e_i) = \sigma^2 \left[1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{S_{xx}} \right].$$

前两个等式来自最小二乘正规方程：最小化 $\sum e_i^2$ 对 $\hat{\beta}_0, \hat{\beta}_1$ 求偏导并令其为 0，得到

$$\sum e_i = 0, \quad \sum x_i e_i = 0.$$

令简单线性回归的设计矩阵为 $\mathbf{X} = (\mathbf{1}, \mathbf{x})$ ，hat matrix 为

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top.$$

因为 $\mathbf{H}\mathbf{X} = \mathbf{X}$,

$$\mathbf{e} = (\mathbf{I} - \mathbf{H})\mathbf{Y} = (\mathbf{I} - \mathbf{H})(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}) = (\mathbf{I} - \mathbf{H})\boldsymbol{\varepsilon}.$$

所以

$$E(\mathbf{e}) = (\mathbf{I} - \mathbf{H})E(\boldsymbol{\varepsilon}) = \mathbf{0}.$$

又因为 $\mathbf{H}$ 对称且幂等，

$$\text{Var}(\mathbf{e}) = (\mathbf{I} - \mathbf{H})\sigma^2 \mathbf{I}(\mathbf{I} - \mathbf{H})^\top \quad (30)$$

$$= \sigma^2(\mathbf{I} - \mathbf{H}). \quad (31)$$

hat matrix 的第 i 个对角元为

$$h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}$$

，因此

$$\text{Var}(e_i) = \sigma^2(1 - h_{ii}).$$

必须记忆：误差方差估计

$$s_e^2 = \frac{\text{SSE}}{n-2} = \frac{1}{n-2} (S_{yy} - \hat{\beta}_1 S_{xy}).$$

$$s_e = \sqrt{s_e^2}.$$

$n-2$ 的原因是简单线性回归中估计了两个参数 β_0, β_1 ，残差自由度为 $n-2$ 。

9 相关系数与决定系数

9.1 散点图与相关

散点图用于直观展示两个变量之间的关系。相关分析衡量的是线性关联强度，不表示因果。

定义 9.1 (相关系数). 总体相关系数记为 ρ , 样本相关系数记为 r 。样本相关系数衡量样本中 X, Y 的线性关系强度:

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} = \frac{SS_{xy}}{\sqrt{SS_x SS_y}}.$$

等价计算式为

$$r = \frac{n \sum xy - (\sum x)(\sum y)}{\sqrt{[n \sum x^2 - (\sum x)^2][n \sum y^2 - (\sum y)^2]}}.$$

相关系数性质

- $-1 \leq r \leq 1$;
- r 越接近 1, 正线性关系越强;
- r 越接近 -1, 负线性关系越强;
- r 越接近 0, 线性关系越弱;
- r 无单位。

9.2 决定系数 R^2

总平方和、回归平方和、误差平方和满足

$$SST = SSR + SSE.$$

必须记忆: 决定系数

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}.$$

定义 9.2 (决定系数). R^2 表示响应变量总变异中, 由回归模型解释的比例。其范围为

$$0 \leq R^2 \leq 1.$$

在只有一个解释变量的简单线性回归中,

$$R^2 = r^2.$$

解释 R^2

$R^2 = 65\%$ 的意思是: 样本中 Y 的总变异约有 65% 可由模型中的 X 线性解释。它不表示“预测一定有 65% 准确”, 也不自动证明因果。

10 最大似然估计

10.1 likelihood 的概念

最大似然估计 (maximum likelihood estimation, MLE) 的基本思想是: 已经观察到的数据发生了, 因此选择让这些数据“最可能发生”的参数值。

设参数为 θ ，观察到事件或样本 E 。似然函数写作

$$\mathcal{L}(E; \theta).$$

它表示在参数规则为 θ 时观察到 E 的概率或密度值。最大似然估计量为

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \mathcal{L}(E; \theta).$$

likelihood 不是普通概率

$P(X | Y)$ 表示在事件 Y 已发生条件下 X 的条件概率； $P(X; \theta)$ 表示概率空间由参数 θ 决定。 θ 是参数，不是事件，所以 $\mathcal{L}(X; \theta)$ 不是“给定 θ 事件发生”的条件概率。固定数据后，likelihood 是关于 θ 的函数，不要求对所有 θ 求和/积分为 1。

10.2 i.i.d. 样本的似然

必须记忆：likelihood 与 log-likelihood

若 $X_1, \dots, X_n$ 独立同分布：

$$\mathcal{L}(\theta) = \prod_{i=1}^n P(X_i = x_i; \theta) \quad \text{离散型。}$$

$$\mathcal{L}(\theta) = \prod_{i=1}^n f_X(x_i; \theta) \quad \text{连续型。}$$

由于 $\log$ 是严格递增函数，

$$\arg \max_{\theta} \mathcal{L}(\theta) = \arg \max_{\theta} \ell(\theta), \quad \ell(\theta) = \log \mathcal{L}(\theta).$$

MLE 标准步骤

1. 写出 likelihood $\mathcal{L}(\theta)$;
2. 为简化乘积，取 $\log$ 得到 log-likelihood $\ell(\theta)$;
3. 对参数求导，令一阶导数为 0;
4. 解出候选点；
5. 检查二阶导数、端点或参数空间限制，确认最大值。

10.3 Bernoulli / coin flip 例子

设抛硬币 n 次，正面概率为 θ ，观察到 x 次正面，则

$$\mathcal{L}(\theta) = \theta^x (1 - \theta)^{n-x}, \quad 0 \leq \theta \leq 1.$$

log-likelihood 为

$$\ell(\theta) = x \log \theta + (n - x) \log(1 - \theta).$$

求导:

$$\ell'(\theta) = \frac{x}{\theta} - \frac{n - x}{1 - \theta}.$$

令其为 0:

$$\frac{x}{\hat{\theta}} = \frac{n - x}{1 - \hat{\theta}} \implies x(1 - \hat{\theta}) = (n - x)\hat{\theta} \implies \boxed{\hat{\theta}_{\text{MLE}} = \frac{x}{n}}.$$

课件例子中 10 次抛硬币观测到 6 次 heads, 因此

$$\hat{\theta}_{\text{MLE}} = \frac{6}{10} = \frac{3}{5}.$$

10.4 正态均值的 MLE

若 $X_1, \dots, X_n$ 独立来自 $N(\mu, 1)$, 其中 μ 未知, 则

$$\mathcal{L}(\mu) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp \left[-\frac{1}{2}(x_i - \mu)^2 \right].$$

忽略与 μ 无关的常数, log-likelihood 等价于

$$\ell(\mu) = -\frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2 + \text{constant}.$$

求导:

$$\ell'(\mu) = \sum_{i=1}^n (x_i - \mu).$$

令其为 0:

$$\sum_{i=1}^n (x_i - \hat{\mu}) = 0 \implies \boxed{\hat{\mu}_{\text{MLE}} = \bar{x}}.$$

二阶导数为

$$\ell''(\mu) = -n < 0,$$

所以该临界点确为最大值。

10.5 正态均值与方差都未知

若 $X_1, \dots, X_n$ 独立来自 $N(\mu, \sigma^2)$, 且 μ, σ^2 都未知, 则

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

对 μ 求偏导并令其为零:

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \implies \hat{\mu} = \bar{x}.$$

再对 $v = \sigma^2$ 求偏导:

$$\frac{\partial \ell}{\partial v} = -\frac{n}{2v} + \frac{1}{2v^2} \sum_{i=1}^n (x_i - \mu)^2 = 0,$$

得到

$$\hat{v} = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2.$$

代入 $\hat{\mu} = \bar{x}$, 得到联合最大值点:

必须记忆: 正态分布参数的 MLE

$$\hat{\mu}_{\text{MLE}} = \bar{x}$$

$$\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

MLE 方差估计与样本方差不同

正态总体方差的 MLE 使用分母 n , 而无偏样本方差 S^2 使用分母 $n-1$:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

因此 $\hat{\sigma}_{\text{MLE}}^2$ 一般是有偏的, 但它由最大似然原则得到; S^2 则由无偏性原则得到。

10.6 Poisson 分布的 MLE

设 $Y_1, \dots, Y_n \stackrel{\text{iid}}{\sim} \text{Poisson}(\lambda)$, $\lambda > 0$ 。则

$$\mathcal{L}(\lambda) = \prod_{i=1}^n \frac{\lambda^{y_i} e^{-\lambda}}{y_i!},$$

$$\ell(\lambda) = \left(\sum_{i=1}^n y_i \right) \log \lambda - n\lambda - \sum_{i=1}^n \log(y_i!).$$

一阶导数为

$$\ell'(\lambda) = \frac{\sum_i y_i}{\lambda} - n.$$

令其为零得到

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n y_i = \bar{y}.$$

由于

$$\ell''(\lambda) = -\frac{\sum_i y_i}{\lambda^2} < 0$$

(非全零样本情形), 该临界点为最大值。若所有 $y_i = 0$ 且参数空间允许 $\lambda = 0$, 最大值位于边界 $\hat{\lambda} = 0$; 若严格规定 $\lambda > 0$, 似然在 $\lambda \downarrow 0$ 时趋近上确界, 但不在参数空间内取得最大值。

10.7 Binomial 分布的 MLE

为避免把“样本量”和“每次二项试验次数”混淆, 设

$$Y_1, \dots, Y_N \stackrel{\text{iid}}{\sim} \text{Binomial}(m, p), \quad 0 \leq p \leq 1.$$

忽略与 p 无关的组合数后,

$$\ell(p) = \left(\sum_{i=1}^N y_i \right) \log p + \left(Nm - \sum_{i=1}^N y_i \right) \log(1-p) + \text{constant}.$$

求导并令其为零:

$$\frac{\sum_i y_i}{p} - \frac{Nm - \sum_i y_i}{1-p} = 0,$$

故

$$\hat{p}_{\text{MLE}} = \frac{\sum_i y_i}{Nm} = \frac{\bar{y}}{m}.$$

对 $0 < p < 1$,

$$\ell''(p) = -\frac{\sum_i y_i}{p^2} - \frac{Nm - \sum_i y_i}{(1-p)^2} < 0,$$

所以内部临界点为最大值; 全失败或全成功样本的最大值分别位于边界 $p = 0$ 或 $p = 1$ 。Bernoulli 情形就是 $m = 1$, 因此 $\hat{p} = \bar{y}$ 。

10.8 Exponential 分布的 MLE

Week 13-14 使用的是 rate 参数化:

$$f(y; \theta) = \theta e^{-\theta y}, \quad y \geq 0, \quad \theta > 0.$$

于是

$$\begin{aligned} \ell(\theta) &= n \log \theta - \theta \sum_{i=1}^n y_i, \\ \ell'(\theta) &= \frac{n}{\theta} - \sum_i y_i, \quad \ell''(\theta) = -\frac{n}{\theta^2} < 0. \end{aligned}$$

因此

$$\hat{\theta}_{\text{MLE}} = \frac{n}{\sum_i y_i} = \frac{1}{\bar{y}}.$$

必须记忆: 常见分布的 MLE

$$Y_i \sim \text{Poisson}(\lambda) \implies \hat{\lambda} = \bar{Y}.$$

$$Y_i \sim \text{Binomial}(m, p) \implies \hat{p} = \frac{\bar{Y}}{m}.$$

$$f(y; \theta) = \theta e^{-\theta y} \implies \hat{\theta} = \frac{1}{\bar{Y}}.$$

Exponential 参数化必须先确认

若教材把 exponential 参数写成 scale $\eta = 1/\theta$, 密度会写成 $f(y; \eta) = \eta^{-1} e^{-y/\eta}$, 此时 MLE 为 $\hat{\eta} = \bar{Y}$ 。考试中必须先判断参数究竟是 rate 还是 scale。

MLE 不一定无偏

$$E(\hat{\lambda}) = \lambda \quad \text{for Poisson}, \quad E(\hat{p}) = p \quad \text{for Binomial}, \quad E(\hat{\mu}) = \mu \quad \text{for Normal mean}.$$

但是, 正态方差的 MLE 满足

$$E(\hat{\sigma}_{\text{MLE}}^2) = \frac{n-1}{n}\sigma^2,$$

因此有偏。Exponential rate 的 MLE $\hat{\theta} = n / \sum_i Y_i$ 在 $n > 1$ 时满足

$$E(\hat{\theta}) = \frac{n}{n-1}\theta,$$

也有偏。最大似然原则和无偏性是不同的估计准则。

10.9 正态方差的 MLE: 均值已知与未知

令 $v = \sigma^2$ 。若 $Y_i \stackrel{\text{iid}}{\sim} N(\mu, v)$ 且 μ 已知, 则

$$\ell(v) = -\frac{n}{2} \log v - \frac{1}{2v} \sum_{i=1}^n (y_i - \mu)^2 + \text{constant}.$$

求导并令其为零:

$$-\frac{n}{2v} + \frac{1}{2v^2} \sum_i (y_i - \mu)^2 = 0,$$

因此

$$\hat{v}_{\text{MLE}} = \frac{1}{n} \sum_{i=1}^n (y_i - \mu)^2.$$

若 μ 也未知, 先得到 $\hat{\mu} = \bar{y}$, 再代入得到

$$\hat{v}_{\text{MLE}} = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2.$$

11 MLE 的 Fisher Information 与渐近推断

11.1 定义、可加性与解释

设 $\ell(\theta) = \log \mathcal{L}(\theta)$, score function 为

$$U(\theta) = \frac{\partial \ell(\theta)}{\partial \theta}.$$

在允许交换微分与积分等常规正则条件下,

必须记忆: Fisher information

$$I_n(\theta) = -E_{\theta} \left[\frac{\partial^2 \ell(\theta)}{\partial \theta^2} \right] = E_{\theta} [U(\theta)^2].$$

若 $Y_1, \dots, Y_n$ i.i.d., 则

$$I_n(\theta) = nI_1(\theta).$$

Fisher information 衡量样本对未知参数所提供的信息量。信息越大, 参数估计通常越精确。在正则条件下, MLE 的大样本方差近似为

$$\text{Var}(\hat{\theta}_{\text{MLE}}) \approx \frac{1}{I_n(\theta)}.$$

无偏估计量还满足 Cramér–Rao 下界

$$\text{Var}(\hat{\theta}) \geq \frac{1}{I_n(\theta)}.$$

11.2 Poisson、Binomial 与 Exponential 的 Fisher information

Poisson 模型中,

$$\ell''(\lambda) = -\frac{\sum_i Y_i}{\lambda^2}.$$

由于 $E(\sum_i Y_i) = n\lambda$,

$$I_n(\lambda) = -E[\ell''(\lambda)] = \frac{n}{\lambda}.$$

若 $Y_1, \dots, Y_N \stackrel{\text{iid}}{\sim} \text{Binomial}(m, p)$, 则

$$\ell''(p) = -\frac{\sum_i Y_i}{p^2} - \frac{Nm - \sum_i Y_i}{(1-p)^2}.$$

利用 $E(\sum_i Y_i) = Nmp$,

$$I_N(p) = \frac{Nm}{p(1-p)}.$$

Exponential rate 模型中,

$$\ell''(\theta) = -\frac{n}{\theta^2},$$

所以

$$I_n(\theta) = \frac{n}{\theta^2}.$$

11.3 正态分布的 Fisher information

若 $Y_i \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$, 且 σ^2 已知, 则

$$\ell''(\mu) = -\frac{n}{\sigma^2},$$

故

$$I_n(\mu) = \frac{n}{\sigma^2}.$$

若 μ 已知, 未知参数为 $v = \sigma^2$, 则

$$\frac{\partial^2 \ell(v)}{\partial v^2} = \frac{n}{2v^2} - \frac{\sum_i (Y_i - \mu)^2}{v^3}.$$

因为 $E[\sum_i (Y_i - \mu)^2] = nv$,

$$I_n(v) = \frac{n}{2v^2} = \frac{n}{2\sigma^4}.$$

当 μ 与 $v = \sigma^2$ 都未知时, Fisher information 是矩阵。由于两个 score 的协方差为零,

$$\mathbf{I}_n(\mu, v) = \begin{pmatrix} n/v & 0 \\ 0 & n/(2v^2) \end{pmatrix}.$$

必须记忆: 课件常见模型的 Fisher information

模型与未知参数	样本 Fisher information
Poisson(λ)	$I_n(\lambda) = n/\lambda$
Binomial(m, p), 共 N 个观测	$I_N(p) = Nm/[p(1-p)]$
Exp(θ), rate 参数	$I_n(\theta) = n/\theta^2$
$N(\mu, \sigma^2)$, 仅 μ 未知	$I_n(\mu) = n/\sigma^2$
$N(\mu, \sigma^2)$, 仅 $v = \sigma^2$ 未知	$I_n(v) = n/(2v^2)$

Fisher information 计算模板

1. 写出完整样本的 log-likelihood $\ell(\theta)$;
2. 对参数求一阶、二阶导数;
3. 计算 $-E_\theta[\ell''(\theta)]$;
4. 若参数为向量, 逐项计算负期望 Hessian, 组成信息矩阵;
5. 最后检查结果是否随样本量 n 线性增加。

11.4 MLE 的渐近置信区间与临界值检验

在正则条件与大样本下, 标量参数的 MLE 近似正态:

$$\hat{\theta}_{\text{MLE}} \sim N\left(\theta, \frac{1}{I_n(\theta)}\right).$$

实际计算时通常用 $\hat{\theta}$ 代入未知的 Fisher information。

必须记忆: MLE 的渐近推断

$$\widehat{\text{SE}}(\hat{\theta}) = \frac{1}{\sqrt{I_n(\hat{\theta})}}.$$

$$(1 - \alpha)100\% \text{ 渐近置信区间: } \hat{\theta} \pm z_{\alpha/2} \widehat{\text{SE}}(\hat{\theta}).$$

检验 $H_0: \theta = \theta_0$ 时, Wald statistic 为

$$Z_{\text{obs}} = \frac{\hat{\theta} - \theta_0}{\widehat{\text{SE}}(\hat{\theta})}.$$

双侧备择在 $|Z_{\text{obs}}| \geq z_{\alpha/2}$ 时拒绝 H_0 ; 单侧备择按方向与 z_{α} 比较。

必须记忆: 常见 MLE 的渐近标准误

MLE	plug-in 渐近标准误
$\hat{\lambda} = \bar{Y}, \quad Y_i \sim \text{Poisson}(\lambda)$	$\sqrt{\hat{\lambda}/n}$
$\hat{p} = \bar{Y}/m, \quad Y_i \sim \text{Binomial}(m, p), \quad i = 1, \dots, N$	$\sqrt{\hat{p}(1 - \hat{p})/(Nm)}$
$\hat{\theta} = 1/\bar{Y}, \quad Y_i \sim \text{Exp}(\theta) \text{ rate}$	$\hat{\theta}/\sqrt{n}$
$\hat{\mu} = \bar{Y}, \quad Y_i \sim N(\mu, \sigma^2)$	$\sigma/\sqrt{n}$
$\hat{v}, \quad Y_i \sim N(\mu, v), \quad v = \sigma^2$	$\sqrt{2/n} \hat{v}$

渐近推断的边界问题

Wald 区间依赖大样本近似。对 p 接近 0 或 1、Poisson 均值很小、或正参数接近边界的情形, 区间可能越过参数空间, 近似质量也可能较差。题目未另作说明时按 Fisher information 公式计算, 并检查所得区间是否符合参数取值范围。

12 课件勘误与待核点对

Week 4 棒球回归例题疑似笔误

Week 4 课件的 baseball batting average 例题中, 课件给出

$$SS_{xy} = 0.003302, \quad SS_x = 0.001182.$$

据此应有

$$\hat{\beta}_1 = \frac{0.003302}{0.001182} \approx 2.7941,$$

而不是课件页中后续写出的 0.7941。相应截距应为

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \approx -0.2268,$$

而不是 0.2935。本笔记采用公式计算得到的结果。

Week 13–14 分布支撑集笔误

Week 13–14 课件在 Binomial 与 Normal 例题下方沿用了不正确的统一支撑集文字。正确支撑集为：

$$Y \sim \text{Binomial}(m, p) \implies Y \in \{0, 1, \dots, m\},$$

$$Y \sim N(\mu, \sigma^2) \implies Y \in \mathbb{R}.$$

Poisson 的支撑集才是 $\{0, 1, 2, \dots\}$ ，Exponential 的支撑集是 $[0, \infty)$ 。

重复课件关系

- SM&I Week 1, Lecture 2.pdf 与 SM&I Week 1, L2 and W2, L1.pdf 大量重复，后者补充了更多课堂问题；
- SM&I Week 2, Lecture 2.pdf 与 SM&I Week 3, Lecture 2.pdf 内容几乎相同，主题均为两总体均值；
- Week 3, Lecture 2.pdf 与 Week 3, Lecture 2_updated.pdf 主题相同，updated 版提取出的公式稍更完整。

课程覆盖完成状态

截至 2026-06-15，已按最新考试范围重新核对全部课件。本知识笔记集中覆盖：

- 无偏估计、MSE 分解及核心无偏性证明；
- 单均值、两均值、未知方差与总体比例的置信区间和临界值假设检验；
- 简单/多元线性回归、最小二乘估计、残差及其性质；
- Normal、Binomial、Poisson、Exponential 的 MLE、Fisher information 与渐近推断。

重要基石公式均使用橙色公式盒标明；MSE、样本方差、简单/多元最小二乘、回归估计量无偏性、残差性质与主要 MLE 推导均已完整写出。

不纳入后续笔记范围

ANOVA/ANCOVA、R 编程、P-value 与 Power 不进入考试范围，因此不纳入知识笔记与后续题型笔记。